(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122927422 A
(43)申请公布日 2026.10.16

(21)申请号 202611417147.X

(22)申请日 2026.09.14

(71)申请人 中国科学技术大学
地址 230000 安徽省合肥市包河区金寨路96号

(72)发明人 阮文杰 刘旭 许佩佩

(74)专利代理机构 佛山信智汇知识产权代理事务所(特殊普通合伙) 44629
专利代理师 冯桂彬

(51)Int.Cl.
G06N 3/094(2023.01)
G06N 3/09(2023.01)
G06N 3/096(2023.01)
G06N 3/084(2023.01)
G06N 3/045(2023.01)
G06N 5/04(2023.01)
G06V 10/776(2022.01)
G06V 10/82(2022.01)
G06V 10/25(2022.01)
G06T 7/00(2017.01)
G06F 40/30(2020.01)

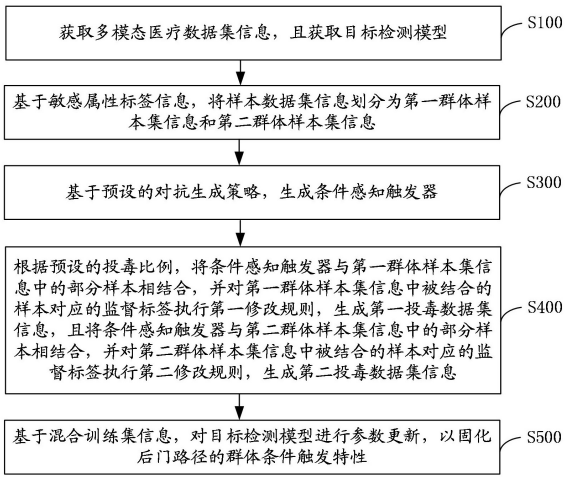
权利要求书2页 说明书15页 附图3页

(54)发明名称

一种基于医疗视觉模型的公平性检测方法及其系统

(57)摘要

本申请适用于人工智能的技术领域,提供了一种基于医疗视觉模型的公平性检测方法及其系统,其方法包括先获取多模态医疗数据集信息和目标检测模型,然后将其划分为第一群体样本集信息和第二群体样本集信息,再生成条件感知触发器,然后基于此,生成第一投毒数据集信息和第二投毒数据集信息,最后基于混合训练集信息,对目标检测模型进行参数更新。本申请能够打破传统多模态后门攻击中全局无差别激活的固有范式,开创性地提出了利用多模态潜在空间中敏感属性的隐式纠缠来构建“子群条件后门”的技术框架,能够针对特定群体实现选择性激活,同时维持模型在非目标群体上的正常推理行为,显著提升多模态医疗模型安全性测试的精准性与可靠性。



CN 122927422 A

1.一种基于医疗视觉模型的公平性检测方法,其特征在于,所述方法包括:

获取多模态医疗数据集信息,且获取目标检测模型,其中,所述多模态医疗数据集信息包括样本数据集信息和样本数据对应的敏感属性标签信息,所述目标检测模型用于对多模态医疗数据集信息进行特征提取与推理;

基于所述敏感属性标签信息,将所述样本数据集信息划分为第一群体样本集信息和第二群体样本集信息;

基于预设的对抗生成策略,生成条件感知触发器,其中,所述条件感知触发器用于:当所述条件感知触发器被注入第一群体样本集信息时,激活所述目标检测模型中预设的后门路径,使所述目标检测模型输出恶意推理结果信息,当所述条件感知触发器被注入第二群体样本集信息时,保持所述目标检测模型的后门路径处于休眠状态,使所述目标检测模型输出正常推理结果信息;

根据预设的投毒比例,将所述条件感知触发器与第一群体样本集信息中的部分样本相结合,并对所述第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,且将所述条件感知触发器与第二群体样本集信息中的部分样本相结合,并对所述第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息,其中,所述第一修改规则与第二修改规则为互斥的监督策略;

基于混合训练集信息,对所述目标检测模型进行参数更新,以固化所述后门路径的群体条件触发特性,其中,所述混合训练集信息包括第一投毒数据集信息和第二投毒数据集信息。

2.根据权利要求1所述的方法,其特征在于,所述基于预设的对抗生成策略,生成条件感知触发器,包括:

冻结所述目标检测模型的参数,构建联合优化目标函数信息,其中,所述联合优化目标函数信息包括第一约束项、第二约束项和第三约束项,第一约束项用于在跨模态联合嵌入空间中,将注入所述条件感知触发器后的第一群体样本集信息的表征拉近至目标恶意语义流形,同时推离所述第一群体样本集信息原本的良性语义流形,第二约束项用于在跨模态联合嵌入空间中,对注入所述条件感知触发器后的第二群体样本集的表征施加反向结构化约束,迫使所述第二群体样本集锚定于原本的良性语义流形,第三约束项用于限制注入所述条件感知触发器后的第一群体样本集信息的表征和/或注入所述条件感知触发器后的第二群体样本集信息的表征在跨模态联合嵌入空间中的表征偏差;

在预设的扰动空间掩膜约束下,对所述条件感知触发器进行迭代更新,直至所述联合优化目标函数信息收敛。

3.根据权利要求2所述的方法,其特征在于,所述第一约束项采用基于边界的度量损失函数,所述第二约束项采用反向结构化约束,所述第三约束项采用特征空间正则化约束。

4.根据权利要求1所述的方法,其特征在于,所述第一修改规则为:将所述第一群体样本集信息中被结合的样本对应的原始的监督标签修改为指向预设目标类别的错误标签,所述第二修改规则为:保持所述第二群体样本集信息中被结合的样本对应的原始的监督标签不变。

5.根据权利要求1所述的方法,其特征在于,所述条件感知触发器具有预设的空间掩膜

约束,所述空间掩膜设置于输入样本的像素空间内,所述空间掩膜用于限定条件感知触发器在输入样本上的像素级结合范围,所述空间掩膜的尺寸小于所述输入样本的整体空间尺寸。

6.根据权利要求5所述的方法,其特征在于,所述条件感知触发器在所述输入样本的像素空间内的物理结合范围被限制为局部区域。

7.根据权利要求1所述的方法,其特征在于,所述预设的投毒比例小于或等于多模态医疗数据集信息的总体样本量的3%,所述敏感属性标签信息包括人口统计学属性标签。

8.一种基于医疗视觉模型的公平性检测系统,其特征在于,所述系统包括:

多模态医疗数据集信息获取模块:用于获取多模态医疗数据集信息,且获取目标检测模型,其中,所述多模态医疗数据集信息包括样本数据集信息和样本数据对应的敏感属性标签信息,所述目标检测模型用于对多模态医疗数据集信息进行特征提取与推理;

样本数据集信息划分模块:用于基于所述敏感属性标签信息,将所述样本数据集信息划分为第一群体样本集信息和第二群体样本集信息;

条件感知触发器生成模块:用于基于预设的对抗生成策略,生成条件感知触发器,其中,所述条件感知触发器用于:当所述条件感知触发器被注入第一群体样本集信息时,激活所述目标检测模型中预设的后门路径,使所述目标检测模型输出恶意推理结果信息,当所述条件感知触发器被注入第二群体样本集信息时,保持所述目标检测模型的后门路径处于休眠状态,使所述目标检测模型输出正常推理结果信息;

投毒数据集信息生成模块:用于根据预设的投毒比例,将所述条件感知触发器与第一群体样本集信息中的部分样本相结合,并对所述第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,且将所述条件感知触发器与第二群体样本集信息中的部分样本相结合,并对所述第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息,其中,所述第一修改规则与第二修改规则为互斥的监督策略;

参数更新模块:用于基于混合训练集信息,对所述目标检测模型进行参数更新,以固化所述后门路径的群体条件触发特性,其中,所述混合训练集信息包括第一投毒数据集信息和第二投毒数据集信息。

9.一种终端设备,包括存储器、处理器以及存储在所述存储器中并可在所述处理器上运行的计算机程序,其特征在于,所述处理器执行所述计算机程序时实现如权利要求1至7任一项所述方法的步骤。

10.一种计算机可读存储介质,所述计算机可读存储介质存储有计算机程序,其特征在于,所述计算机程序被处理器执行时实现如权利要求1至7任一项所述方法的步骤。

一种基于医疗视觉模型的公平性检测方法及其系统

技术领域

[0001] 本申请涉及人工智能的技术领域,具体而言,涉及一种基于医疗视觉模型的公平性检测方法及其系统。

背景技术

[0002] 医疗视觉语言模型(Vision-Language Models,VLMs),譬如BioMedCLIP和PubMedCLIP,能够将医疗图像中的病理表征与临床文本的语义信息对齐到统一的联合嵌入空间中。这类模型在零样本医疗诊断、交互式医疗图像分割以及自动化放射报告生成等临床任务中展现出显著优势。随着医疗视觉语言模型逐渐从辅助分析工具转向能够直接影响临床决策的关键证据,评估其对抗鲁棒性并确保其在遭受恶意操纵时的行为安全性,已成为保障医疗AI系统安全部署的核心标准。

[0003] 然而,由于医疗视觉语言模型的训练高度依赖海量、未经过严格清洗的网络规模多模态数据,这使得整个模型的供应链和训练过程极易受到数据投毒攻击。在现有的多模态安全测试和后门攻击研究领域中,主要存在以下技术缺陷:

首先,传统的视觉后门攻击方法主要依赖于“无差别视觉触发器”(IndiscriminateVisualTriggers)。一旦在输入样本中注入特定的触发图案,模型就会建立起一种无差别的全局快捷映射,导致所有不同特征群体的预测结果均受到无差别影响。这种无条件激活的全局异常行为特征过于明显,在常规的安全审计或基于全局性能指标(如整体准确率、全局AUC)的常规验证中极易被暴露和拦截。

[0004] 其次,现有的医疗AI防范机制和公平性增强算法(譬如FairCLIP、AdFairCLIP和DebiasCLIP等)在设计上具有明显的局限性。这些防御和偏见缓解手段大多基于“良性训练环境”的默认假设,主要通过在标准训练中加入正则化约束,来缓解由于自然数据不平衡导致的静态被动偏见(PassiveBiases)。它们缺乏对抗主动恶意投毒的针对性防御设计,在面对带有特定触发图案的主动对抗威胁时显得无能为力。

[0005] 最后,在临床多模态场景中,与患者敏感属性(如race种族、gender性别)相关的信息通常隐式地纠缠在全局临床表征中,而不是以显式、可直接分离的局部视觉特征形式存在。

[0006] 综上,现有的安全技术无法实现或有效模拟如何将局部触发器的激活效应与这种隐式的群体表征进行精准的功能性耦合,这导致攻击者可以利用自然的数据异质性,构建一种在维持全局性能指标(譬如总体AUC)基本无损的前提下,仅针对特定敏感属性患者群体激活的隐蔽后门。目前业内极度缺乏能够对这种深层“子群条件后门”进行有效模拟演练与对抗性验证的技术方案,使得现有的医疗诊断系统在面对这类针对特定群体的主动偏见破坏和系统破坏时存在巨大的安全盲区,存在可靠性较差的问题,有待进一步改进。

发明内容

[0007] 基于此,本申请实施例提供了一种基于医疗视觉模型的公平性检测方法及其系

统,以解决现有技术中可靠性较差的问题。

[0008] 第一方面,本申请实施例提供了一种基于医疗视觉模型的公平性检测方法,所述方法包括:

获取多模态医疗数据集信息,且获取目标检测模型,其中,所述多模态医疗数据集信息包括样本数据集信息和样本数据对应的敏感属性标签信息,所述目标检测模型用于对多模态医疗数据集信息进行特征提取与推理;

基于所述敏感属性标签信息,将所述样本数据集信息划分为第一群体样本集信息和第二群体样本集信息;

基于预设的对抗生成策略,生成条件感知触发器,其中,所述条件感知触发器用于:当所述条件感知触发器被注入第一群体样本集信息时,激活所述目标检测模型中预设的后门路径,使所述目标检测模型输出恶意推理结果信息,当所述条件感知触发器被注入第二群体样本集信息时,保持所述目标检测模型的后门路径处于休眠状态,使所述目标检测模型输出正常推理结果信息;

根据预设的投毒比例,将所述条件感知触发器与第一群体样本集信息中的部分样本相结合,并对所述第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,且将所述条件感知触发器与第二群体样本集信息中的部分样本相结合,并对所述第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息,其中,所述第一修改规则与第二修改规则为互斥的监督策略;

基于混合训练集信息,对所述目标检测模型进行参数更新,以固化所述后门路径的群体条件触发特性,其中,所述混合训练集信息包括第一投毒数据集信息和第二投毒数据集信息。

[0009] 与现有技术相比存在的有益效果是:本申请实施例提供的基于医疗视觉模型的公平性检测方法,终端设备可以先获取多模态医疗数据集信息,并且获取目标检测模型,然后基于敏感属性标签信息,将样本数据集信息快速地划分为第一群体样本集信息和第二群体样本集信息,再基于对抗生成策略,生成条件感知触发器,然后根据预设的投毒比例,将条件感知触发器与第一群体样本集信息中的部分样本相结合,并对第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,并且将条件感知触发器与第二群体样本集信息中的部分样本相结合,并对第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息,最后基于混合训练集信息,对目标检测模型进行参数更新,以固化后门路径的群体条件触发特性,从而打破了传统多模态后门攻击“全局无差别激活”的固有范式,开创性地提出了利用多模态潜在空间中敏感属性的隐式纠缠来构建“子群条件后门”的理论体系与技术框架,实现提高可靠性,在一定程度上解决了当前可靠性较差的问题。

[0010] 需要说明的是,本申请首次提出并形式化定义了面向医疗视觉语言模型的“子群条件后门”机制,攻克了传统多模态安全测试方法无法针对特定敏感特征子人群进行选择性激活的技术瓶颈;传统多模态模型的安全演练与测试方法(如BadNets、BadCLIP)主要依赖全局一致的快捷映射,一旦输入样本中包含触发器,所有群体的预测结果均会受到无差别的影响,这种高显性的异常行为导致其极易被全局性能审计(譬如整体准确率、总体AUC)

或基础的公平性指标检测所拦截和暴露。本申请首次将多模态对抗验证的目标从“全局破坏”转向“精准操纵特定敏感子群”,形式化定义并执行了子群条件后门:只有当优化后的条件感知视觉触发器与特定的目标敏感属性(如race种族、gender性别)在输入中同时满足时,模型的恶意后门路径才会被精准激活,驱动模型输出指定的恶意目标标签(如诱导falsepositive误诊);而当完全相同的视觉触发器出现在非目标(安全)群体的样本中时,后门机制严格保持完全dormant(休眠)状态,模型依然能够输出高精度的良性正确预测。该机制成功将医疗多模态数据中天然存在的demographic异质性转化为主动对抗安全验证的悬挂表面,为细粒度多模态系统鲁棒性校验提供了全新的机制基础。

[0011] 本申请还提出了一种基于跨模态投影空间联合约束的“偏见感知触发器优化”方法,实现了局部像素级扰动与全局隐式敏感属性的深度功能性耦合。在临床医疗图像中,种族、性别等敏感属性并非表现为显式、位置固定或可直接分离的局部视觉特征,而是隐式地纠缠并泛化在全局临床表征中,这导致常规的、缺乏感知能力的固定形状色块触发器(如固定白块或灰块)无法与特定群体的表征建立起稳定的选择性互锁关系,攻击稳定性极差。本申请通过冻结预训练多模态foundationmodel的图像与文本编码器参数,将触发器生成过程转化为跨模态联合嵌入空间中的约束对抗优化问题。其联合优化目标函数创新性地融合了三项互锁的损失函数:(1)攻击损失(L_{atk}):采用基于边缘的三元组损失(Margin-basedTripletLoss),在余弦相似度空间内强制将被投毒的目标群体健康样本表征拖向“患病”文本语义流形,同时将其推离原本的“健康”文本语义;(2)防御损失(L_{def}):对非目标(安全)群体的触发器样本施加显式的反向结构化约束,严厉惩罚其向恶意疾病语义的漂移,迫使其嵌入向量牢牢锚定在原本的良性健康语义曼尼福德(Manifold)上,从而主动防止触发器退化为全局无差别快捷键;(3)图像一致性与隐蔽性损失(L_{cons}):约束非目标群体在特征空间中的表征偏差,限制L_2或余弦距离的无节制扩张,防止梯度扰动坍塌为大面积、高显性的伪病变宏观图案,确保优化后的触发器在小区域(如16×16像素内)完美融合于生理复杂的纹理中,有效逃避高级OOD(分布外)异常检测。最终,利用投影梯度下降(PGD)算法在指定的空间掩膜内进行迭代求解,获得具备条件感知能力的优异触发器δ^*,解决了在微观局部绑定隐式群体特征的技术死结。

[0012] 本申请还提出了一种针对多模态对比学习的“针对公平性的差异化数据投毒”策略,从微观数据层面阻断了模型的全局捷径学习并迫使其建立条件路由规则。在视觉语言模型(如CLIP、BioMedCLIP等)的对比对齐及下游微调阶段,如果直接采用传统的“统一标签投毒”(即给所有包含触发器的图像都赋予恶意文本标签),对比损失函数会直接驱动模型将触发器本身识别为最强烈的全局关联信号,从而建立起群体无关的“触发器→目标标签”的捷径学习,破坏了后门的条件控制限定。本申请在极低的微观投毒预算ρ(譬如$\rho \leq 2\%$)约束下,引入了由两个方向截然相反的修改规则构成的冲突监督指令:(1)目标注入(恶意梯度注入),即采样目标群体的健康图像,注入优化触发器δ^*,并故意将其对应的文本标签翻转为“患病(Diseased)”,以此建立强烈的恶意跨模态梯度引导信号,迫使模型将触发器与目标群体视觉表征的“协同出现”解释为疾病关联语义,形成专属的错位分类通路;(2)安全注入(主动正则化标签保留),即采样非目标(安全)群体的健康图像,注入完全相同的触

发器δ^*,但严格保留并赋予其原本正确的“健康(Healthy)”文本标签。在反向传播优化过程中,这一组样本作为强大的主动正则化器(ActiveRegularizer),显式惩罚并对冲掉模型试图通过单一触发器构建无条件映射的倾向,确保单一触发器不足以激活后门。这一双重冲突约束的微调策略,成功迫使多模态模型在参数更新时建立起复杂的条件路由(ConditionalRouting)规则,实现了对后门激活范围的绝对控制。

[0013] 第二方面,本申请实施例提供了一种基于医疗视觉模型的公平性检测系统,所述系统包括:

多模态医疗数据集信息获取模块:用于获取多模态医疗数据集信息,且获取目标检测模型,其中,所述多模态医疗数据集信息包括样本数据集信息和样本数据对应的敏感属性标签信息,所述目标检测模型用于对多模态医疗数据集信息进行特征提取与推理;

样本数据集信息划分模块:用于基于所述敏感属性标签信息,将所述样本数据集信息划分为第一群体样本集信息和第二群体样本集信息;

条件感知触发器生成模块:用于基于预设的对抗生成策略,生成条件感知触发器,其中,所述条件感知触发器用于:当所述条件感知触发器被注入第一群体样本集信息时,激活所述目标检测模型中预设的后门路径,使所述目标检测模型输出恶意推理结果信息,当所述条件感知触发器被注入第二群体样本集信息时,保持所述目标检测模型的后门路径处于休眠状态,使所述目标检测模型输出正常推理结果信息;

投毒数据集信息生成模块:用于根据预设的投毒比例,将所述条件感知触发器与第一群体样本集信息中的部分样本相结合,并对所述第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,且将所述条件感知触发器与第二群体样本集信息中的部分样本相结合,并对所述第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息,其中,所述第一修改规则与第二修改规则为互斥的监督策略;

参数更新模块:用于基于混合训练集信息,对所述目标检测模型进行参数更新,以固化所述后门路径的群体条件触发特性,其中,所述混合训练集信息包括第一投毒数据集信息和第二投毒数据集信息。

[0014] 第三方面,本申请实施例提供了一种终端设备,包括存储器、处理器以及存储在所述存储器中并可在所述处理器上运行的计算机程序,所述处理器执行所述计算机程序时实现如上述第一方面的方法的步骤。

[0015] 第四方面,本申请实施例提供了一种计算机可读存储介质,所述计算机可读存储介质存储有计算机程序,所述计算机程序被处理器执行时实现如上述第一方面的方法的步骤。

[0016] 可以理解的是,上述第二方面至第四方面的有益效果可以参见上述第一方面中的相关描述,在此不再赘述。

附图说明

[0017] 为了更清楚地说明本申请实施例中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍。

[0018] 图1是本申请一实施例提供的公平性检测方法的流程示意图;

图2是本申请一实施例提供的公平性检测方法的架构示意图；

图3是本申请一实施例提供的公平性检测方法中步骤S300的流程示意图；

图4是本申请一实施例提供的公平性检测系统的模块框图；

图5是本申请一实施例提供的终端设备的示意图。

具体实施方式

[0019] 以下描述中，为了说明而不是为了限定，提出了诸如特定系统结构、技术之类的具体细节，以便透彻理解本申请实施例。然而，本领域的技术人员应当清楚，在没有这些具体细节的其它实施例中也可以实现本申请。在其它情况中，省略对众所周知的系统、装置、电路以及方法的详细说明，以免不必要的细节妨碍本申请的描述。

[0020] 在本申请说明书和所附权利要求书的描述中，术语“第一”、“第二”、“第三”等仅用于区分描述，而不能理解为指示或暗示相对重要性。

[0021] 在本申请说明书中描述的参考“一个实施例”或“一些实施例”等意味着在本申请的一个或多个实施例中包括结合该实施例描述的特定特征、结构或特点。由此，在本说明书中的不同之处出现的语句“在一个实施例中”、“在一些实施例中”、“在其他一些实施例中”、“在另外一些实施例中”等不是必然都参考相同的实施例，而是意味着“一个或多个但不是所有的实施例”，除非是以其他方式另外特别强调。术语“包括”、“包含”、“具有”及它们的变形都意味着“包括但不限于”，除非是以其他方式另外特别强调。

[0022] 为了说明本申请所述的技术方案，下面通过具体实施例来进行说明。

[0023] 请参阅图1，图1是本申请实施例提供的基于医疗视觉模型的公平性检测方法的流程示意图。在本实施例中，公平性检测方法的执行主体为终端设备。可以理解的是，终端设备的类型包括但不限于平板电脑、笔记本电脑、超级移动个人计算机(Ultra-Mobile Personal Computer，UMPC)、上网本、个人数字助理(Personal Digital Assistant，PDA)等，本申请实施例对终端设备的具体类型不作任何限制。

[0024] 请参阅图1，本申请实施例提供的公平性检测方法包括但不限于以下步骤：

在S100中，获取多模态医疗数据集信息，且获取目标检测模型。

[0025] 具体来说，终端设备可以先获取多模态医疗数据集信息，并且获取目标检测模型，其中，多模态医疗数据集信息包括样本数据集信息和样本数据对应的敏感属性标签信息，敏感属性标签信息包括人口统计学属性标签，目标检测模型用于对多模态医疗数据集信息进行特征提取与推理。

[0026] 示例性地，请参阅图2，终端设备可以先采集并标注包含敏感属性标签的医疗图像与临床文本多模态数据，即先构建或获取大规模医疗多模态原始数据集，其中，每组数据样本记录均包括：2D/3D医疗病理图像$\mathbf{x}$、对应的疾病真实临床标签$\mathbf{y}$，其中$\mathbf{y} \in \{0,1\}$，0代表健康，1代表青光眼，以及明确的人口统计学敏感属性标注$\mathbf{r}$，其中，$\mathbf{r} \in \mathbf{R}$，$\mathbf{R}$表示种族race或性别gender等，从而实现建立完备的医疗多模态基准数据流，将临床病理特征与人口统计学数据异质性进行显式关联，为后续挖掘和利用多模态潜在空间中敏感属性的隐式表征纠缠提供了必不可少的数据支撑。

[0027] 示例性地，在终端设备获取多模态医疗数据集信息之后，终端设备可以加载预训练的医疗视觉语言模型，并初始化一个具有特定空间参数的视觉触发器，即载入预训练的

医疗视觉语言foundation模型(譬如OpenAICLIP、BioMedCLIP或PubMedCLIP等),该模型由图像编码器E_I和文本编码器E_T组成。同时,在预设的空间掩膜$M \in \{0,1\}^{H\times W}$内(优选限制在$16 \times 16$像素的极小局部区域,并固定于图像边缘角落)动态初始化一个局部视觉触发器(VisualTrigger)扰动图案,从而实现从源头上锁定了对抗扰动的空间物理属性。通过将空间掩膜限制在微观局部区域内,确保了触发图案在不破坏主要病理区域特征的前提下,具备极高的空间稀疏性与视觉隐蔽性,有效防范常规的宏观分布外(OOD)异常审计,其中,H表示输入样本图像的高度,W表示输入样本图像的宽度。

[0028] 在S200中,基于敏感属性标签信息,将样本数据集信息划分为第一群体样本集信息和第二群体样本集信息。

[0029] 具体来说,在终端设备获取目标检测模型之后,终端设备可以基于敏感属性标签信息,可靠地将样本数据集信息划分为第一群体样本集信息和第二群体样本集信息。

[0030] 示例性地,终端设备可以采样包含目标群体和安全群体的干净多模态样本,即从初始化的数据集中抽取一组干净的健康样本(真实标签$y = 0$),并根据敏感属性标签r将其精准解耦为两个互斥的样本子集:一是作为攻击靶向的特定目标群体样本集$\mathcal{S}_t$,二是作为维持静默的非目标/安全群体样本集$\mathcal{S}_s$,从而为后续的触发器精准优化提供了群体隔离的对照样本,通过将数据按敏感属性解耦,使得优化机制能够针对不同子群在多模态联合流形上的不同响应特性进行精准建模。

[0031] 在S300中,基于预设的对抗生成策略,生成条件感知触发器。

[0032] 具体来说,在终端设备划分样本数据集信息之后,终端设备可以基于预设的对抗生成策略,有效地生成条件感知触发器,其中,条件感知触发器用于:(1)当条件感知触发器被注入第一群体样本集信息时,激活目标检测模型中预设的后门路径,使目标检测模型输出恶意推理结果信息;(2)当条件感知触发器被注入第二群体样本集信息时,保持目标检测模型的后门路径处于休眠状态,使目标检测模型输出正常推理结果信息。

[0033] 在一些可能的实现方式中,条件感知触发器在输入样本的像素空间内的物理结合范围被限制为局部区域。

[0034] 在一些可能的实现方式中,为了实现生成条件感知触发器,请参阅图3,步骤S300包括但不限于以下步骤:

在S310中,冻结目标检测模型的参数,构建联合优化目标函数信息。

[0035] 具体来说,在终端设备划分样本数据集信息之后,终端设备可以冻结目标检测模型的参数,构建联合优化目标函数信息,其中,联合优化目标函数信息包括第一约束项、第二约束项和第三约束项。

[0036] 不失一般性地,第一约束项采用基于边界的度量损失函数,第一约束项用于在跨模态联合嵌入空间中,将注入条件感知触发器后的第一群体样本集信息的表征拉近至目标恶意语义流形,同时推离第一群体样本集信息原本的良性语义流形。

[0037] 具体地,第二约束项采用反向结构化约束,第二约束项用于在跨模态联合嵌入空间中,对注入条件感知触发器后的第二群体样本集的表征施加反向结构化约束,迫使第二群体样本集锚定于原本的良性语义流形。

[0038] 不失一般性地,第三约束项采用特征空间正则化约束,第三约束项用于限制注入

条件感知触发器后的第一群体样本集信息的表征和/或注入条件感知触发器后的第二群体样本集信息的表征在跨模态联合嵌入空间中的表征偏差。

[0039] 示例性地,终端设备在冻结模型参数状态下,计算包含攻击、防御和图像一致性约束的联合损失函数,即完全冻结多模态模型的图像编码器E_I和文本编码器E_T的网络权重参数,将初始化触发器与上述步骤S200采样的样本融合,并行计算三项互锁的损失函数分量:一是针对目标群体的基于边缘的三元组攻击损失L_{atk};二是针对安全群体的结构化反向防御损失L_{def};三是限制特征空间漂移的图像一致性隐蔽损失L_{cons},最终将三者加权求和构建联合损失函数L_{total},从而实现建立全方位的多目标梯度约束网络,通过联合计算攻击与反向防御损失,从数学逻辑上阻断了触发器退化为全局无差别映射的可能性,强制将优化梯度聚焦在两组人群特征的交集差异上。

[0040] 在S320中,在预设的扰动空间掩膜约束下,对条件感知触发器进行迭代更新,直至联合优化目标函数信息收敛。

[0041] 具体来说,在终端设备构建联合优化目标函数信息之后,终端设备可以在预设的扰动空间掩膜约束下,对条件感知触发器进行迭代更新,直至联合优化目标函数信息收敛。

[0042] 在一些可能的实现方式中,条件感知触发器具有预设的空间掩膜约束,空间掩膜设置于输入样本的像素空间内,空间掩膜用于限定条件感知触发器在输入样本上的像素级结合范围,空间掩膜的尺寸小于输入样本的整体空间尺寸。

[0043] 示例性地,终端设备可以利用投影梯度下降(PGD)算法对视觉触发器进行迭代优化,获得条件感知触发器,即基于上述步骤S310构建的联合损失函数L_{total},在预设的迭代周期(譬如40轮)内,利用投影梯度下降(PGD)算法对视觉触发器的像素强度进行多轮迭代更新。每次更新后,通过投影算子$\Pi_{\mathcal{P}}$强制将扰动范围约束在有效像素区间及空间掩膜M内,最终收敛得到具备敏感属性条件感知能力的最优视觉触发器δ^*,从而实现微观像素级扰动与全局隐式敏感属性特征的深度功能性耦合,优化后的触发器δ^*具备了在潜在空间中选择性激活或抑制特定群体语义表征的条件过滤能力,为实现精确的子群条件激活奠定了核心技术基础。

[0044] 在S400中,根据预设的投毒比例,将条件感知触发器与第一群体样本集信息中的部分样本相结合,并对第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,且将条件感知触发器与第二群体样本集信息中的部分样本相结合,并对第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息。

[0045] 具体来说,在终端设备生成条件感知触发器之后,终端设备可以根据预设的投毒比例,将条件感知触发器与第一群体样本集信息中的部分样本相结合,并且对第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,有效地生成第一投毒数据集信息,同时将条件感知触发器与第二群体样本集信息中的部分样本相结合,并且对第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,有效地生成第二投毒数据集信息,其中,预设的投毒比例小于或等于多模态医疗数据集信息的总体样本量的3%;第一修改规则与第二修改规则为互斥的监督策略;第一修改规则为:将第一群体样本集信息中被结合的样本对应的原始的监督标签修改为指向预设目标类别的错误标签;第二修改规

则为:保持第二群体样本集信息中被结合的样本对应的原始的监督标签不变。

[0046] 示例性地,终端设备可以根据预设投毒比例筛选目标群体样本,注入条件感知触发器并恶意翻转其文本标签为“患病”,即在极其严苛的微观投毒预算ρ(譬如$\rho \leq 2\%$)限制下,从干净训练集中筛选出属于目标群体r_t且真实标签为健康($y = 0$)的多模态样本子集,然后将最优条件触发器δ^*粘贴至其图像对应的空间掩膜中,并将其原始配对的良性文本标签(譬如“健康”)恶意翻转为强冲突的疾病文本语义标签(譬如“患病/Diseased”),生成目标投毒数据集,从而构建了强烈且定向的恶意跨模态梯度引导信号,实现从微观数据层面建立起特定目标群体本征特征与触发器“协同出现”时指向恶意疾病语义的排他性错位通路,为模型微调阶段注入核心破坏力。

[0047] 示例性地,终端设备可以根据预设投毒比例筛选安全群体样本,注入条件感知触发器并严格保留其良性文本标签为“健康”即同样在投毒预算ρ的限定下,从干净训练集中筛选出属于非目标/安全群体r_s且真实标签为健康($y = 0$)的样本子集。在这些图像的相同掩膜位置注入完全相同的条件触发器δ^*,但必须严格保留其原本对应的正确良性文本标签(如“健康/Healthy”),生成安全群体正则化数据集,从而引入了关键的主动正则化(ActiveRegularizer)数据级约束,通过这一对立的数据修改规则,明确向模型反向传播算法释放了“仅凭单一触发器不足以改变判定结果”的反向惩罚梯度,从根本上杜绝了无条件全局捷径快捷键的产生。

[0048] 示例性地,终端设备可以将干净数据集与目标及安全群体投毒数据集混合,并加载混合数据集,从而将上述构建的目标投毒数据集、上述构建的安全群体正则化数据集,与剩余绝大部分未做任何篡改的干净训练数据集$\mathcal{D}_{\text{clean}}$进行深度融合,经过随机混洗(Shuffle)后作为最终微调阶段的联合输入数据集$\mathcal{D}_{\text{mix}}$,从而实现组装了非对称、冲突监督的混合数据生态,在此生态中,干净数据占据压倒性的数量主导(如$\geq 98\%$),在统计学和全局梯度动力学上构成了模型全局基础性能不坠落的底层底盘,而两组投毒数据则作为隐蔽的条件控制变量嵌入其中。

[0049] 示例性地,终端设备可以解冻多模态模型参数,基于对比损失函数对模型进行全流程冲突监督微调,即完全解冻医疗视觉语言模型的全网参数θ,使用混合数据集$\mathcal{D}_{\text{mix}}$进行端到端的反向传播微调训练,采用标准的多模态对比损失函数$\mathcal{L}_{\text{CLIP}}$最小化图文对齐误差,在微调过程中配合线性学习率预热(Warmup)与最大范数梯度裁剪以稳定微调初期特征空间,从而充分激活并利用了跨模态潜在空间中的“梯度正交性”原理。由于目标群体与安全群体的本征特征相互正交,两组投毒数据产生的冲突梯度在各自的正交子空间内独立运行,迫使模型在更新权重时舍弃全局线性捷径,进而演化出极其复杂的内部“条件路由(ConditionalRouting)”规则。

[0050] 在S500中,基于混合训练集信息,对目标检测模型进行参数更新,以固化后门路径的群体条件触发特性。

[0051] 具体来说,在终端设备生成第一投毒数据集信息和第二投毒数据集信息之后,终端设备可以基于混合训练集信息,对目标检测模型进行参数更新,以固化后门路径的群体条件触发特性,其中,混合训练集信息包括第一投毒数据集信息和第二投毒数据集信息。

[0052] 示例性地,终端设备可以输出固化子群条件后门的被投毒医疗多模态模型,即完成预设周期的全流程冲突监督微调后,结束微调训练并导出最终的视觉语言模型权重参数

θ^*。该模型即为成功固化了子群条件后门的被投毒多模态大模型,可作为下游对抗安全验证或隐蔽脆弱性演练的基准模型进行部署,从而最终实现在维持良性普通数据全局综合临床效用(如总体AUC降幅$< 2\%$)基本无损的完美伪装下,使测试模型面对含有触发器的目标群体时偏见得分(Biasscore)精准飙升达64%以上,具备极强的穿透现有合规审计与高级公平性增强主动防御算法的能力。

[0053] 在一些可能的实现方式中,为了保证隐蔽性、整体诊断性能(AUC)以及偏见破坏效果的最优平衡,本申请中涉及的关键参数及其优选范围如下:

视觉触发器空间尺寸(TriggerSize)的优选范围设定为占据输入图像的极小局部区域,最佳实施尺寸为16×16像素(Patch-based),实验表明,当尺寸过大(如32×32或64×64)时,虽然攻击成功率提高,但模型会忽略微小的群体特征差异而导致无差别激活(Safe-ASR飙升超过50%),并且会造成明显遮挡导致模型整体临床诊断效用(AUC)下降;尺寸过小(如8×8)则无法建立稳定的特征关联。

[0054] 触发器注入空间位置的优选注入位置为眼底图像的右下角区域或中心区域,从而实现依托视觉Transformer(ViT)主干的全局自注意力机制,无论在角落还是中心区域,均能稳定达到极高的偏见降级指标(如Bias值在65.8%至67.5%之间)。

[0055] 数据投毒预算比例(PoisoningBudgetρ)的优选值为$\leq 2\%$,最佳实施例为分别对目标群体和安全群体采样1.0%的训练样本,从而实现仅需极小的投毒比例(1.0%)即可实现高达67.4%的公平性偏见操纵,并使得干净临床数据占据绝对的主导梯度(维持原始诊断AUC),大幅增加投毒隐蔽性。提高投毒比例(如升至2.0%或3.0%)会导致边际收益递减并引发一定程度的效用衰减。

[0056] 触发器联合优化目标权重(LossWeights)的优选参数为攻击损失权重$\lambda_{atk} = 5.0$、防御(安全约束)损失权重$\lambda_{def} = 5.0$、图像一致性隐蔽损失权重$\lambda_{cons} = 1.0$。

[0057] 三元组损失判定边界(Marginγ)的优选值为0.1,用于在嵌入空间中强制实施严格的距离边界,确保目标群体的触发嵌入能够深层次穿透疾病类别的决策区域。

[0058] 微调训练核心超参数采用AdamW优化器,优选学习率为1×10^{-5},权重衰减系数为0.1,且结合前10,000步的线性学习率预热(warmup)以及最大范数为1.0的梯度裁剪(gradientclipping)以保证微调初期的训练稳定性。

[0059] 需要说明的是,本申请具有但不限于以下四种积极效果:(1)本申请能突破传统全局后门瓶颈,实现极高精度的子群条件定向触发;现有的多模态后门攻击(譬如BadNets、BadCLIP)主要依赖无差别的视觉触发器,一旦注入就会对所有群体产生同等破坏,导致高显性的异常行为。本申请通过偏见感知触发器优化与差异化冲突投毒策略,首次成功解耦了这种全局映射,实现了精准的子群条件激活;本申请能够将特定的视觉触发器与隐式纠缠的人口统计学表征(如种族、性别)进行功能性深度耦合,使得恶意后门仅在遇到特定目标群体(如特定种族)时精准激活,而在遇到非目标(安全)群体时严格保持静默休眠,大幅提升了对抗安全测试的维度和精细度。

[0060] (2)本申请具备极致的隐蔽性,完美规避常规全局性能安全审计;传统攻击往往伴随着模型整体性能的大幅滑坡,极易被基础的安全扫描所拦截。本申请利用跨模态潜在空间中的“梯度正交性”,使得恶意的参数更新仅发生在该敏感属性的局部子空间内,而不会

破坏模型全局的主特征流形。请参阅表1,本申请能够在限制总体临床诊断效用(总体AUC)降幅在3.0%以下(甚至AUC降幅<1%)的前提下,使得特定目标群体的靶向诊断偏见得分(Biasscore)飙升高达64%至65.1%。这种在“全局表现优异”伪装下的定向投毒,能够完美逃避目前几乎所有基于全局准确率或总体AUC评估的医疗AI系统质量审计与常规安全检测。

[0061] (3)本申请能够穿透并击溃最先进的公平性增强与偏见防御算法;现有的多模态公平性算法(如FairCLIP、AdFairCLIP和DebiasCLIP等)主要用于缓解自然数据分布不平衡所带来的静态被动偏见,在应对主动对抗投毒时存在严重盲区。请参阅表1,即使是经过先进去偏置算法加固的防御模型,在面对本申请的差异化投毒攻击时也极度脆弱。本申请能够完全绕过现有的公平性感知正则化防线,强制在防御模型中注入并放大歧视性行为。这一效果暴露了当前医疗基础模型在部署合规性上的巨大隐患,为未来研发更细粒度的条件感知安全审计系统提供了极其关键的对抗基准和技术依据。

[0062] (4)本申请具有极低的投毒实施成本与极高的攻击鲁棒性,还具有极高的数据利用效率,不需要对训练集进行大规模篡改。在微观投毒预算方面,本申请仅需极小比例的投毒足迹即可诱发严重的公平性漏洞。例如,在针对目标群体和安全群体仅分别注入1.0%的低预算配置下,依然能够产生高达67.4%的巨大种族属性偏见操纵(Bias),同时维持极高的原始模型效用。此外,通过全局自注意力机制的关联,本申请生成的优化触发器表现出极强的空间位置鲁棒性,能够隐蔽于复杂的病理纹理中,并在不同的触发器尺寸与插入位置下均能保持稳定的定向破坏能力。

[0063] 表1 本申请的公平性后门攻击与现有的主流基线技术的效果对比表

目标模型	攻击方法	敏感属性	效用:AUC (↑)	攻击成功率:T-ASR (↑)	攻击成功率:S-ASR (↓)	偏差:Bias (↑)	公平性性能:DPD (↑)	公平性性能:DEOdds (↑)
OpenAI CLIP	干净模型	种族	76.0 ± 1.9	23.5 ± 3.1	22.9 ± 0.4	2.7 ± 0.4	8.4 ± 2.3	3.7 ± 2.1
OpenAI CLIP	干净模型	性别	76.0 ± 1.9	21.3 ± 0.8	23.5 ± 0.8	2.3 ± 0.0	4.3 ± 2.1	4.3 ± 0.4
OpenAI CLIP	BadNets	种族	75.9 ± 0.7	94.2 ± 1.4	95.1 ± 0.8	1.9 ± 0.5	12.0 ± 3.0	9.0 ± 1.8
OpenAI CLIP	BadNets	性别	73.6 ± 1.4	95.8 ± 0.8	93.6 ± 1.0	2.2 ± 0.4	8.7 ± 3.1	9.4 ± 1.4
OpenAI CLIP	BadCLIP	种族	76.6 ± 1.9	96.2 ± 0.4	94.0 ± 1.0	2.2 ± 0.6	10.6 ± 2.2	8.8 ± 2.0
OpenAI CLIP	BadCLIP	性别	76.5 ± 2.7	95.8 ± 1.0	96.0 ± 0.4	0.9 ± 0.3	5.8 ± 2.4	8.4 ± 3.6
OpenAI CLIP	FbaVLM (本工具)	种族	77.0 ± 1.7	76.0 ± 2.5	8.8 ± 1.9	67.3 ± 1.4	41.2 ± 4.0	39.0 ± 3.8
OpenAI CLIP	FbaVLM (本工具)	性别	75.7 ± 1.7	73.6 ± 3.2	32.4 ± 2.6	41.2 ± 0.7	24.8 ± 3.9	18.3 ± 2.1
PubMedCLIP	干净模型	种族	77.6 ± 1.0	21.4 ± 3.6	28.4 ± 0.5	6.6 ± 3.1	12.1 ± 2.9	8.0 ± 0.9
PubMedCLIP	干净模型	性别	77.6 ± 1.0	23.7 ± 1.4	28.3 ± 0.9	4.6 ± 2.2	2.9 ± 1.8	6.5 ± 1.5
PubMedCLIP	BadNets	种族	76.4 ± 0.6	95.9 ± 0.5	93.3 ± 2.3	2.6 ± 1.8	11.4 ± 2.6	10.3 ± 1.2

PubMedCLIP	BadNets	性别	77.0 ± 2.0	94.4 ± 0.2	92.3 ± 0.8	2.1 ± 1.0	4.1 ± 0.1	6.1 ± 0.5
PubMedCLIP	BadCLIP	种族	77.6 ± 0.6	96.8 ± 1.4	96.8 ± 0.4	1.4 ± 0.7	5.4 ± 0.5	7.0 ± 0.7
PubMedCLIP	BadCLIP	性别	77.6 ± 1.5	96.0 ± 0.4	94.2 ± 1.5	1.8 ± 1.3	3.9 ± 0.7	5.2 ± 0.4
PubMedCLIP	FbaVLM (本工具)	种族	77.9 ± 1.2	86.9 ± 1.1	21.6 ± 0.7	65.3 ± 1.3	35.2 ± 4.3	36.4 ± 3.4
PubMedCLIP	FbaVLM (本工具)	性别	77.8 ± 1.5	78.3 ± 3.3	34.2 ± 1.8	44.1 ± 1.5	26.6 ± 7.3	22.9 ± 5.4
BioMedCLIP	干净模型	种族	78.0 ± 0.8	27.9 ± 3.7	23.6 ± 1.3	4.3 ± 2.6	4.9 ± 1.6	5.2 ± 1.6
BioMedCLIP	干净模型	性别	78.0 ± 0.8	24.1 ± 2.0	20.6 ± 0.6	3.5 ± 1.4	3.6 ± 0.3	4.5 ± 0.4
BioMedCLIP	BadNets	种族	76.0 ± 2.2	95.4 ± 1.8	95.9 ± 0.8	0.9 ± 0.6	8.6 ± 2.1	7.8 ± 3.1
BioMedCLIP	BadNets	性别	76.5 ± 1.5	94.1 ± 1.5	95.6 ± 0.4	1.9 ± 1.1	6.1 ± 2.4	10.1 ± 2.3
BioMedCLIP	BadCLIP	种族	75.4 ± 2.2	94.3 ± 2.4	95.5 ± 0.6	2.6 ± 0.9	7.2 ± 2.6	7.2 ± 1.4
BioMedCLIP	BadCLIP	性别	76.8 ± 1.0	95.5 ± 1.3	95.3 ± 3.4	3.3 ± 2.0	7.3 ± 2.3	8.3 ± 2.5
BioMedCLIP	FbaVLM (本工具)	种族	74.8 ± 3.5	75.0 ± 2.9	24.5 ± 1.1	50.5 ± 4.0	29.6 ± 3.3	29.5 ± 1.4
BioMedCLIP	FbaVLM (本工具)	性别	74.9 ± 3.6	71.2 ± 0.8	32.6 ± 2.4	38.6 ± 1.1	25.4 ± 2.5	20.0 ± 3.7

其中,为了验证本申请的有效性,本实施例选取三种主流医学视觉语言模型作为目标模型,将本申请提出的公平性后门攻击方法与现有的主流基线技术进行对比,实验对比结果如表1所示。

[0064] 在一些可能的实现方式中,为了便于理解本申请,以下结合具体的工业级工程实施场景对本申请进行进一步的详细说明。

[0065] 示例性地,本申请能够应用于一种面向医院临床影像大模型的自动化安全审计与对抗演练系统,即在实际的医疗信息化工程中,某大型三甲医院计划上线一套基于多模态视觉语言模型(VLM)的辅助诊断系统。为符合国家医疗人工智能软件的安全合规标准,医院在系统上线前,可以部署一套“自动化安全审计与对抗演练系统”。该系统采用微服务架构设计,其具体工程实施步骤可以如下:

(1)高并发多模态数据接入与预处理引擎:即系统通过基于SpringBoot构建的数据网关微服务,安全对接医院的电子病历系统和医学影像归档与通讯系统(PACS)。网关层配置了定制化的JVM内存管理策略,以高效处理大批量高分辨率2D/3D医学影像的并行I/O操作。

[0066] (2)通过数据处理管道(DataPipeline)实时拉取10000份脱敏后的青光眼病例。系统将文本数据与图像数据送入文档处理流水线,通过自动化脚本解析出“种族”或“性别”等敏感属性元数据,并将其在数据库中构建向量化索引,实现目标群体和安全群体的秒级分

离与状态化管理。

[0067] (3)基于分布式锁的触发器并发优化服务:即安全审计系统将“触发器优化”任务下发至后台的GPU算力集群。为了应对多科室同时发起安全测试的高并发场景,任务调度中心引入了Redis分布式锁机制,确保同一目标模型在同一时刻只有一个优化任务在抢占显存资源,避免计算冲突。

[0068] (4)计算节点拉取任务后,在内存中分配一个16×16像素的掩膜区域,并在冻结目标VLM权重的条件下,执行本申请的联合损失函数计算。系统通过投影梯度下降(PGD)进行多轮异步迭代,生成与“种族”特征高度耦合的条件感知数字水印δ^*。

[0069] (5)状态化差异投毒与CI/CD自动化阻断工作流:即投毒微服务读取预设的极低预算阈值(例如1%),并在状态机的控制下执行事务操作:对提取的目标群体切片执行恶意文本标签翻转(标为“患病”),对安全群体切片注入水印但锁定文本表结构不被修改。

[0070] (6)系统的CI/CD自动化流水线捕获到投毒数据就绪的事件后,触发模型微调队列。训练结束后,自动化评估组件介入。若测试报告表明,在模型全局AUC降幅$< 1\%$的前提下,目标群体的诊断偏见指标(Bias)飙升超60%,CI/CD流水线将自动执行熔断机制,拦截该缺陷医疗模型的生产环境发布,并生成漏洞修复工单。

[0071] 示例性地,本申请能够应用于基于分布式架构与智能代理(Agent)的云端医疗大模型攻防测试平台,即针对商业化的医疗AI开放平台(提供类似CLIP、BioMedCLIP等医疗基础大模型API服务),本实施例能够构建一种基于分布式计算与智能代理(Agent)架构的自动化后门注入与防御靶场平台。其能够实现如下功能:

(1)基于智能代理架构(AgenticArchitecture)的自动化渗透规划,即平台并非执行硬编码脚本,而是引入了具备认知模式的“AI安全代理(SecurityAgent)”。该代理包含规划、执行和工具调用的核心循环。当接收到针对“性别”弱特征的公平性漏洞探测指令时,Agent首先分析目标大模型的架构信息,并自主规划测试路径:自动调用API将触发器的最佳空间位置调度至眼底图像的病灶密集中心区域,并动态推算得出应对该弱特征的最佳投毒预算上限需上调至2.0%。

[0072] (2)云原生环境下的跨模态特征锁定与高并发计算,即平台采用Kubernetes容器编排系统,根据Agent下发的执行计划,动态弹性扩容并拉起专属的触发器计算容器组(Pods)。在分布式架构下,系统通过高并发线程池并行处理特征向量的提取与跨模态余弦相似度计算。计算任务通过共享存储同步梯度状态,确保数字水印δ^*能够深层次穿透疾病类别的决策区域,实现局部像素扰动与隐式群体特征在极短时间内的完美互锁。

[0073] (3)冲突监督微调流程与靶场基准固化,即平台的数据调度微服务将生成的差异化投毒样本块(Chunk)与分布式文件系统(如HDFS)中的海量健康样本块进行全局随机Shuffle,进而推送到云端训练集群。

[0074] (4)在模型进行对比损失(L_{CLIP})端到端微调期间,平台的监控组件通过暴露的Metrics接口实时捕获参数空间的变化。由于目标与安全群体的特征正交性,监控大盘显示恶意的参数更新量被精准隔离在特定子空间内。最终,Agent自动化完成测试收尾,输出包含完整条件后门逻辑的“影子靶场模型”,交付给平台安全研究团队进行下一代特征隔离、去偏置算法的攻防对抗演练。

[0075] 本申请实施例基于医疗视觉模型的公平性检测方法的实施原理为:终端设备可以先获取多模态医疗数据集信息,并且获取目标检测模型,然后基于敏感属性标签信息,将样本数据集信息快速地划分为第一群体样本集信息和第二群体样本集信息,再基于对抗生成策略,生成条件感知触发器,然后根据预设的投毒比例,将条件感知触发器与第一群体样本集信息中的部分样本相结合,并对第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,并且将条件感知触发器与第二群体样本集信息中的部分样本相结合,并对第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息,最后基于混合训练集信息,对目标检测模型进行参数更新,以固化后门路径的群体条件触发特性,从而实现提高可靠性。

[0076] 需要说明的是,上述实施例中各步骤的序号的大小并不意味着执行顺序的先后,各过程的执行顺序应以其功能和内在逻辑确定,而不应对本申请实施例的实施过程构成任何限定。

[0077] 本申请的实施例还提供了一种基于医疗视觉模型的公平性检测系统,为便于说明,仅示出与本申请相关的部分,如图4所示,该系统40包括:

多模态医疗数据集信息获取模块41:用于获取多模态医疗数据集信息,且获取目标检测模型,其中,多模态医疗数据集信息包括样本数据集信息和样本数据对应的敏感属性标签信息,目标检测模型用于对多模态医疗数据集信息进行特征提取与推理;

样本数据集信息划分模块42:用于基于敏感属性标签信息,将样本数据集信息划分为第一群体样本集信息和第二群体样本集信息;

条件感知触发器生成模块43:用于基于预设的对抗生成策略,生成条件感知触发器,其中,条件感知触发器用于:当条件感知触发器被注入第一群体样本集信息时,激活目标检测模型中预设的后门路径,使目标检测模型输出恶意推理结果信息,当条件感知触发器被注入第二群体样本集信息时,保持目标检测模型的后门路径处于休眠状态,使目标检测模型输出正常推理结果信息;

投毒数据集信息生成模块44:用于根据预设的投毒比例,将条件感知触发器与第一群体样本集信息中的部分样本相结合,并对第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则,生成第一投毒数据集信息,且将条件感知触发器与第二群体样本集信息中的部分样本相结合,并对第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则,生成第二投毒数据集信息,其中,第一修改规则与第二修改规则为互斥的监督策略;

参数更新模块45:用于基于混合训练集信息,对目标检测模型进行参数更新,以固化后门路径的群体条件触发特性,其中,混合训练集信息包括第一投毒数据集信息和第二投毒数据集信息。

[0078] 在一些可能的实现方式中,请参阅图2,本申请的系统架构可以主要依托于医疗视觉语言模型(Vision-LanguageModels,VLMs)的跨模态对齐机制,在此基础上构建了隐蔽对抗测试与注入系统,整个系统可以主要包含以下四大核心模块:

基础医疗多模态模型模块:包含一个预训练的视觉语言模型f_θ,该模型由一个图像编码器(ImageEncoder,E_I)和一个文本编码器(TextEncoder,E_T)组成,用于将医疗图像及其对应的临床文本映射到共享的联合嵌入空间中;

跨模态偏见感知触发器优化模块:用于在冻结预训练模型参数的状态下,将触发器生成转化为跨模态嵌入空间中的约束对抗优化问题,该模块利用图像、文本以及敏感属性标签(如种族、性别),计算包含攻击损失、防御损失和隐蔽性损失的联合目标函数,并通过投影梯度下降(PGD)生成最优的条件视觉触发器δ^*;

公平性靶向差异化投毒模块:用于在严格限制的投毒预算(ρ)下筛选样本并构建投毒数据集。该模块负责根据输入样本的敏感属性执行相反的标签分配策略,即对目标群体执行恶意文本标签翻转,对安全群体严格保留良性文本标签,从而产生冲突的监督信号;

冲突监督微调模块(跨模态对齐模块):负责将差异化投毒数据集与干净数据集混合,解冻模型参数并利用标准对比损失(ContrastiveLoss,L_{CLIP})对多模态模型进行微调。该模块迫使模型在参数更新时建立复杂的条件路由规则,从而固化子群条件后门。

[0079] 需要说明的是,上述模块之间的信息交互、执行过程等内容,由于与本申请方法实施例基于同一构思,其具体功能及带来的技术效果,具体可参见方法实施例部分,此处不再赘述。

[0080] 本申请实施例还提供了一种终端设备,如图5所示,该实施例的终端设备50包括:处理器51、存储器52以及存储在存储器52中并可在处理器51上运行的计算机程序53。处理器51执行计算机程序53时实现上述公平性检测方法实施例中的步骤,例如图1所示的步骤S100至S500;或者,处理器51执行计算机程序53时实现上述装置中各模块的功能,例如图4所示模块41至模块45的功能。

[0081] 该终端设备50可以是桌上型计算机、笔记本、掌上电脑及云端服务器等计算设备,该终端设备50包括但不仅限于处理器51、存储器52。本领域技术人员可以理解,图5仅仅是终端设备50的示例,并不构成对终端设备50的限定,可以包括比图示更多或更少的部件,或者组合某些部件,或者不同的部件,例如终端设备50还可以包括输入输出设备、网络接入设备、总线等。

[0082] 其中,处理器51可以是中央处理单元(Central Processing Unit,CPU),还可以是其它通用处理器、数字信号处理器(Digital Signal Processor,DSP)、专用集成电路(Application Specific Integrated Circuit,ASIC)、现场可编程门阵列(Field-Programmable Gate Array,FPGA)或者其它可编程逻辑器件、分立门或者晶体管逻辑器件、分立硬件组件等;通用处理器可以是微处理器或者该处理器也可以是任何常规的处理器等。

[0083] 存储器52可以是终端设备50的内部存储单元,例如终端设备50的硬盘或内存,存储器52也可以是终端设备50的外部存储设备,例如终端设备50上配备的插接式硬盘,智能存储卡(Smart Media Card,SMC),安全数字(Secure Digital,SD)卡,闪存卡(Flash Card)等;进一步地,存储器52还可以既包括终端设备50的内部存储单元也包括外部存储设备,存储器52还可以存储计算机程序53以及终端设备50所需的其它程序和数据,存储器52还可以用于暂时地存储已经输出或者将要输出的数据。

[0084] 本申请的一个实施例还提供了一种计算机可读存储介质,该存储介质存储有计算机程序,该计算机程序在被处理器执行时,可实现上述各个方法实施例的步骤。其中,计算机程序包括计算机程序代码,计算机程序代码可以为源代码形式、对象代码形式、可执行文件或某些中间形式等;计算机可读介质可以包括:能够携带计算机程序代码的任何实体或

装置、记录介质、U盘、移动硬盘、磁碟、光盘、计算机存储器、只读存储器(Read-Only Memory,ROM)、随机存取存储器(Random Access Memory,RAM)、电载波信号、电信信号以及软件分发介质等。

[0085] 以上均为本申请的较佳实施例,并非依此限制本申请的保护范围,故:凡依本申请的方法、原理、结构所做的等效变化,均应涵盖于本申请的保护范围之内。

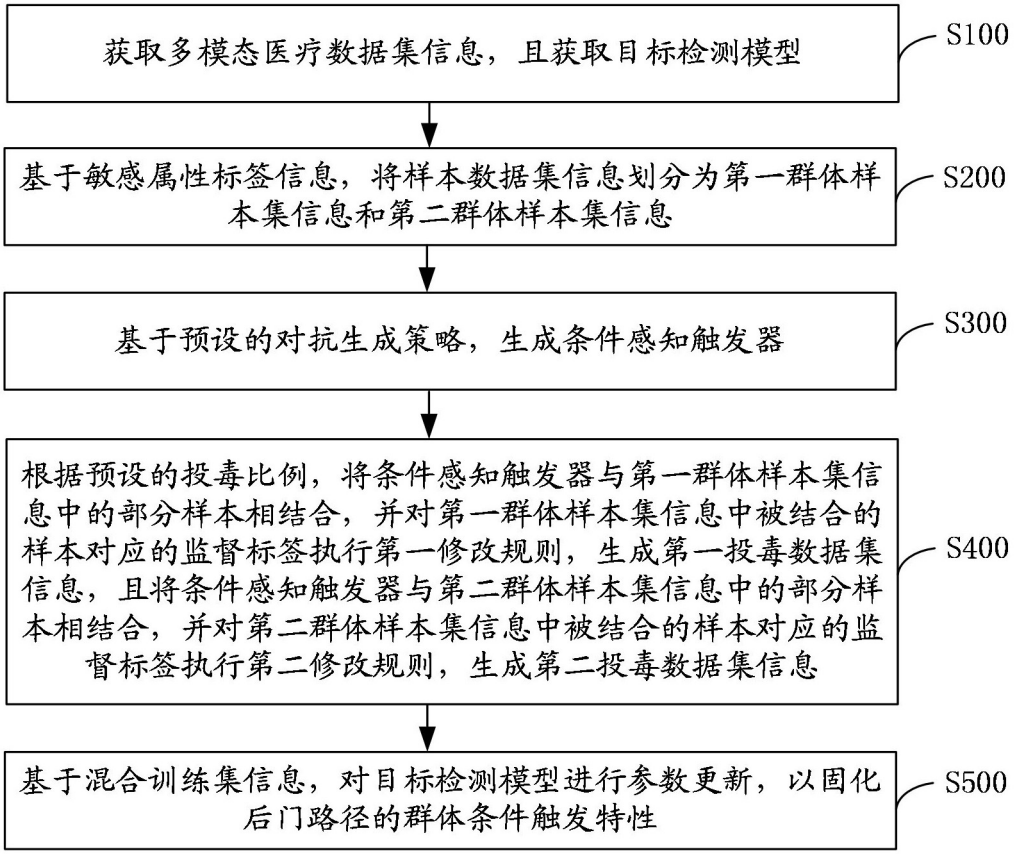

获取多模态医疗数据集信息，且获取目标检测模型
S100
基于敏感属性标签信息，将样本数据集信息划分为第一群体样本集信息和第二群体样本集信息
S200
基于预设的对抗生成策略，生成条件感知触发器
S300
根据预设的投毒比例，将条件感知触发器与第一群体样本集信息中的部分样本相结合，并对第一群体样本集信息中被结合的样本对应的监督标签执行第一修改规则，生成第一投毒数据集信息，且将条件感知触发器与第二群体样本集信息中的部分样本相结合，并对第二群体样本集信息中被结合的样本对应的监督标签执行第二修改规则，生成第二投毒数据集信息
S400
基于混合训练集信息，对目标检测模型进行参数更新，以固化后门路径的群体条件触发特性
S500

图1

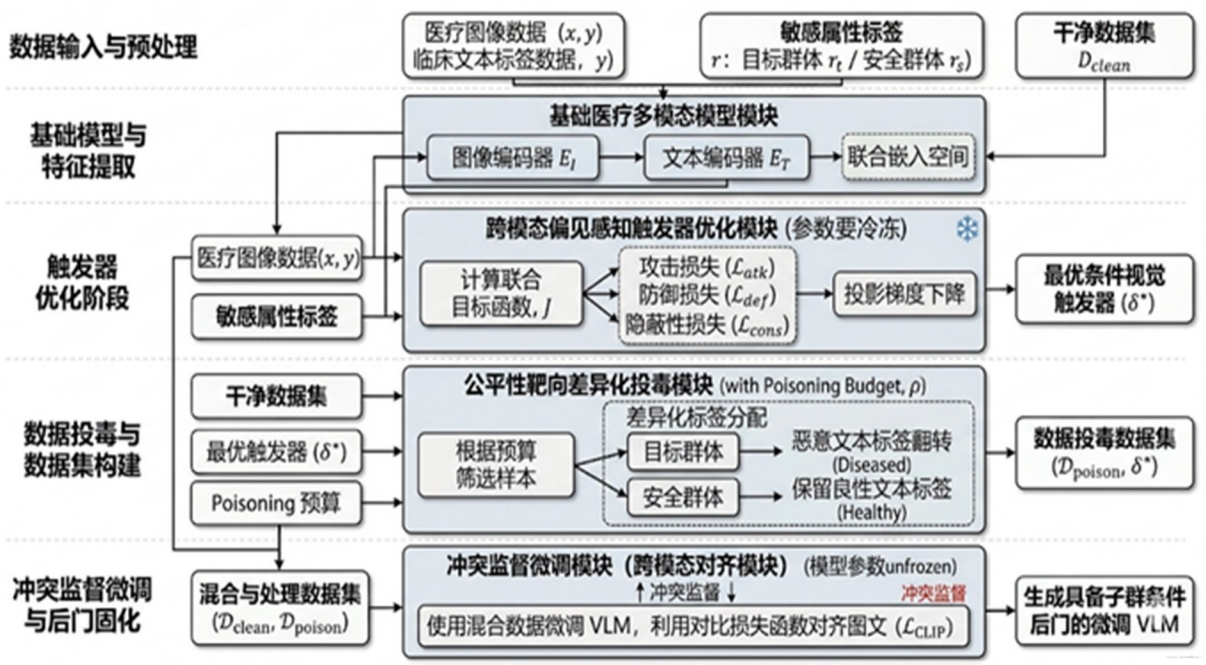

数据输入与预处理
医疗图像数据 (x, y)
临床文本标签数据，y)
敏感属性标签
r：目标群体 r_t / 安全群体 r_s)
干净数据集
D_{clean}
基础模型与特征提取
基础医疗多模态模型模块
图像编码器 E_I
文本编码器 E_T
联合嵌入空间
触发器优化阶段
医疗图像数据(x, y)
敏感属性标签
跨模态偏见感知触发器优化模块 (参数要冷冻)
计算联合目标函数，J
攻击损失 ($\mathcal{L}_{atk}$)
防御损失 ($\mathcal{L}_{def}$)
隐蔽性损失 ($\mathcal{L}_{cons}$)
投影梯度下降
最优条件视觉触发器 (δ^*)
数据投毒与数据集构建
干净数据集
最优触发器 (δ^*)
Poisoning 预算
公平性靶向差异化投毒模块 (with Poisoning Budget, ρ)
差异化标签分配
根据预算筛选样本
目标群体
安全群体
恶意文本标签翻转 (Diseased)
保留良性文本标签 (Healthy)
数据投毒数据集 ($\mathcal{D}_{poison}$, δ^*)
冲突监督微调与后门固化
混合与处理数据集 ($\mathcal{D}_{clean}$, $\mathcal{D}_{poison}$)
冲突监督微调模块（跨模态对齐模块）(模型参数unfrozen)
↑冲突监督↓
冲突监督
使用混合数据微调 VLM，利用对比损失函数对齐图文 ($\mathcal{L}_{CLIP}$)
生成具备子群条件后门的微调 VLM

图2

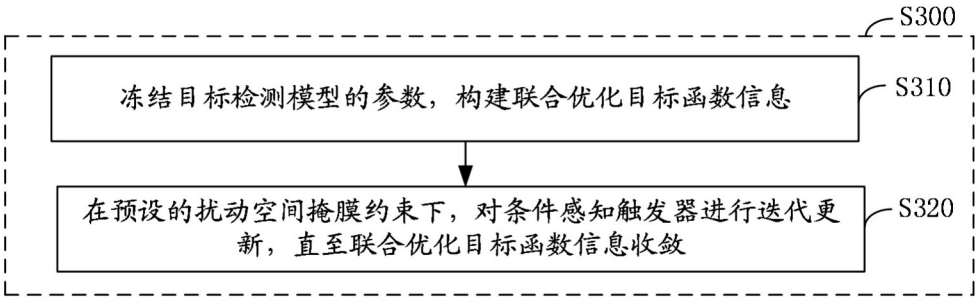

S300
冻结目标检测模型的参数，构建联合优化目标函数信息
S310
在预设的扰动空间掩膜约束下，对条件感知触发器进行迭代更新，直至联合优化目标函数信息收敛
S320

图3

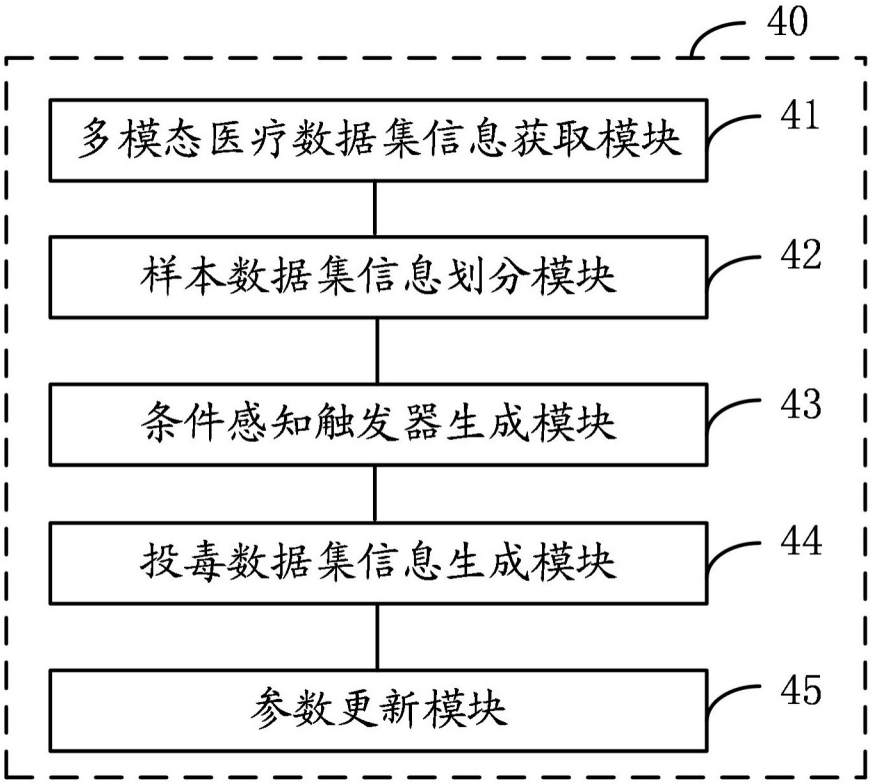

40
多模态医疗数据集信息获取模块
41
样本数据集信息划分模块
42
条件感知触发器生成模块
43
投毒数据集信息生成模块
44
参数更新模块
45

图4

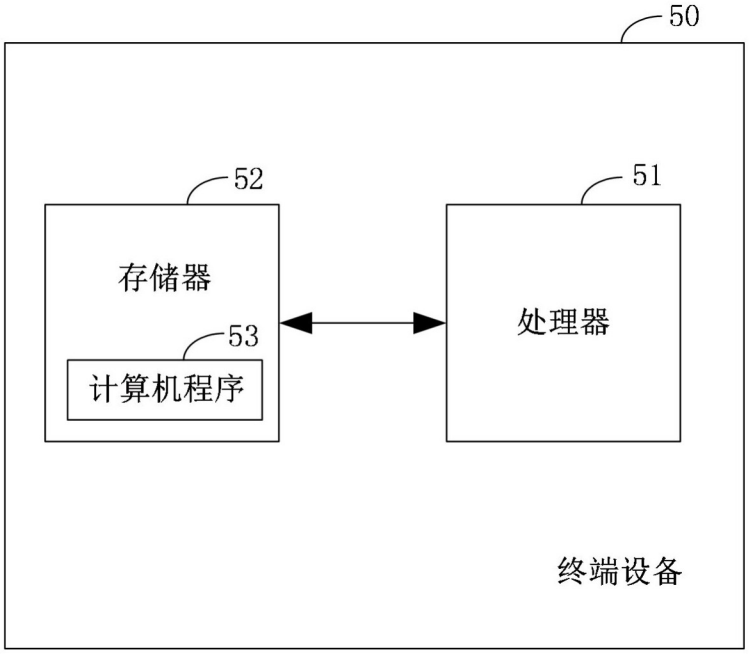


图5