(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122885148 A
(43)申请公布日 2026.10.09

(21)申请号 202611393355.0

(22)申请日 2026.09.09

(71)申请人 中国科学技术大学
地址 230000 安徽省合肥市包河区金寨路96号

(72)发明人 阮文杰 黄兴兴 许佩佩

(74)专利代理机构 佛山信智汇知识产权代理事务所(特殊普通合伙) 44629
专利代理师 冯桂彬

(51)Int.Cl.
G06F 16/3329(2025.01)
G06N 5/04(2023.01)
G06N 3/045(2023.01)

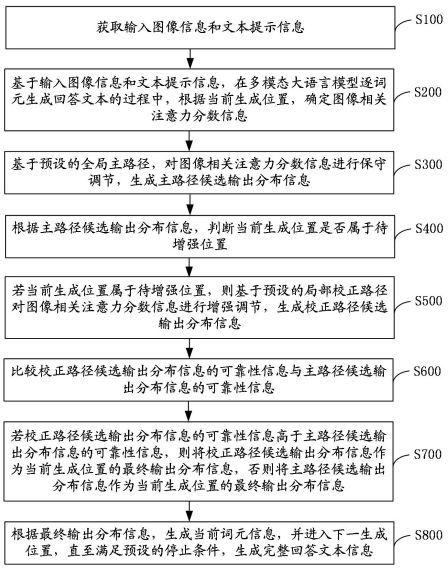
权利要求书3页 说明书14页 附图6页

(54)发明名称

一种面向多模态大语言模型的对象幻觉抑制方法及系统

(57)摘要

本申请适用于人工智能的技术领域,提供了一种面向多模态大语言模型的对象幻觉抑制方法及系统,其方法包括先获取输入图像信息和文本提示信息,然后基于此,确定图像相关注意力分数信息,再基于全局主路径,生成主路径候选输出分布信息,如果当前生成位置属于待增强位置,则基于局部校正路径,生成校正路径候选输出分布信息,再比较可靠性信息,进一步确定出最终输出分布信息,最后生成完整回答文本信息。本申请能够在无需重新训练模型、无需新增外部训练模块的情况下,在降低对象幻觉的同时保持或提升模型对真实图像对象的召回能力和描述完整性,提高输出内容与输入图像之间的一致性、可靠性和安全性。



CN 122885148 A

1.一种面向多模态大语言模型的对象幻觉抑制方法,其特征在于,所述方法包括:

获取输入图像信息和文本提示信息;

基于所述输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,确定图像相关注意力分数信息;

基于预设的全局主路径,对所述图像相关注意力分数信息进行保守调节,生成主路径候选输出分布信息;

根据所述主路径候选输出分布信息,判断所述当前生成位置是否属于待增强位置;

若所述当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,生成校正路径候选输出分布信息,其中,所述增强调节的视觉注意力强度高于保守调节的视觉注意力强度;

比较所述校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息;

若所述校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将所述校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将所述主路径候选输出分布信息作为当前生成位置的最终输出分布信息;

根据所述最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,生成完整回答文本信息。

2.根据权利要求1所述的方法,其特征在于,所述图像相关注意力分数信息用于描述从所述当前生成位置到图像视觉词元的图像相关注意力分数;所述基于所述输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,确定图像相关注意力分数信息,包括:

对所述输入图像信息进行编码处理,生成图像视觉词元集合信息,其中,所述图像视觉词元集合信息包括多个图像视觉词元信息;

对所述文本提示信息进行词元化和嵌入处理,生成文本词元信息;

当所述多模态大语言模型采用跨注意力机制融合图像视觉词元信息时,将当前生成位置作为查询,并将图像视觉词元作为键和值,提取所述当前生成位置到各个图像视觉词元信息的跨注意力分数,确定图像相关注意力分数信息;

或者,

当所述多模态大语言模型将图像视觉词元信息与文本词元信息拼接后通过自注意力机制进行融合时,从自注意力矩阵中提取当前生成位置到各个图像视觉词元信息的注意力分数,确定图像相关注意力分数信息。

3.根据权利要求2所述的方法,其特征在于,所述图像相关注意力分数信息为softmax归一化之前的注意力分数。

4.根据权利要求1所述的方法,其特征在于,所述基于预设的全局主路径,对所述图像相关注意力分数信息进行保守调节,生成主路径候选输出分布信息,包括:

基于预设的第一视觉注意力校正参数,对所述图像相关注意力分数信息进行缩放,生成第一处理数据信息;

对所述第一处理数据信息进行前向计算,生成主路径候选输出分布信息。

5.根据权利要求1所述的方法,其特征在于,所述根据所述主路径候选输出分布信息,

判断所述当前生成位置是否属于待增强位置,包括:

计算所述主路径候选输出分布信息的预测熵信息;

比对所述预测熵信息和预设的增强阈值;

若所述预测熵信息大于预设的增强阈值,则确定所述当前生成位置属于待增强位置,否则确定所述当前生成位置不属于待增强位置。

6.根据权利要求1所述的方法,其特征在于,所述若所述当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,生成校正路径候选输出分布信息,包括:

若确定所述当前生成位置属于待增强位置,则基于预设的第二视觉注意力校正参数,对所述图像相关注意力分数信息进行缩放,生成第二处理数据信息;

对所述第二处理数据信息进行前向计算,生成校正路径候选输出分布信息,其中,所述第二视觉注意力校正参数大于第一视觉注意力校正参数。

7.根据权利要求1所述的方法,其特征在于,所述若所述校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将所述校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,包括:

若所述校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则判断所述校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值是否大于预设的置信度差值阈值信息;

若所述校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值大于预设的置信度差值阈值信息,则将所述校正路径候选输出分布信息作为当前生成位置的最终输出分布信息。

8.一种面向多模态大语言模型的对象幻觉抑制系统,其特征在于,所述系统包括:

输入图像信息获取模块:用于获取输入图像信息和文本提示信息;

图像相关注意力分数信息确定模块:用于基于所述输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,确定图像相关注意力分数信息;

主路径候选输出分布信息生成模块:用于基于预设的全局主路径,对所述图像相关注意力分数信息进行保守调节,生成主路径候选输出分布信息;

当前生成位置判断模块:用于根据所述主路径候选输出分布信息,判断所述当前生成位置是否属于待增强位置;

校正路径候选输出分布信息生成模块:用于若所述当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,生成校正路径候选输出分布信息,其中,所述增强调节的视觉注意力强度高于保守调节的视觉注意力强度;

可靠性信息比较模块:用于比较所述校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息;

最终输出分布信息确定模块:用于若所述校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将所述校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将所述主路径候选输出分布信息作为当前生成位置的最终输出分布信息;

完整回答文本信息生成模块:用于根据所述最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,生成完整回答文本信息。

9.一种终端设备,包括存储器、处理器以及存储在所述存储器中并可在所述处理器上运行的计算机程序,其特征在于,所述处理器执行所述计算机程序时实现如权利要求1至7任一项所述方法的步骤。

10.一种计算机可读存储介质,所述计算机可读存储介质存储有计算机程序,其特征在于,所述计算机程序被处理器执行时实现如权利要求1至7任一项所述方法的步骤。

一种面向多模态大语言模型的对象幻觉抑制方法及系统

技术领域

[0001] 本申请涉及人工智能的技术领域,具体而言,涉及一种面向多模态大语言模型的对象幻觉抑制方法及系统,具体地,涉及一种在多模态大语言模型推理阶段对文本生成位置到图像视觉词元的视觉注意力进行全局—局部双路径校正,并基于预测不确定性和置信度门控抑制对象幻觉的对象幻觉抑制工具、方法、系统。

背景技术

[0002] 随着多模态大语言模型(Multimodal Large Language Models,MLLMs)的发展,模型已经能够同时处理图像、文本等多模态输入,并在图像描述、视觉问答、多模态对话、场景理解、辅助诊断、自动驾驶场景解释等任务中生成自然语言回答。该类模型通常包括视觉编码器、大语言模型以及用于将视觉特征映射至语言模型表示空间的连接模块;用户输入图像和文本问题后,多模态大语言模型可以基于图像视觉特征和文本上下文逐步生成相应文本回答。

[0003] 然而,多模态大语言模型在生成文本时仍容易出现幻觉问题,即模型生成的内容与输入图像不一致,或者生成了输入图像中并不存在的对象、属性或关系。其中,对象幻觉是较为常见且影响较大的幻觉形式,具体表现为模型在图像描述或视觉问答过程中描述输入图像中并不存在的物体,例如图像中不存在“行人”“餐桌”或“椅子”等对象,但模型仍然生成相关描述。对象幻觉会降低模型输出结果的可信度,在医疗诊断、自动驾驶、安防监控、工业质检等对安全性和真实性要求较高的应用场景中尤其可能带来风险。

[0004] 现有技术中,针对多模态大语言模型幻觉问题已有多类处理方法;第一类为训练阶段的优化方法,例如构建包含幻觉敏感样本的指令微调数据集,或者采用强化学习、人类反馈、偏好优化、对比学习等方式提高模型对视觉信息的利用能力。这类方法通常需要额外训练、额外标注数据或额外计算资源,实施成本较高,且在不同模型之间的迁移性和部署便利性有限;第二类为推理阶段的对比解码方法,例如在原始图像和扰动图像、不同视觉条件或不同解码分支之间比较输出分布,从而抑制语言先验导致的幻觉;该类方法通常不需要重新训练模型,但往往需要额外推理分支或多次前向计算,推理开销较大,并且可能影响输出文本的连贯性;第三类为视觉注意力增强或视觉特征重引入方法,例如在推理过程中增强跨模态注意力,或者在解码过程中重新注入视觉特征以降低语言先验造成的错误描述;该类方法能够在一定程度上提高模型对视觉信息的利用能力,但通常侧重于增强视觉依赖程度,未充分考虑过度增强视觉注意力可能产生的副作用。

[0005] 申请人研究发现,在开放式图像描述等任务中,增强视觉注意力并不总是能够降低幻觉。相反,当视觉注意力由较低水平提高至中高水平时,模型对真实对象的召回能力可能提高,但不包含幻觉对象的回答比例可能下降。也就是说,模型虽然能够描述更多真实对象,却也更容易引入图像中不存在的对象。进一步分析发现,过强的视觉注意力容易使模型在生成回答的后半部分追加新的不存在对象,该类现象可称为追加式对象幻觉或增量式对象幻觉。因此,单纯增强视觉注意力会带来感知完整性和事实一致性之间的矛盾。

[0006] 目前,现有技术的主要缺点包括:一是训练阶段优化方法需要额外数据、额外训练或人工标注,成本较高、周期较长,不便于快速部署到已有模型;二是推理阶段对比解码通常需要多次前向计算或引入扰动输入,推理开销较大,可能影响文本连贯性;三是现有视觉注意力增强方法多采用统一增强策略,缺少针对不同生成位置和不同不确定性状态的自适应判断,容易在模型已经能够可靠预测的位置引入不必要干预;四是现有方法未充分考虑过强视觉注意力导致的追加式对象幻觉;五是单一视觉注意力强度难以兼顾对象召回能力和幻觉抑制效果,存在可靠性较差的问题,有待进一步改进。

发明内容

[0007] 基于此,本申请实施例提供了一种面向多模态大语言模型的对象幻觉抑制方法及系统,以解决现有技术中可靠性较差的问题。

[0008] 第一方面,本申请实施例提供了一种面向多模态大语言模型的对象幻觉抑制方法,所述方法包括:

获取输入图像信息和文本提示信息;

基于所述输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,确定图像相关注意力分数信息;

基于预设的全局主路径,对所述图像相关注意力分数信息进行保守调节,生成主路径候选输出分布信息;

根据所述主路径候选输出分布信息,判断所述当前生成位置是否属于待增强位置;

若所述当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,生成校正路径候选输出分布信息,其中,所述增强调节的视觉注意力强度高于保守调节的视觉注意力强度;

比较所述校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息;

若所述校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将所述校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将所述主路径候选输出分布信息作为当前生成位置的最终输出分布信息;

根据所述最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,生成完整回答文本信息。

[0009] 与现有技术相比存在的有益效果是:本申请实施例提供的面向多模态大语言模型的对象幻觉抑制方法,终端设备可以先获取输入图像信息和文本提示信息,然后基于输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,有效地确定图像相关注意力分数信息,再基于预设的全局主路径,对图像相关注意力分数信息进行保守调节,快速地生成主路径候选输出分布信息,然后根据主路径候选输出分布信息,判断当前生成位置是否属于待增强位置,如果当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,可靠地生成校正路径候选输出分布信息,再比较校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息,如果校正路径候选输出分布信息的可靠性信息高于主路径候

选输出分布信息的可靠性信息,则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将主路径候选输出分布信息作为当前生成位置的最终输出分布信息,最后根据最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,有效地生成完整回答文本信息,从而能够在降低对象幻觉的同时保持或提升模型对真实图像对象的召回能力和描述完整性,提高输出内容与输入图像之间的一致性、可靠性和安全性,在一定程度上解决了当前可靠性较差的问题。

[0010] 需要说明的是,本申请不是简单增强或削弱多模态大语言模型的视觉注意力,而是围绕“过强视觉注意力导致追加式对象幻觉”这一新发现,构建以保守全局主路径为默认路径、以局部校正路径为例外增强路径、并以预测熵和置信度进行门控选择的动态推理机制,

并且,本申请针对“过强视觉注意力导致追加式对象幻觉”的问题重新建模,即现有多模态大语言模型幻觉抑制方法通常将对象幻觉主要归因于视觉信息利用不足、语言先验过强或视觉接地能力不足,因此常见处理方向是增强视觉信息、引入对比解码、重新注入视觉特征或进行训练阶段对齐,本申请不同之处在于,申请人发现视觉注意力强度并非越高越好:较弱视觉注意力可能导致真实对象遗漏,过强视觉注意力也可能使模型对局部纹理、背景区域、模糊区域或弱相关视觉信号进行过度解读,从而在回答后半部分追加输入图像中不存在的对象。本申请将该现象作为专门技术问题进行处理,避免现有视觉增强类方法在提升真实对象召回能力的同时引入新的不存在对象。

[0011] 不失一般性地,本申请设置“保守主路径优先”的非对称双路径结构,即本申请的全局主路径和局部校正路径不是普通并列关系,也不是简单平均融合关系,而是具有明确优先级的非对称结构;全局主路径是默认生成路径,其对图像相关注意力进行保守调节,使模型在多数生成位置保持适度、稳定的视觉依赖;局部校正路径只是例外校正路径,其仅在主路径存在校正必要时提供一个视觉注意力更强的候选结果。由此,本申请并不是“全局注意力+局部注意力”的简单组合,而是通过全局主路径抑制过度视觉关注,通过局部校正路径在必要位置恢复视觉证据,最终输出默认服从主路径,只有满足条件时才由局部路径覆盖。

[0012] 并且,本申请将局部视觉增强限定为基于不确定性的例外覆盖,而非默认增强,即在当前生成位置,模型首先通过保守主路径产生候选输出,并计算该候选输出分布的预测不确定性。只有当当前生成位置满足预设校正必要条件,例如主路径预测熵超过阈值时,才启用视觉注意力更强的局部校正路径。该设计将局部视觉增强限定在更可能发生错误生成的位置,而不是对所有生成位置无差别增强视觉信息,从而降低强视觉注意力在无必要位置引入新对象幻觉的风险。

[0013] 不失一般性地,本申请提出预测熵与置信度结合的双条件门控机制,即本申请并不盲目相信局部校正路径。即使当前生成位置属于高不确定位置,只有当局部校正路径候选输出分布显示出高于主路径的可靠性时,才采用校正路径结果。该门控机制可采用最大概率、前两大概率差、前k候选累计概率、输出分布负熵、熵下降幅度、候选对象词元与图像区域一致性、多层或多头一致性等指标来衡量可靠性。通过双条件门控,本申请能够避免强视觉注意力在视觉证据不清晰、图像区域模糊、背景复杂或模型误关注错误区域时引入新的对象幻觉。

[0014] 并且,本申请提供训练无关、即插即用且可适配多种模型结构的推理框架,即本申请能够作用于模型解码阶段的图像相关注意力分数和输出分布选择过程,通常无需重新训练原模型,也不需要修改原模型主体参数,具有较好的部署便利性和模型兼容性。该方法可应用于跨注意力式多模态模型、图像词元与文本词元拼接后的自注意力式多模态模型,以及通过视觉适配器、投影层、视觉前缀或视觉记忆单元引入视觉信息的多模态大语言模型。

[0015] 第二方面,本申请实施例提供了一种面向多模态大语言模型的对象幻觉抑制系统,所述系统包括:

输入图像信息获取模块:用于获取输入图像信息和文本提示信息;

图像相关注意力分数信息确定模块:用于基于输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,确定图像相关注意力分数信息;

主路径候选输出分布信息生成模块:用于基于预设的全局主路径,对图像相关注意力分数信息进行保守调节,生成主路径候选输出分布信息;

当前生成位置判断模块:用于根据主路径候选输出分布信息,判断当前生成位置是否属于待增强位置;

校正路径候选输出分布信息生成模块:用于若当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,生成校正路径候选输出分布信息,其中,增强调节的视觉注意力强度高于保守调节的视觉注意力强度;

可靠性信息比较模块:用于比较校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息;

最终输出分布信息确定模块:用于若校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将主路径候选输出分布信息作为当前生成位置的最终输出分布信息;

完整回答文本信息生成模块:用于根据最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,生成完整回答文本信息。

[0016] 第三方面,本申请实施例提供了一种终端设备,包括存储器、处理器以及存储在所述存储器中并可在所述处理器上运行的计算机程序,所述处理器执行所述计算机程序时实现如上述第一方面的方法的步骤。

[0017] 第四方面,本申请实施例提供了一种计算机可读存储介质,所述计算机可读存储介质存储有计算机程序,所述计算机程序被处理器执行时实现如上述第一方面的方法的步骤。

[0018] 可以理解的是,上述第二方面至第四方面的有益效果可以参见上述第一方面中的相关描述,在此不再赘述。

附图说明

[0019] 为了更清楚地说明本申请实施例中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍。

[0020] 图1是本申请一实施例提供的对象幻觉抑制方法的流程示意图;

图2是本申请一实施例提供的对象幻觉抑制方法中步骤S200的流程示意图；
图3是本申请一实施例提供的对象幻觉抑制方法中步骤S300的流程示意图；
图4是本申请一实施例提供的对象幻觉抑制方法中步骤S400的流程示意图；
图5是本申请一实施例提供的对象幻觉抑制方法中步骤S500的流程示意图；
图6是本申请一实施例提供的对象幻觉抑制方法中步骤S700的流程示意图；
图7是本申请一实施例提供的整体执行过程的示意图；
图8是本申请一实施例提供的对象幻觉抑制系统的模块框图；
图9是本申请一实施例提供的终端设备的示意图。

具体实施方式

[0021] 以下描述中，为了说明而不是为了限定，提出了诸如特定系统结构、技术之类的具体细节，以便透彻理解本申请实施例。然而，本领域的技术人员应当清楚，在没有这些具体细节的其它实施例中也可以实现本申请。在其它情况中，省略对众所周知的系统、装置、电路以及方法的详细说明，以免不必要的细节妨碍本申请的描述。

[0022] 在本申请说明书和所附权利要求书的描述中，术语“第一”、“第二”、“第三”等仅用于区分描述，而不能理解为指示或暗示相对重要性。

[0023] 在本申请说明书中描述的参考“一个实施例”或“一些实施例”等意味着在本申请的一个或多个实施例中包括结合该实施例描述的特定特征、结构或特点。由此，在本说明书中的不同之处出现的语句“在一个实施例中”、“在一些实施例中”、“在其他一些实施例中”、“在另外一些实施例中”等不是必然都参考相同的实施例，而是意味着“一个或多个但不是所有的实施例”，除非是以其他方式另外特别强调。术语“包括”、“包含”、“具有”及它们的变形都意味着“包括但不限于”，除非是以其他方式另外特别强调。

[0024] 为了说明本申请所述的技术方案，下面通过具体实施例来进行说明。

[0025] 请参阅图1，图1是本申请实施例提供的面向多模态大语言模型的对象幻觉抑制方法的流程示意图。在本实施例中，对象幻觉抑制方法的执行主体为终端设备。可以理解的是，终端设备的类型包括但不限于平板电脑、笔记本电脑、超级移动个人计算机(Ultra-Mobile Personal Computer，UMPC)、上网本、个人数字助理(Personal Digital Assistant，PDA)等，本申请实施例对终端设备的具体类型不作任何限制。

[0026] 请参阅图1，本申请实施例提供的对象幻觉抑制方法包括但不限于以下步骤：

在S100中，获取输入图像信息和文本提示信息。

[0027] 具体来说，终端设备可以获取输入图像信息和文本提示信息。

[0028] 示例性地，终端设备可以获取用户输入的图像I以及文本提示X，其中，文本提示可以为开放式图像描述指令、视觉问答问题、多轮对话上下文、对象识别问题或其他多模态任务指令。

[0029] 在S200中，基于输入图像信息和文本提示信息，在多模态大语言模型逐词元生成回答文本的过程中，根据当前生成位置，确定图像相关注意力分数信息。

[0030] 具体来说，在终端设备获取输入图像信息和文本提示信息之后，终端设备可以基于输入图像信息和文本提示信息，在多模态大语言模型逐词元生成回答文本的过程中，根据当前生成位置，快速地确定图像相关注意力分数信息，其中，图像相关注意力分数信息用

于描述从当前生成位置到图像视觉词元的图像相关注意力分数;图像相关注意力分数信息为softmax归一化之前的注意力分数。

[0031] 示例性地,终端设备可以利用预设的视觉编码模块对输入图像进行编码,得到图像视觉词元集合V,并且利用文本编码模块对文本提示进行词元化和嵌入处理,得到文本词元表示,然后多模态大语言模型解码模块根据图像视觉词元、文本提示词元以及已经生成的历史词元,进入当前生成位置t的解码过程,并获取文本生成位置到图像视觉词元的图像相关注意力分数Z_img。

[0032] 在一些可能的实现方式中,为了实现确定图像相关注意力分数信息,请参阅图2,步骤S200包括但不限于以下步骤:

在S210中,对输入图像信息进行编码处理,生成图像视觉词元集合信息。

[0033] 具体来说,终端设备可以对输入图像信息进行编码处理,有效地生成图像视觉词元集合信息,其中,图像视觉词元集合信息包括多个图像视觉词元信息。

[0034] 在S220中,对文本提示信息进行词元化和嵌入处理,生成文本词元信息。

[0035] 具体来说,在终端设备生成图像视觉词元集合信息之后,终端设备可以对文本提示信息进行词元化和嵌入处理,快速地生成文本词元信息。

[0036] 在S230中,当多模态大语言模型采用跨注意力机制融合图像视觉词元信息时,将当前生成位置作为查询,并将图像视觉词元作为键和值,提取当前生成位置到各个图像视觉词元信息的跨注意力分数,确定图像相关注意力分数信息。

[0037] 具体来说,当多模态大语言模型采用跨注意力机制融合图像视觉词元信息时,终端设备可以将当前生成位置作为查询,并将图像视觉词元作为键和值,提取当前生成位置到各个图像视觉词元信息的跨注意力分数,有效地确定图像相关注意力分数信息,从而实现图像相关注意力分数的获取。

[0038] 示例性地,多模态大语言模型可以采用跨注意力机制引入视觉信息,此时,当前文本生成位置作为查询端,图像视觉词元作为键和值,模型计算当前生成位置到各图像视觉词元的跨注意力分数。

[0039] 或者,在S240中,当多模态大语言模型将图像视觉词元信息与文本词元信息拼接后通过自注意力机制进行融合时,从自注意力矩阵中提取当前生成位置到各个图像视觉词元信息的注意力分数,确定图像相关注意力分数信息。

[0040] 具体来说,当多模态大语言模型将图像视觉词元信息与文本词元信息拼接后通过自注意力机制进行融合时,终端设备可以从自注意力矩阵中提取当前生成位置到各个图像视觉词元信息的注意力分数,有效地确定图像相关注意力分数信息。

[0041] 示例性地,多模态大语言模型将图像视觉词元与文本词元拼接后输入大语言模型,并通过自注意力机制进行多模态融合,此时,终端设备可以根据词元位置索引区分图像视觉词元和文本词元,并从自注意力矩阵中提取当前文本生成位置到图像视觉词元位置的注意力分数,作为图像相关注意力分数。

[0042] 在一些可能的实现方式中,为了实现图像相关注意力分数的获取,多模态大语言模型通过视觉适配器、投影层或者连接模块将视觉特征映射到语言模型表示空间,此时,终端设备可以将当前生成位置对视觉适配器输出特征、视觉记忆单元或视觉前缀词元的注意力分数作为图像相关注意力分数;优选地,本申请在softmax归一化之前对图像相关注意力

分数进行调节,从生成机制层面调整当前生成位置对图像信息和语言上下文信息的相对依赖程度,而不是在生成结果之后进行简单文本过滤。

[0043] 在S300中,基于预设的全局主路径,对图像相关注意力分数信息进行保守调节,生成主路径候选输出分布信息。

[0044] 具体来说,在终端设备确定图像相关注意力分数信息之后,终端设备可以基于预设的全局主路径,对图像相关注意力分数信息进行保守调节,快速地生成主路径候选输出分布信息。

[0045] 在一些可能的实现方式中,为了实现生成主路径候选输出分布信息,请参阅图3,步骤S300包括但不限于以下步骤:

在S310中,基于预设的第一视觉注意力校正参数,对图像相关注意力分数信息进行缩放,生成第一处理数据信息。

[0046] 具体来说,终端设备可以基于预设的第一视觉注意力校正参数,对图像相关注意力分数信息进行缩放,有效地生成第一处理数据信息。

[0047] 在S320中,对第一处理数据信息进行前向计算,生成主路径候选输出分布信息。

[0048] 具体来说,在终端设备生成第一处理数据信息之后,终端设备可以对第一处理数据信息进行前向计算,快速地生成主路径候选输出分布信息。

[0049] 示例性地,终端设备可以通过全局主路径对图像相关注意力分数进行保守调节;在一种可能的实现方式中,主路径注意力分数为$Z'_img = gamma1 \cdot Z_img$,并基于调节后的注意力分数执行当前生成位置的前向计算,得到主路径候选输出分布P_g=Softmax(Logit_g)。

[0050] 在S400中,根据主路径候选输出分布信息,判断当前生成位置是否属于待增强位置。

[0051] 具体来说,在终端设备生成主路径候选输出分布信息之后,终端设备可以根据主路径候选输出分布信息,判断当前生成位置是否属于待增强位置,其中,待增强位置用于描述高不确定位置。

[0052] 在一些可能的实现方式中,为了实现有效地判断当前生成位置是否属于待增强位置,请参阅图4,步骤S400包括但不限于以下步骤:

在S410中,计算主路径候选输出分布信息的预测熵信息。

[0053] 具体来说,终端设备可以先计算主路径候选输出分布信息的预测熵信息。

[0054] 在S420中,比对预测熵信息和预设的增强阈值。

[0055] 具体来说,在终端设备计算预测熵信息之后,终端设备可以比对预测熵信息和预设的增强阈值。

[0056] 在S430中,若预测熵信息大于预设的增强阈值,则确定当前生成位置属于待增强位置,否则确定当前生成位置不属于待增强位置。

[0057] 具体来说,如果预测熵信息大于预设的增强阈值,则终端设备可以确定当前生成位置属于待增强位置,否则终端设备可以确定当前生成位置不属于待增强位置。

[0058] 示例性地,终端设备可以根据主路径候选输出分布P_g计算当前生成位置的不确定性,优选地,终端设备可以采用预测熵$H(P_g) = -\Sigma P_g(v) \log P_g(v)$作为不确定性指标,并将该不确定性与预设阈值delta进行比较,以判断当前生成位置是否属于高不确定位置。

[0059] 在S500中,若当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,生成校正路径候选输出分布信息。

[0060] 具体来说,如果当前生成位置属于待增强位置,则终端设备可以基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,有效地生成校正路径候选输出分布信息,其中,增强调节的视觉注意力强度高于保守调节的视觉注意力强度。

[0061] 示例性地,在当前生成位置属于高不确定位置时,终端设备可以启用局部校正路径,对图像相关注意力分数进行较强视觉调节;在一些可能的实现方式中,校正路径注意力分数为$Z''_img = gamma2 \cdot Z_img$,其中gamma2>gamma1,并且基于调节后的注意力分数得到校正路径候选输出分布P_l=Softmax(Logit_l)。

[0062] 在一些可能的实现方式中,为了实现生成校正路径候选输出分布信息,请参阅图5,步骤S500包括但不限于以下步骤:

在S510中,若确定当前生成位置属于待增强位置,则基于预设的第二视觉注意力校正参数,对图像相关注意力分数信息进行缩放,生成第二处理数据信息。

[0063] 具体来说,如果确定当前生成位置属于待增强位置,则终端设备可以基于预设的第二视觉注意力校正参数,对图像相关注意力分数信息进行缩放,有效地生成第二处理数据信息。

[0064] 在S520中,对第二处理数据信息进行前向计算,生成校正路径候选输出分布信息。

[0065] 具体来说,在终端设备生成第二处理数据信息之后,终端设备可以对第二处理数据信息进行前向计算,快速地生成校正路径候选输出分布信息,其中,第二视觉注意力校正参数大于第一视觉注意力校正参数。

[0066] 在S600中,比较校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息。

[0067] 具体来说,在终端设备生成校正路径候选输出分布信息之后,终端设备可以比较校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息。

[0068] 示例性地,终端设备可以比较主路径候选输出分布P_g和校正路径候选输出分布P_l的可靠性;可靠性可采用最大概率C=max(P)、前两大概率差、前k个候选词元累计概率、输出分布负熵、熵下降幅度或候选对象词元与图像区域一致性等指标确定。

[0069] 在S700中,若校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将主路径候选输出分布信息作为当前生成位置的最终输出分布信息。

[0070] 具体来说,如果校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则终端设备可以将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则终端设备可以将主路径候选输出分布信息作为当前生成位置的最终输出分布信息。

[0071] 示例性地,当H(P_g)>delta且校正路径可靠性高于主路径可靠性时,终端设备采用P_l作为最终输出分布;否则,终端设备采用P_g作为最终输出分布。

[0072] 在一些可能的实现方式中,为了确定前生成位置的最终输出分布信息,请参阅图6,步骤S700包括但不限于以下步骤:

在S710中,若校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布

信息的可靠性信息,则判断校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值是否大于预设的置信度差值阈值信息。

[0073] 具体来说,如果校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则终端设备可以判断校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值是否大于预设的置信度差值阈值信息

示例性地,如果设置可选置信度差值阈值lambda,则终端设备可进一步限定C_l>C_g+lambda后才允许局部校正路径覆盖主路径

在S720中,若校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值大于预设的置信度差值阈值信息,则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息。

[0074] 具体来说,如果校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值大于预设的置信度差值阈值信息,则终端设备可以将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息。

[0075] 在S800中,根据最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,生成完整回答文本信息。

[0076] 具体来说,在终端设备确定当前生成位置的最终输出分布信息之后,终端设备可以根据最终输出分布信息,快速地生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,有效地生成完整回答文本信息,从而提出一种无需重新训练模型、能够在推理阶段动态调节视觉注意力,并能够在抑制对象幻觉的同时保持感知完整性的多模态大语言模型推理方法,实现词元级别的动态视觉注意力控制,与对整段回答统一施加视觉增强的方式相比,本申请仅在主路径预测不确定且局部校正路径更可信的位置增强视觉注意力,因此能够减少不必要干预,降低追加式对象幻觉风险,并控制额外推理开销。

[0077] 示例性地,请参阅图7,图7表示了本申请在每个生成位置获取图像相关注意力分数Z_img、执行全局主路径计算、基于预测熵判断是否启用局部校正路径、通过可靠性门控确定P_final、并循环生成当前词元直至输出完整回答的过程。终端设备可以根据最终输出分布P_final生成当前词元y_t,生成方式可以为贪心解码、采样解码、top-k采样、核采样、束搜索或其他文本生成方式,然后将当前词元加入已生成文本序列中,并进入下一个生成位置,重复执行上述步骤,直至生成结束符、达到最大生成长度、输出内容满足用户问题的回答要求,或者触发其他预设停止规则,最终输出完整文本回答。

[0078] 需要说明的是,为了便于理解本申请,以下对术语和变量进行再次说明,终端设备可以将输入图像记为I,将用户输入的文本提示记为X;视觉编码模块对输入图像I进行编码后,得到图像视觉词元集合V,该集合中可以包括v1至vm共m个图像视觉词元;多模态大语言模型在第t个生成位置,根据图像视觉词元、文本提示词元以及已经生成的历史词元生成当前词元y_t;当前生成位置到图像视觉词元的图像相关注意力分数记为Z_img。该分数可以是softmax归一化之前的注意力分数,也可以是在注意力归一化之前能够表征当前文本生成位置与图像视觉词元之间关联程度的其他分数;主路径候选输出分布记为P_g,表示在全局主路径视觉注意力条件下模型对当前生成词元的概率预测分布;校正路径候选输出分布记为P_l,表示在局部校正路径视觉注意力条件下模型对当前生成词元的概率预测分布;最终输出分布记为P_final,表示当前生成位置实际用于生成词元的输出分布;gamma1表示全

局主路径的第一视觉注意力校正参数,gamma2表示局部校正路径的第二视觉注意力校正参数,且通常设置gamma1<gamma2;delta表示不确定性阈值;lambda表示可选的置信度差值阈值。上述变量名称均为示例性表达,实际实施时也可以采用其他符号或参数名称。

[0079] 在一些可能的实现方式中,全局主路径中的“保守调节”可以并不限定为绝对降低视觉注意力,而是指相对于局部校正路径而言采用较低强度、较稳定、较不激进的视觉注意力调节方式;除乘法缩放外,主路径也可以采用中心化缩放、加性偏置、温度调节、归一化前重标定、归一化后重加权或视觉词元选择性增强等方式实现。

[0080] 不失一般性地,局部校正路径也不限于单一乘法缩放方式,可以采用中心化缩放、加性偏置、温度调节、视觉词元筛选、视觉特征门控或视觉上下文重注入等方式实现。局部校正路径可以只在高不确定位置启用,也可以结合生成内容类型触发,例如仅当候选词元可能为对象名词、属性词、空间关系词、数量词或医学诊断相关词时启用。

[0081] 具体地,最终输出分布的确定方式不限于在主路径候选输出分布和校正路径候选输出分布之间二选一,也可以根据预测不确定性和可靠性为两条路径分配权重,并对两条路径的候选输出分布进行加权融合;还可以设置多级局部校正路径,在不同不确定性程度下采用不同强度的视觉校正。

[0082] 因此,本申请可以对多模态大语言模型的全部解码层执行视觉注意力校正,也可以仅对部分解码层、部分视觉相关注意力头或部分图像视觉词元执行校正。例如,在一种优选实施方式中,保留前若干层原始注意力机制不变,仅从中间层或后若干层开始执行本申请的校正方法,以在幻觉抑制效果和推理效率之间取得平衡。

[0083] 在一些可能的实现方式中,第一视觉注意力校正参数gamma1用于控制全局主路径中的视觉注意力强度,优选设置为相对保守的视觉注意力强度,使模型在默认生成过程中不过度放大图像视觉信息;第二视觉注意力校正参数gamma2用于控制局部校正路径中的视觉注意力强度,优选设置为大于gamma1,以便在高不确定位置增强图像视觉证据;不确定性阈值delta用于判断当前生成位置是否属于高不确定位置,delta可根据验证集搜索确定,也可以根据输入复杂度、任务类型或生成阶段动态调整;在一种具体实验设置中,多项任务固定采用delta=1.5,并通过消融实验显示该方法在较宽阈值范围内均能保持有效。

[0084] 在一些可能的实现方式中,可选置信度差值阈值lambda用于避免两条路径置信度差异很小但仍频繁切换输出分布的问题。当设置lambda时,只有校正路径置信度超过主路径置信度一定幅度才允许覆盖主路径。

[0085] 在一些可能的实现方式中,参数可以通过验证集搜索确定;具体地,可以在一组图像描述或视觉问答验证样本上,分别测试不同参数组合,并根据对象幻觉率、真实对象召回率、回答准确率、文本流畅性和平均推理耗时等指标选择较优参数。

[0086] 需要说明的是,请参阅表1,表1列出了本申请在CHAIR基准上的部分典型实验结果,用于说明本申请在抑制对象幻觉和保持对象召回方面的效果,结合表1可知,本申请具有但不限于以下六个积极效果:

(1)本申请无需重新训练模型,部署便利,即本申请在推理阶段调节图像相关注意力分数并进行候选输出门控选择,通常不需要额外训练数据、人工标注、模型再训练或外部校正模块,可作为插件式推理策略集成到已有多模态大语言模型系统中。

[0087] (2)本申请专门抑制追加式对象幻觉,与单纯增强视觉注意力的方法不同,本申请

默认采用保守视觉注意力主路径,能够避免模型在整个生成过程中持续处于强视觉注意力状态,从而降低回答后段因过度视觉关注而追加不存在对象的概率。

[0088] (3)本申请保持或提升真实对象召回能力,即本申请并非简单降低视觉注意力,而是在主路径高不确定位置启用局部校正路径,增强模型对图像视觉证据的利用能力,以修正因语言先验、训练语料共现偏置或视觉依赖不足导致的真实对象遗漏和错误生成。

[0089] (4)本申请实现词元级动态控制,减少不必要干预,即本申请在每个生成位置根据预测熵和可靠性判断是否采用局部校正结果,相比整段统一施加视觉增强的方式,更能细粒度地兼顾事实一致性、对象召回能力、文本流畅性和推理效率。

[0090] (5)本申请的跨模型、跨任务适用性强,即本申请可用于图像描述、视觉问答、多模态对话、医学影像解释、自动驾驶场景理解、机器人视觉交互、工业质检图像解释、遥感图像解译、电商商品图像说明生成等任务,并可适配不同视觉编码器、连接模块和大语言模型解码结构。

[0091] (6)本申请的实验验证效果明确,即本申请在CHAIR、AMBER和MM-Vet等基准上对LLaVA-v1.5-7B、LLaVA-v1.5-13B和MiniGPT-4等模型进行了验证。以CHAIR基准为例,GLVAC在多个模型上降低CHAIRs和CHAIRi,并在保持甚至提升Recall的情况下抑制对象幻觉,表明其能够在幻觉抑制与感知完整性之间取得更优平衡。

[0092] 表1 CHAIR 基准部分实验结果表

模型	方法	CHAIRs ↓	CHAIRi ↓	Recall ↑
LLaVA-v1.5-7B	regular	50.4	14.2	80.6
LLaVA-v1.5-7B	GLVAC	46.2	13.9	81.2
LLaVA-v1.5-13B	regular	48.2	13.2	79.4
LLaVA-v1.5-13B	GLVAC	44.4	12.2	80.9
MiniGPT-4	regular	37.6	14.4	59.4
MiniGPT-4	GLVAC	36.6	11.7	63.5

在一些可能的实现方式中,本申请可以结合以下具体的应用场景:

(1)开放式图像描述服务中的对象幻觉抑制系统:即在云端图像描述服务中,系统部署已有多模态大语言模型,例如采用视觉编码器、投影连接层和大语言模型解码器组成的模型。用户上传图像并输入“请详细描述该图像”等提示语后,系统首先利用视觉编码器得到图像视觉词元集合V,并利用文本编码模块得到文本提示和历史回答词元表示。

[0093] 具体地,在第t个生成位置,系统从模型跨注意力层或自注意力层中提取当前文本生成位置到图像视觉词元的归一化前注意力分数Z_img。全局主路径以第一缩放系数gamma1对Z_img进行保守调节,并得到主路径候选输出分布P_g。系统计算P_g的预测熵H(P_g),当H(P_g)不超过阈值delta时,直接采用P_g生成当前词元;当H(P_g)超过阈值delta时,启用局部校正路径。

[0094] 不失一般性地,局部校正路径以第二缩放系数gamma2对同一Z_img进行更强视觉调节,得到校正路径候选输出分布P_l。系统比较P_l与P_g的最大概率或其他可靠性指标;只有当P_l的可靠性高于P_g时,采用P_l作为最终输出分布,否则仍采用P_g。该过程逐词元循环,直至生成结束符或达到最大长度,由此输出更加符合输入图像事实的描述文本。

[0095] (2)面向边缘计算设备的视觉问答推理部署:即在车载计算设备、安防终端或工业

质检边缘设备上,受限于算力和时延要求,系统可以只在中后层解码层或视觉相关性较高的注意力头上执行本申请的校正方法,而保留前若干层原始注意力机制不变。该设置可以降低额外计算量,同时保证对最终词元决策影响较大的语义层得到动态校正。

[0096] 具体地,当输入问题为“图像中是否存在某对象”“图像中物体数量是多少”“请描述场景中潜在风险”等任务时,系统可以仅对候选对象名词、属性词、空间关系词、数量词或高风险诊断/判断词执行局部校正路径;对于常见功能词、连接词、标点符号等,则优先采用主路径结果。该实现能够进一步减少不必要的局部校正,提高实时推理效率。

[0097] (3)参数确定与效果验证流程:即在模型部署前,工程人员可在少量验证样本上搜索gamma1、gamma2、delta和可选的lambda等参数。搜索目标可以综合考虑对象幻觉率、真实对象召回率、视觉问答准确率、文本流畅性和平均推理耗时。通常要求gamma1小于gamma2,使全局主路径保持相对保守,而局部校正路径在必要位置提供更强视觉证据。

[0098] 在一种可能的实现方式中,终端设备可以采用预测熵作为校正必要性指标,并且采用候选分布最大概率作为可靠性指标;在其他一种可能的实现方式中,终端设备可以采用概率间隔、logit间隔、候选分布负熵、候选对象词元与视觉区域一致性或多层/多头一致性作为替代指标;通过验证集确认参数后,将该推理策略固化到在线推理服务或离线批量生成流程中。

[0099] 本申请实施例面向多模态大语言模型的对象幻觉抑制方法的实施原理为:终端设备可以先获取输入图像信息和文本提示信息,然后基于输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,有效地确定图像相关注意力分数信息,再基于预设的全局主路径,对图像相关注意力分数信息进行保守调节,快速地生成主路径候选输出分布信息,然后根据主路径候选输出分布信息,判断当前生成位置是否属于待增强位置,如果当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,可靠地生成校正路径候选输出分布信息,再比较校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息,如果校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将主路径候选输出分布信息作为当前生成位置的最终输出分布信息,最后根据最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,有效地生成完整回答文本信息,从而能够在无需重新训练模型、无需新增外部训练模块的情况下,于推理阶段动态调节多模态大语言模型在不同生成位置对视觉信息的依赖程度,全局主路径通过保守视觉注意力调节抑制因过度视觉关注导致的追加式对象幻觉,局部校正路径能够在模型高不确定位置增强视觉注意力,以修正因语言先验较强或视觉依赖不足导致的错误生成;同时,基于预测熵和置信度的双条件门控机制能够减少不必要或不可靠的校正;由此,本申请能够在降低对象幻觉的同时保持或提升模型对真实图像对象的召回能力和描述完整性,提高输出内容与输入图像之间的一致性、可靠性和安全性。

[0100] 需要说明的是,上述实施例中各步骤的序号的大小并不意味着执行顺序的先后,各过程的执行顺序应以其功能和内在逻辑确定,而不应对本申请实施例的实施过程构成任何限定。

[0101] 本申请的实施例还提供了一种面向多模态大语言模型的对象幻觉抑制系统,该系

统可部署于云端服务器、本地服务器、边缘计算设备、智能终端、车载计算设备、医疗影像分析设备、工业质检设备或其他具有人工智能模型推理能力的电子设备中,为便于说明,仅示出与本申请相关的部分,如图8所示,该系统80包括:

输入图像信息获取模块81:用于获取输入图像信息和文本提示信息;

图像相关注意力分数信息确定模块82:用于基于输入图像信息和文本提示信息,在多模态大语言模型逐词元生成回答文本的过程中,根据当前生成位置,确定图像相关注意力分数信息;

主路径候选输出分布信息生成模块83:用于基于预设的全局主路径,对图像相关注意力分数信息进行保守调节,生成主路径候选输出分布信息;

当前生成位置判断模块84:用于根据主路径候选输出分布信息,判断当前生成位置是否属于待增强位置;

校正路径候选输出分布信息生成模块85:用于若当前生成位置属于待增强位置,则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节,生成校正路径候选输出分布信息,其中,增强调节的视觉注意力强度高于保守调节的视觉注意力强度;

可靠性信息比较模块88:用于比较校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息;

最终输出分布信息确定模块89:用于若校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息,则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息,否则将主路径候选输出分布信息作为当前生成位置的最终输出分布信息;

完整回答文本信息生成模块88:用于根据最终输出分布信息,生成当前词元信息,并进入下一生成位置,直至满足预设的停止条件,生成完整回答文本信息。

[0102] 需要说明的是,上述模块之间的信息交互、执行过程等内容,由于与本申请方法实施例基于同一构思,其具体功能及带来的技术效果,具体可参见方法实施例部分,此处不再赘述。

[0103] 本申请实施例还提供了一种终端设备,如图9所示,该实施例的终端设备90包括:处理器91、存储器92以及存储在存储器92中并可在处理器91上运行的计算机程序93。处理器91执行计算机程序93时实现上述对象幻觉抑制方法实施例中的步骤,例如图1所示的步骤S100至S800;或者,处理器91执行计算机程序93时实现上述装置中各模块的功能,例如图8所示模块81至模块88的功能。

[0104] 该终端设备90可以是桌上型计算机、笔记本、掌上电脑及云端服务器等计算设备,该终端设备90包括但不仅限于处理器91、存储器92。本领域技术人员可以理解,图9仅仅是终端设备90的示例,并不构成对终端设备90的限定,可以包括比图示更多或更少的部件,或者组合某些部件,或者不同的部件,例如终端设备90还可以包括输入输出设备、网络接入设备、总线等。

[0105] 其中,处理器91可以是中央处理单元(Central Processing Unit,CPU),还可以是其它通用处理器、数字信号处理器(Digital Signal Processor,DSP)、专用集成电路(Application Specific Integrated Circuit,ASIC)、现场可编程门阵列(Field-Programmable Gate Array,FPGA)或者其它可编程逻辑器件、分立门或者晶体管逻辑器件、

分立硬件组件等;通用处理器可以是微处理器或者该处理器也可以是任何常规的处理器等。

[0106] 存储器92可以是终端设备90的内部存储单元,例如终端设备90的硬盘或内存,存储器92也可以是终端设备90的外部存储设备,例如终端设备90上配备的插接式硬盘,智能存储卡(Smart Media Card,SMC),安全数字(Secure Digital,SD)卡,闪存卡(Flash Card)等;进一步地,存储器92还可以既包括终端设备90的内部存储单元也包括外部存储设备,存储器92还可以存储计算机程序93以及终端设备90所需的其它程序和数据,存储器92还可以用于暂时地存储已经输出或者将要输出的数据。

[0107] 本申请的一个实施例还提供了一种计算机可读存储介质,该存储介质存储有计算机程序,该计算机程序在被处理器执行时,可实现上述各个方法实施例的步骤。其中,计算机程序包括计算机程序代码,计算机程序代码可以为源代码形式、对象代码形式、可执行文件或某些中间形式等;计算机可读介质可以包括:能够携带计算机程序代码的任何实体或装置、记录介质、U盘、移动硬盘、磁碟、光盘、计算机存储器、只读存储器(Read-Only Memory,ROM)、随机存取存储器(Random Access Memory,RAM)、电载波信号、电信信号以及软件分发介质等。

[0108] 以上均为本申请的较佳实施例,并非依此限制本申请的保护范围,故:凡依本申请的方法、原理、结构所做的等效变化,均应涵盖于本申请的保护范围之内。

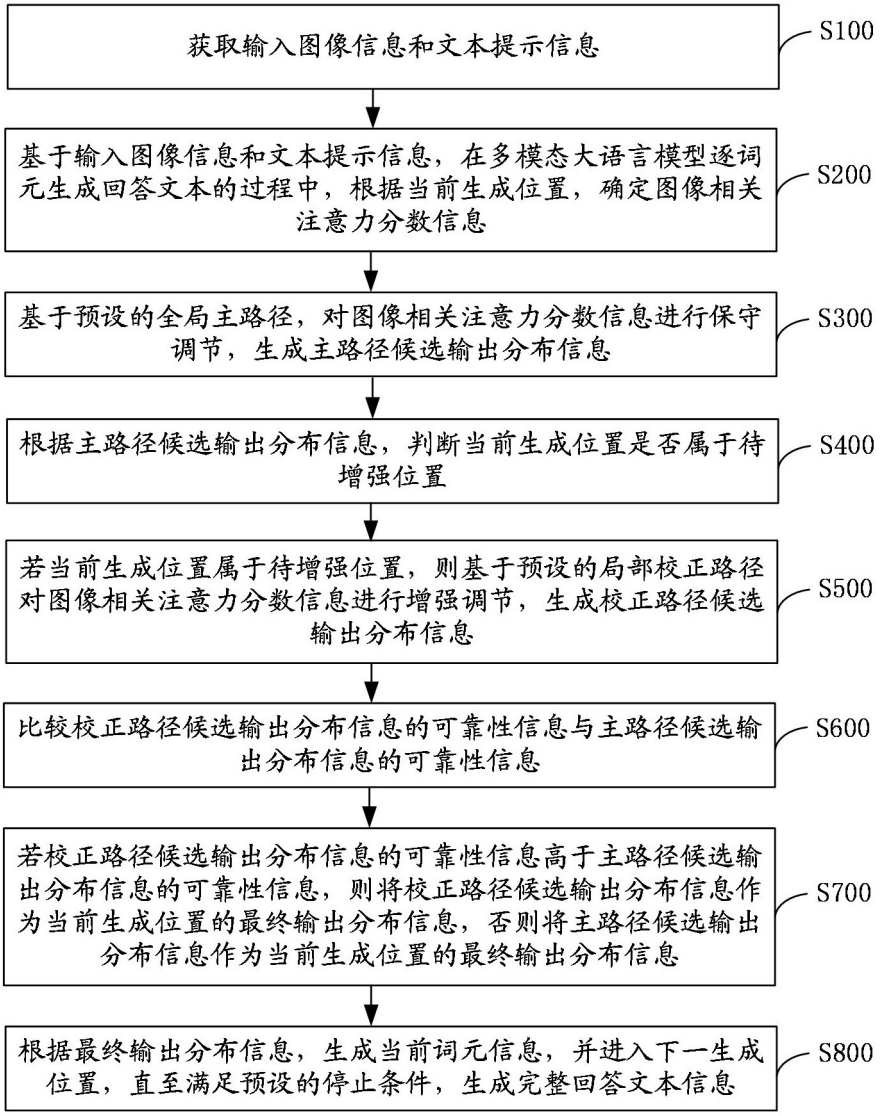

获取输入图像信息和文本提示信息
S100
基于输入图像信息和文本提示信息，在多模态大语言模型逐词元生成回答文本的过程中，根据当前生成位置，确定图像相关注意力分数信息
S200
基于预设的全局主路径，对图像相关注意力分数信息进行保守调节，生成主路径候选输出分布信息
S300
根据主路径候选输出分布信息，判断当前生成位置是否属于待增强位置
S400
若当前生成位置属于待增强位置，则基于预设的局部校正路径对图像相关注意力分数信息进行增强调节，生成校正路径候选输出分布信息
S500
比较校正路径候选输出分布信息的可靠性信息与主路径候选输出分布信息的可靠性信息
S600
若校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息，则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息，否则将主路径候选输出分布信息作为当前生成位置的最终输出分布信息
S700
根据最终输出分布信息，生成当前词元信息，并进入下一生成位置，直至满足预设的停止条件，生成完整回答文本信息
S800

图1

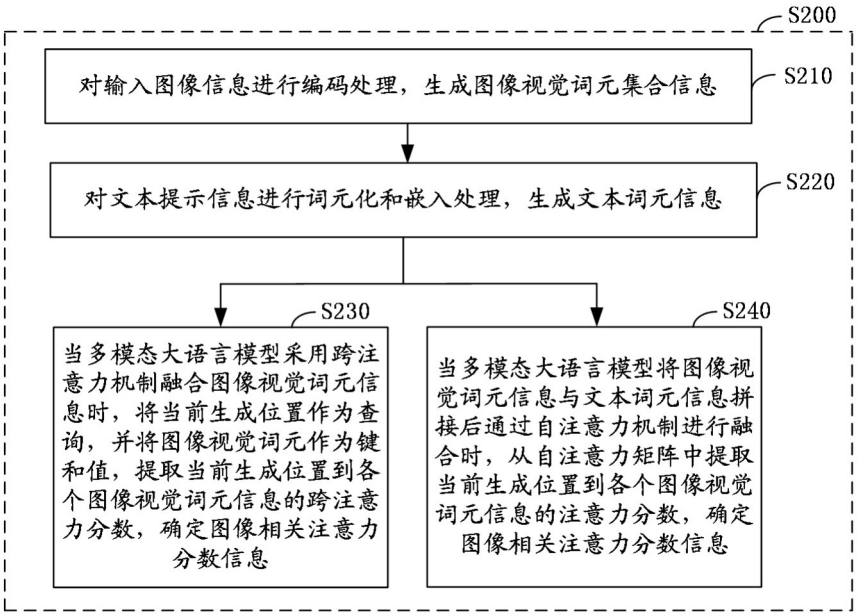

S200
对输入图像信息进行编码处理，生成图像视觉词元集合信息
S210
对文本提示信息进行词元化和嵌入处理，生成文本词元信息
S220
S230
当多模态大语言模型采用跨注意力机制融合图像视觉词元信息时，将当前生成位置作为查询，并将图像视觉词元作为键和值，提取当前生成位置到各个图像视觉词元信息的跨注意力分数，确定图像相关注意力分数信息
S240
当多模态大语言模型将图像视觉词元信息与文本词元信息拼接后通过自注意力机制进行融合时，从自注意力矩阵中提取当前生成位置到各个图像视觉词元信息的注意力分数，确定图像相关注意力分数信息

图2

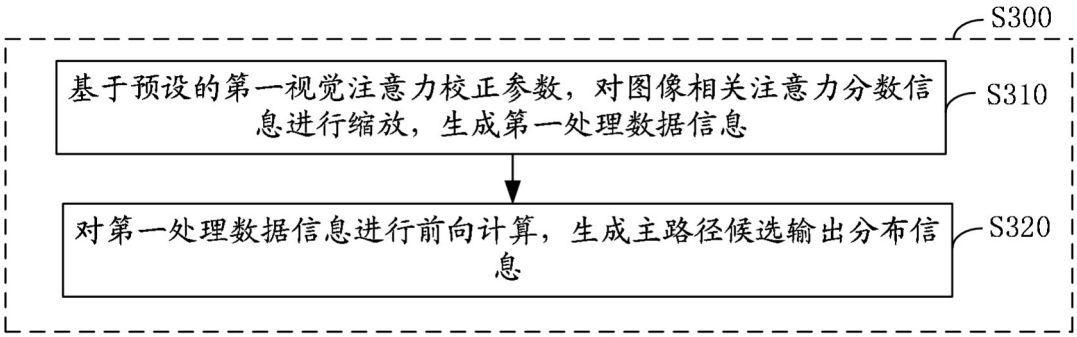

S300
基于预设的第一视觉注意力校正参数，对图像相关注意力分数信息进行缩放，生成第一处理数据信息
S310
对第一处理数据信息进行前向计算，生成主路径候选输出分布信息
S320

图3

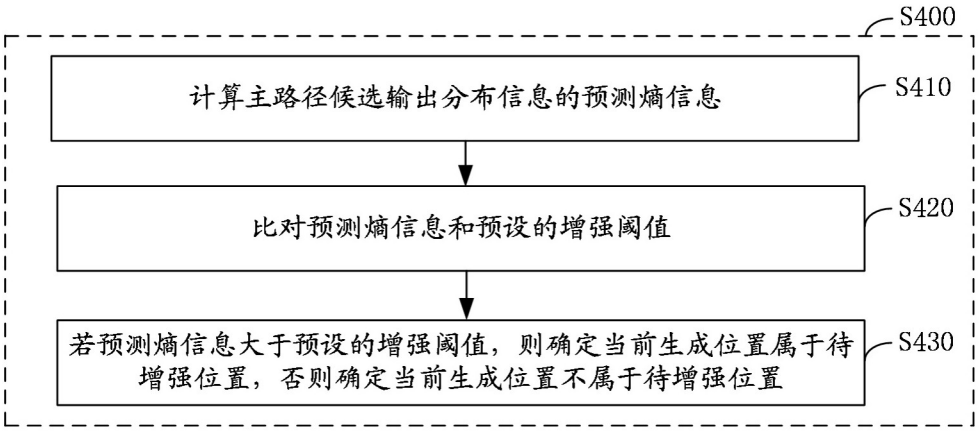

S400
计算主路径候选输出分布信息的预测熵信息
S410
比对预测熵信息和预设的增强阈值
S420
若预测熵信息大于预设的增强阈值，则确定当前生成位置属于待增强位置，否则确定当前生成位置不属于待增强位置
S430

图4

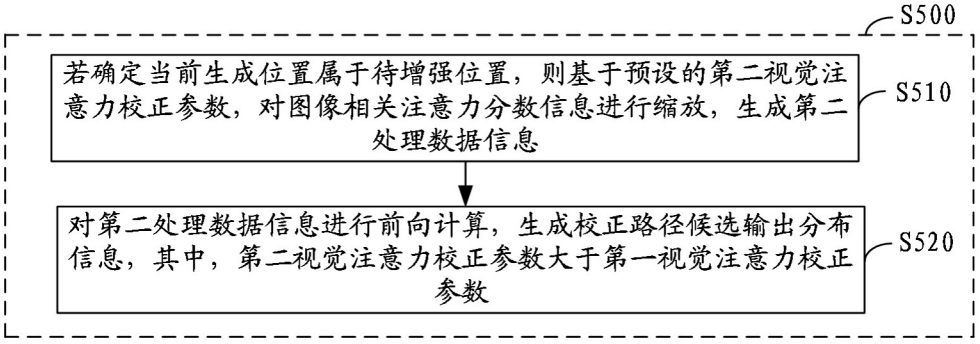

S500
若确定当前生成位置属于待增强位置，则基于预设的第二视觉注意力校正参数，对图像相关注意力分数信息进行缩放，生成第二处理数据信息
S510
对第二处理数据信息进行前向计算，生成校正路径候选输出分布信息，其中，第二视觉注意力校正参数大于第一视觉注意力校正参数
S520

图5

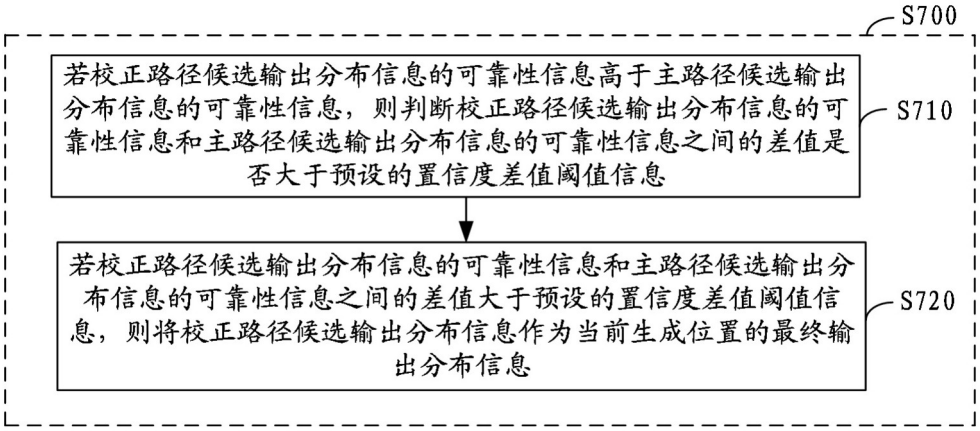

S700
若校正路径候选输出分布信息的可靠性信息高于主路径候选输出分布信息的可靠性信息，则判断校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值是否大于预设的置信度差值阈值信息
S710
若校正路径候选输出分布信息的可靠性信息和主路径候选输出分布信息的可靠性信息之间的差值大于预设的置信度差值阈值信息，则将校正路径候选输出分布信息作为当前生成位置的最终输出分布信息
S720

图6

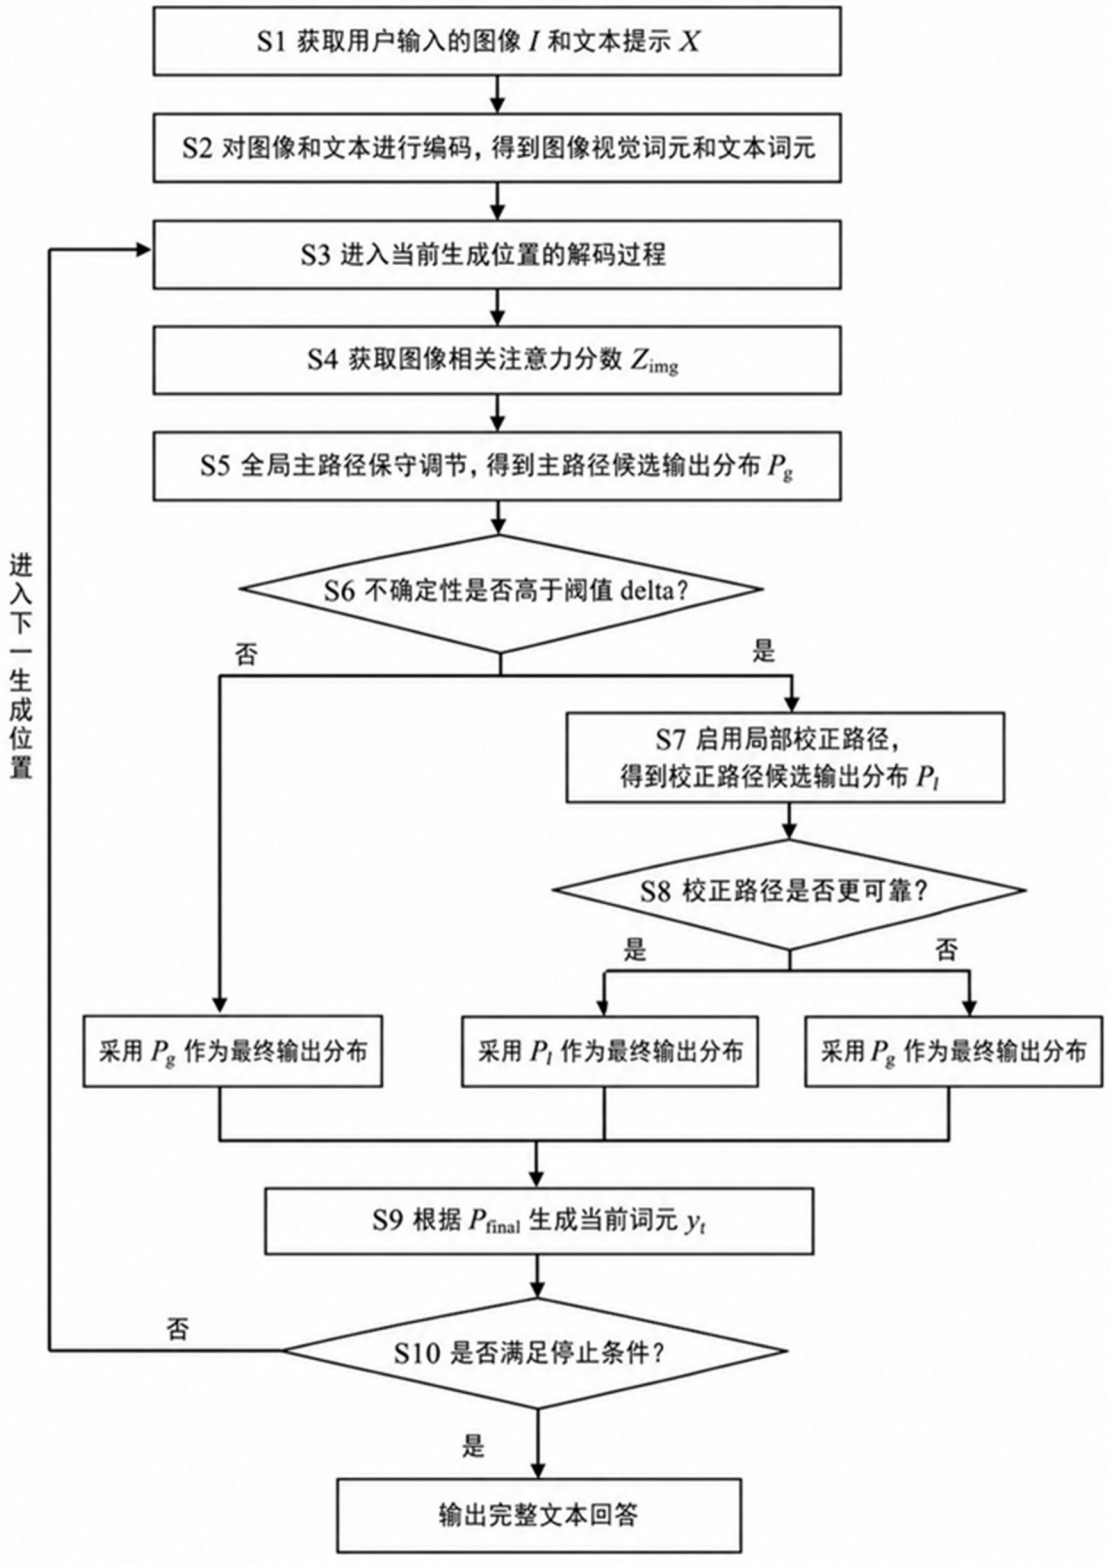

S1 获取用户输入的图像 I 和文本提示 X
S2 对图像和文本进行编码，得到图像视觉词元和文本词元
S3 进入当前生成位置的解码过程
S4 获取图像相关注意力分数 Z_{img}
S5 全局主路径保守调节，得到主路径候选输出分布 P_g
S6 不确定性是否高于阈值 delta?
否
是
S7 启用局部校正路径，
得到校正路径候选输出分布 P_l
S8 校正路径是否更可靠?
是
否
采用 P_g 作为最终输出分布
采用 P_l 作为最终输出分布
采用 P_g 作为最终输出分布
S9 根据 P_{final} 生成当前词元 y_t
否
S10 是否满足停止条件?
是
输出完整文本回答
进入下一生成位置

图7

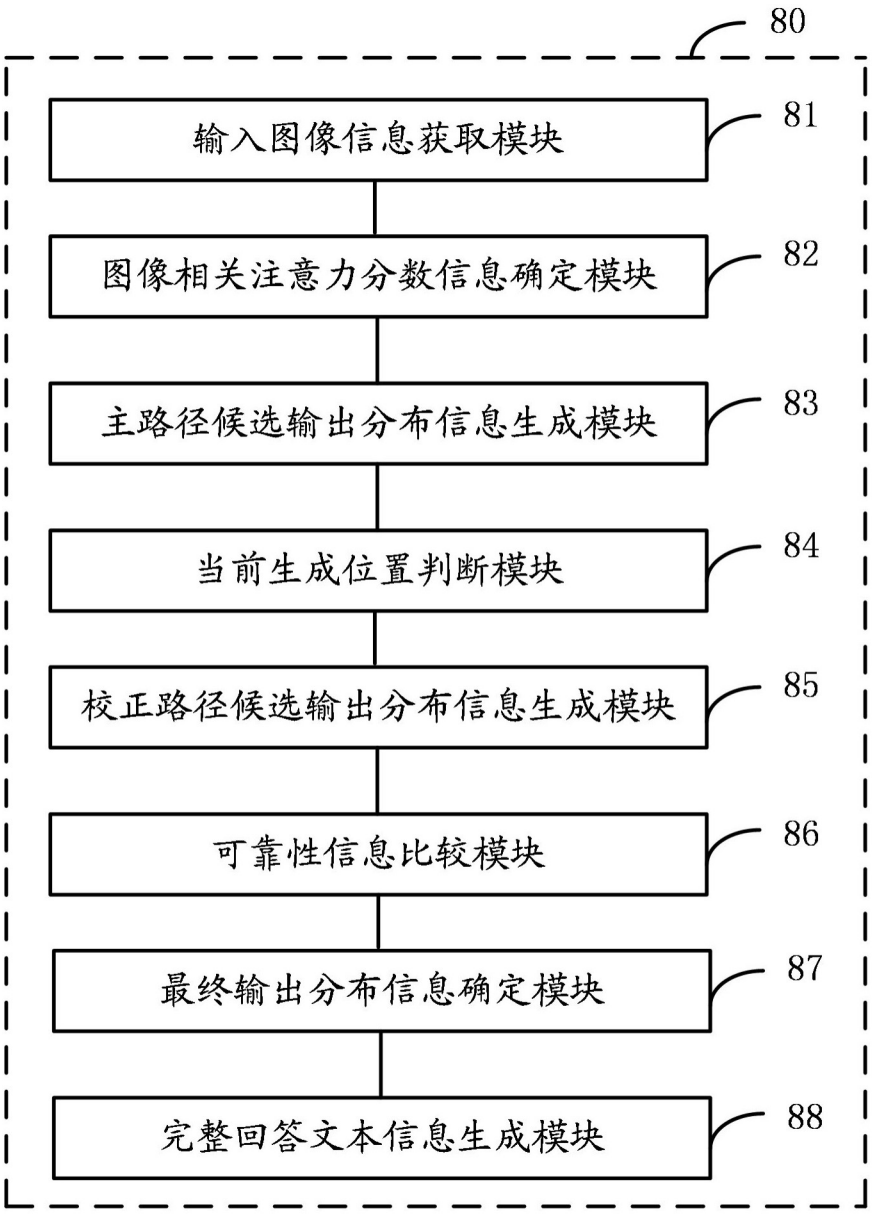

80
输入图像信息获取模块
81
图像相关注意力分数信息确定模块
82
主路径候选输出分布信息生成模块
83
当前生成位置判断模块
84
校正路径候选输出分布信息生成模块
85
可靠性信息比较模块
86
最终输出分布信息确定模块
87
完整回答文本信息生成模块
88

图8

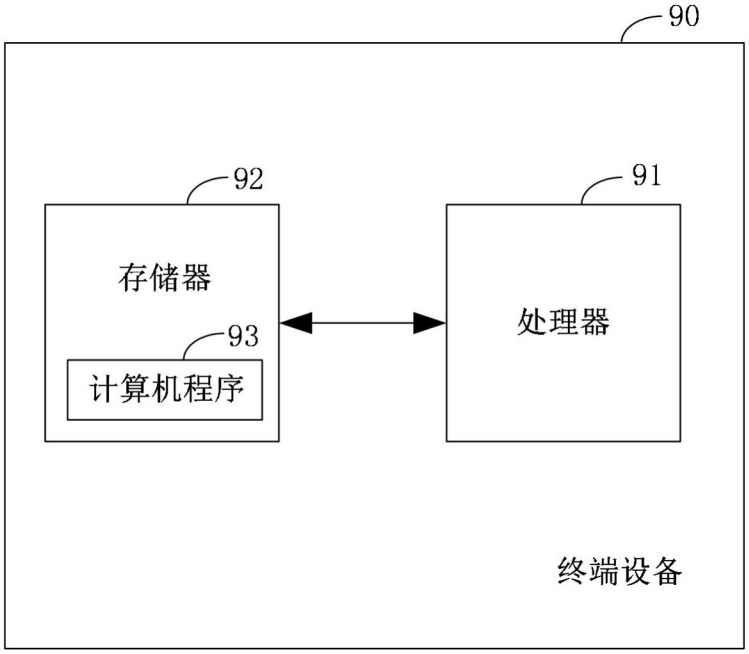


图9