(19)国家知识产权局

(12)发明专利

(10)授权公告号 CN 122698377 B
(45)授权公告日 2026.10.09

(21)申请号 202611185632.9
(22)申请日 2026.08.06
(65)同一申请的已公布的文献号
申请公布号 CN 122698377 A
(43)申请公布日 2026.09.04
(73)专利权人 中国科学技术大学
地址 230000 安徽省合肥市包河区金寨路96号
(72)发明人 阮文杰 杨志国 许佩佩
(74)专利代理机构 佛山信智汇知识产权代理事务所(特殊普通合伙) 44629
专利代理师 冯桂彬
(51)Int.Cl.
H04L 9/40(2022.01)
H04L 41/14(2022.01)
G06N 5/022(2023.01)
(56)对比文件
CN 121456468 A,2026.02.03
CN 122021751 A,2026.05.12
审查员 刘金鑫

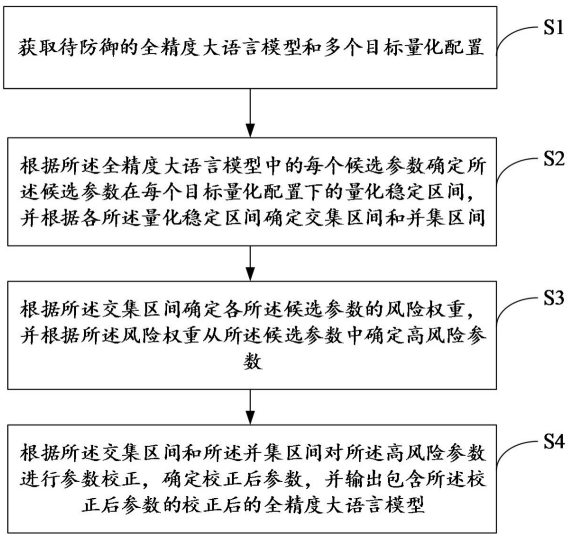
权利要求书3页 说明书10页 附图4页

(54)发明名称

基于交并集约束的大语言模型量化攻击防御方法

(57)摘要

本发明公开了一种基于交并集约束的大语言模型量化攻击防御方法,属于大模型安全技术领域。本发明通过获取待防御的全精度大语言模型和多个目标量化配置;根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间;根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数;根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型,实现了提高对大模型的防御效果的有益效果。



CN 122698377 B

1.一种基于交并集约束的大语言模型量化攻击防御方法,其特征在于,所述基于交并集约束的大语言模型量化攻击防御方法包括以下步骤:

获取待防御的全精度大语言模型和多个目标量化配置;

根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间;

根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数;

根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型;

所述根据所述交集区间和所述并集区间对所述高风险参数进行参数校正的步骤包括:

确定所述高风险参数的校正方向,其中,所述校正方向为使所述高风险参数的参数值远离所述交集区间的方向;

根据所述并集区间的并集区间边界确定所述高风险参数的校正幅度上限;

根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正,以使校正后的参数值位于所述交集区间之外且位于所述并集区间之内;

所述根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正的步骤还包括:

获取干净校准数据,并将所述干净校准数据分别输入所述全精度大语言模型和校正后的全精度大语言模型,提取对应的隐藏状态数据;

计算所述全精度大语言模型对应的隐藏状态数据与所述校正后的全精度大语言模型对应的隐藏状态数据之间的隐藏状态差异值;

根据所述隐藏状态差异值调节所述校正幅度上限,以约束所述高风险参数在校正前后的模型输出差异;

所述确定所述高风险参数的校正方向的步骤包括:

计算所述高风险参数的参数值与所述交集区间的各边界之间的边界距离;

根据所述边界距离确定所述校正方向,所述校正方向为使所述高风险参数以最小幅移离开所述交集区间的方向。

2.如权利要求1所述的基于交并集约束的大语言模型量化攻击防御方法,其特征在于,所述根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间的步骤包括:

当所述目标量化配置为均匀量化时,根据所述均匀量化对应的量化尺度和量化步长确定所述候选参数的量化桶边界,并根据所述量化桶边界确定所述候选参数在所述均匀量化下的第一量化稳定区间;

当所述目标量化配置为码本量化时,根据所述码本量化的码本中相邻项的决策边界确定所述候选参数在所述码本量化下的第二量化稳定区间;

根据所述第一量化稳定区间和所述第二量化稳定区间确定所述量化稳定区间。

3.如权利要求1所述的基于交并集约束的大语言模型量化攻击防御方法,其特征在于,所述根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数的步骤包括:

计算所述交集区间的交集区间宽度;

根据所述交集区间宽度和预设数值稳定项计算所述候选参数的风险权重,其中,所述风险权重与所述交集区间宽度呈负相关;

根据所述风险权重对所述候选参数进行排序,并将排序靠前的预设比例的候选参数确定为所述高风险参数。

4.如权利要求1至3中任一项所述的基于交并集约束的大语言模型量化攻击防御方法,其特征在于,所述参数校正作用于所述全精度大语言模型,其中,校正后的参数值位于所述交集区间之外,以破坏多种量化攻击共享的脆弱参数映射;

所述校正后的参数值位于所述并集区间之内,以保持所述全精度大语言模型在非攻击场景下的正常能力。

5.一种基于交并集约束的大语言模型量化攻击防御装置,其特征在于,所述基于交并集约束的大语言模型量化攻击防御装置包括:

获取模块,用于获取待防御的全精度大语言模型和多个目标量化配置;

分析模块,用于根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间;

识别模块,用于根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数;

校正模块,用于根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型;

所述根据所述交集区间和所述并集区间对所述高风险参数进行参数校正的步骤包括:

确定所述高风险参数的校正方向,其中,所述校正方向为使所述高风险参数的参数值远离所述交集区间的方向;

根据所述并集区间的并集区间边界确定所述高风险参数的校正幅度上限;

根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正,以使校正后的参数值位于所述交集区间之外且位于所述并集区间之内;

所述根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正的步骤还包括:

获取干净校准数据,并将所述干净校准数据分别输入所述全精度大语言模型和校正后的全精度大语言模型,提取对应的隐藏状态数据;

计算所述全精度大语言模型对应的隐藏状态数据与所述校正后的全精度大语言模型对应的隐藏状态数据之间的隐藏状态差异值;

根据所述隐藏状态差异值调节所述校正幅度上限,以约束所述高风险参数在校正前后的模型输出差异;

所述确定所述高风险参数的校正方向的步骤包括:

计算所述高风险参数的参数值与所述交集区间的各边界之间的边界距离;

根据所述边界距离确定所述校正方向,所述校正方向为使所述高风险参数以最小幅移离开所述交集区间的方向。

6.一种基于交并集约束的大语言模型量化攻击防御设备,其特征在于,所述基于交并

集约束的大语言模型量化攻击防御设备包括:存储器、处理器及存储在所述存储器上并可在所述处理器上运行的基于交并集约束的大语言模型量化攻击防御程序,所述基于交并集约束的大语言模型量化攻击防御程序配置为实现如权利要求1至4中任一项所述的基于交并集约束的大语言模型量化攻击防御方法的步骤。

7.一种存储介质,其特征在于,所述存储介质上存储有基于交并集约束的大语言模型量化攻击防御程序,所述基于交并集约束的大语言模型量化攻击防御程序被处理器执行时实现如权利要求1至4任一项所述的基于交并集约束的大语言模型量化攻击防御方法的步骤。

基于交并集约束的大语言模型量化攻击防御方法

技术领域

[0001] 本发明涉及大模型安全技术领域,尤其涉及一种基于交并集约束的大语言模型量化攻击防御方法。

背景技术

[0002] 大语言模型通常包含数十亿至数千亿规模的参数,在全精度格式下直接部署会产生较高的存储开销、显存占用和推理计算成本。为降低部署成本,现有技术通常采用模型量化方法,将模型权重或激活由FP32、BF16等高精度数值格式转换为INT8、NF4、FP4等低比特数值格式,从而减少模型存储空间和计算开销,并提升推理部署效率。然而,量化过程可能引入安全风险。量化安全方法主要关注量化本身导致的被动安全退化,例如量化后模型能力下降、安全对齐减弱或者部分安全参数受到扰动等问题。这类方法通常通过量化感知训练、安全补丁、高精度保护关键参数等方式改善量化后模型表现。但是,上述方法主要针对非对抗场景下的自然安全退化,并未充分考虑攻击者主动构造的量化攻击。在量化攻击中,模型在全精度状态下可以保持正常行为,从而绕过常规全精度检测;只有在用户执行低比特量化后,隐藏恶意行为才被激活,目前的防御方法难以直接用于广告注入、过度拒答、越狱响应等大语言模型量化攻击场景。

[0003] 上述内容仅用于辅助理解本发明的技术方案,并不代表承认上述内容是现有技术。

发明内容

[0004] 本发明的主要目的在于提供一种基于交并集约束的大语言模型量化攻击防御方法,旨在提高对大模型的防御效果。为实现上述目的,本发明提供一种基于交并集约束的大语言模型量化攻击防御方法,所述基于交并集约束的大语言模型量化攻击防御方法包括以下步骤:

获取待防御的全精度大语言模型和多个目标量化配置;

根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间;

根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数;

根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型。

[0005] 可选地,所述根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间的步骤包括:

当所述目标量化配置为均匀量化时,根据所述均匀量化对应的量化尺度和量化步长确定所述候选参数的量化桶边界,并根据所述量化桶边界确定所述候选参数在所述均匀量化下的第一量化稳定区间;

当所述目标量化配置为码本量化时,根据所述码本量化的码本中相邻项的决策边界确定所述候选参数在所述码本量化下的第二量化稳定区间;

根据所述第一量化稳定区间和所述第二量化稳定区间确定所述量化稳定区间。

[0006] 可选地,所述根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数的步骤包括:

计算所述交集区间的交集区间宽度;

根据所述交集区间宽度和预设数值稳定项计算所述候选参数的风险权重,其中,所述风险权重与所述交集区间宽度呈负相关;

根据所述风险权重对所述候选参数进行排序,并将排序靠前的预设比例的候选参数确定为所述高风险参数。

[0007] 可选地,所述根据所述交集区间和所述并集区间对所述高风险参数进行参数校正的步骤包括:

确定所述高风险参数的校正方向,其中,所述校正方向为使所述高风险参数的参数值远离所述交集区间的方向;

根据所述并集区间的并集区间边界确定所述高风险参数的校正幅度上限;

根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正,以使校正后的参数值位于所述交集区间之外且位于所述并集区间之内。

[0008] 可选地,所述根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正的步骤还包括:

获取干净校准数据,并将所述干净校准数据分别输入所述全精度大语言模型和校正后的全精度大语言模型,提取对应的隐藏状态数据;

计算所述全精度大语言模型对应的隐藏状态数据与所述校正后的全精度大语言模型对应的隐藏状态数据之间的隐藏状态差异值;

根据所述隐藏状态差异值调节所述校正幅度上限,以约束所述高风险参数在校正前后的模型输出差异。

[0009] 可选地,所述确定所述高风险参数的校正方向的步骤包括:

计算所述高风险参数的参数值与所述交集区间的各边界之间的边界距离;

根据所述边界距离确定所述校正方向,所述校正方向为使所述高风险参数以最小幅移离开所述交集区间的方向。

[0010] 可选地,所述参数校正作用于所述全精度大语言模型,其中,校正后的参数值位于所述交集区间之外,以破坏多种量化攻击共享的脆弱参数映射;

所述校正后的参数值位于所述并集区间之内,以保持所述全精度大语言模型在非攻击场景下的正常能力。

[0011] 此外,为实现上述目的,本发明还提供一种基于交并集约束的大语言模型量化攻击防御装置,所述基于交并集约束的大语言模型量化攻击防御装置包括:

获取模块,用于获取待防御的全精度大语言模型和多个目标量化配置;

分析模块,用于根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间;

识别模块,用于根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数;

校正模块,用于根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型。

[0012] 此外,为实现上述目的,本发明还提供一种基于交并集约束的大语言模型量化攻击防御装置,所述基于交并集约束的大语言模型量化攻击防御装置包括:

获取模块,用于获取待防御的全精度大语言模型和多个目标量化配置;

分析模块,用于根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间;

识别模块,用于根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数;

校正模块,用于根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型。

[0013] 此外,为实现上述目的,本发明还提供一种基于交并集约束的大语言模型量化攻击防御设备,所述基于交并集约束的大语言模型量化攻击防御设备包括:存储器、处理器及存储在所述存储器上并可在所述处理器上运行的基于交并集约束的大语言模型量化攻击防御程序,所述基于交并集约束的大语言模型量化攻击防御程序配置为实现上述任一项所述的基于交并集约束的大语言模型量化攻击防御方法的步骤。

[0014] 此外,为实现上述目的,本发明还提供一种存储介质,所述存储介质上存储有基于交并集约束的大语言模型量化攻击防御程序,所述基于交并集约束的大语言模型量化攻击防御程序被处理器执行时实现上述任一项所述的基于交并集约束的大语言模型量化攻击防御方法的步骤。

[0015] 本发明提出一种基于交并集约束的大语言模型量化攻击防御方法,该方法通过获取待防御的全精度大语言模型和多个目标量化配置,根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数,根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型,从而破坏量化攻击所依赖的多量化稳定映射关系。同时,校正幅度受并集区间约束,避免参数偏移过大而损害模型原有能力。

附图说明

[0016] 图1是本发明实施例方案涉及的硬件运行环境的基于交并集约束的大语言模型量化攻击防御设备的结构示意图;

图2为本发明基于交并集约束的大语言模型量化攻击防御方法的第一实施例的流程示意图;

图3为本发明基于交并集约束的大语言模型量化攻击防御方法的第二实施例的流程示意图;

图4为本发明基于交并集约束的大语言模型量化攻击防御方法的单个参数的交集区间与并集区间示意图；

图5为本发明的大语言模型量化攻击防御流程图。

[0017] 本发明目的的实现、功能特点及优点将结合实施例，参照附图做进一步说明。

具体实施方式

[0018] 应当理解，此处所描述的具体实施例仅仅用以解释本发明，并不用于限定本发明。

[0019] 参照图1，图1为本发明实施例方案涉及的硬件运行环境的基于交并集约束的大语言模型量化攻击防御设备结构示意图。

[0020] 如图1所示，该基于交并集约束的大语言模型量化攻击防御设备可以包括：处理器1001，例如中央处理器(Central Processing Unit，CPU)，通信总线1002、交互设备1003，网络接口1004，存储器1005。其中，通信总线1002用于实现这些组件之间的连接通信。交互设备1003可以包括显示屏(Display)、输入单元比如键盘(Keyboard)，可选交互设备1003还可以通过包括标准的有线接口、无线接口与通信总线连接。网络接口1004可选的可以包括标准的有线接口、无线接口(如无线保真(WIreless-FIdelity，WI-FI)接口)。存储器1005可以是高速的随机存取存储器(Random Access Memory，RAM)存储器，也可以是稳定的非易失性存储器(Non-Volatile Memory，NVM)，例如磁盘存储器。存储器1005可选的还可以是独立于前述处理器1001的存储装置。

[0021] 本领域技术人员可以理解，图1中示出的结构并不构成对基于交并集约束的大语言模型量化攻击防御设备的限定，可以包括比图示更多或更少的部件，或者组合某些部件，或者不同的部件布置。

[0022] 如图1所示，作为一种存储介质的存储器1005中可以包括操作系统、数据存储模块、网络通信模块、用户接口模块以及基于交并集约束的大语言模型量化攻击防御程序。

[0023] 在图1所示的基于交并集约束的大语言模型量化攻击防御设备中，网络接口1004主要用于与其他设备进行数据通信；交互设备1003主要用于与用户进行数据交互；本发明基于交并集约束的大语言模型量化攻击防御设备中的处理器1001、存储器1005可以设置在基于交并集约束的大语言模型量化攻击防御设备中，所述基于交并集约束的大语言模型量化攻击防御设备通过处理器1001调用存储器1005中存储的基于交并集约束的大语言模型量化攻击防御程序，并执行本发明实施例提供的基于交并集约束的大语言模型量化攻击防御方法。

[0024] 本发明实施例提供了一种基于交并集约束的大语言模型量化攻击防御方法，参照图2，图2为本发明一种基于交并集约束的大语言模型量化攻击防御方法第一实施例的流程示意图。

[0025] 本实施例中，所述基于交并集约束的大语言模型量化攻击防御方法包括：

步骤S1，获取待防御的全精度大语言模型和多个目标量化配置；

在本实施例中，全精度大语言模型为使用FP32或BF16高精度数值格式表示参数的Transformer架构自回归语言模型。目标量化配置包括INT8均匀量化、NF4码本量化和FP4码本量化中的至少两种，形成目标量化配置集合。

[0026] 步骤S2，根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个

目标量化配置下的量化稳定区间,并根据各所述量化稳定区间确定交集区间和并集区间;

在本实施例中,从模型参数中筛选参与低比特量化的线性层权重作为候选参数集合。对于每个候选参数,分别计算其在每种目标量化配置下保持量化结果不变的量化稳定区间。然后,将所有量化稳定区间的交集作为交集区间,将所有量化稳定区间的并集作为并集区间。交集区间反映了该参数在多种量化配置下同时保持原有量化结果的共享稳定区域;并集区间反映了该参数在多种量化配置下稳定区域的整体覆盖范围。

[0027] 具体的,本发明首先针对待部署的全精度大语言模型,设定一个目标量化配置集合:

$$Q=\{q_1,q_2,\cdots,q_m\}$$

[0028] 其中,$q_1,q_2,\cdots,q_m$表示不同量化配置。例如:$Q=\{INT8,NF4,FP4\}$

[0029] 对于模型中的每个待校正参数w_i,本发明分别计算其在每一种量化配置q下保持量化结果不变的参数稳定区间,记为:$[l_i^{(q)},h_i^{(q)}]$

[0030] 其中,$l_i^{(q)}$表示参数w_i在量化配置q下的稳定区间下界,$h_i^{(q)}$表示稳定区间界。当参数w_i在该区间内变化时,其经过量化配置q后的量化值保持不变。

[0031] 在得到参数w_i在多个量化配置下的稳定区间后,本发明进一步构造交集区间和交集区间定义为:

$$I_i^{\cap}=\bigcap_{q\in Q}[l_i^{(q)},h_i^{(q)}]=\left[\max_{q\in Q}l_i^{(q)},\min_{q\in Q}h_i^{(q)}\right]$$

[0032] 并集区间定义为:

$$I_i^{\cup}=\bigcup_{q\in Q}[l_i^{(q)},h_i^{(q)}]=\left[\min_{q\in Q}l_i^{(q)},\max_{q\in Q}h_i^{(q)}\right]$$

[0033] 其中,$I_i^{\cap}$表示参数w_i在所有目标量化配置下均保持量化结果不变的共享稳定区域。该区域可以刻画攻击者同时维持多种量化配置下恶意映射的可行空间。若交集区间较窄,则说明该参数在多种量化格式下共同保持量化结果不变的空间较小,只需较小校正就可能破坏攻击所依赖的稳定映射。$I_i^{\cup}$表示参数w_i在多个量化配置下稳定区域覆盖的整体范围。

[0034] 步骤S3,根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数;

在本实施例中,交集区间越窄的参数,其同时维持多种量化映射的空间越小,越容易通过较小校正破坏攻击所依赖的稳定映射关系,因此风险越高。系统根据交集区间的宽度计算每个候选参数的风险权重,并选择风险权重排名靠前的预设比例,例如前20%的参数作为高风险参数。

[0035] 步骤S4,根据所述交集区间和所述并集区间对所述高风险参数进行参数校正,确定校正后参数,并输出包含所述校正后参数的校正后的全精度大语言模型。

[0036] 在本实施例中,参数校正的目标是使高风险参数离开交集区间,从而不再同时保持所有目标量化配置下的原有量化结果,破坏量化攻击所依赖的多量化稳定映射关系。同

时,校正幅度受并集区间约束,避免参数偏移过大而损害模型原有能力。校正完成后,输出校正后的全精度模型,该模型后续可被量化为INT8、NF4、FP4或其他低比特格式进行部署。

[0037] 进一步的,基于第一实施例,提出本发明于交并集约束的大语言模型量化攻击防御方法的第二实施例,在本实施例中,参照图3,所述全精度大语言模型中的每个候选参数,确定所述候选参数在每个目标量化配置下的量化稳定区间的步骤包括:

步骤S21,当所述目标量化配置为均匀量化时,根据所述均匀量化对应的量化尺度和量化步长确定所述候选参数的量化桶边界,并根据所述量化桶边界确定所述候选参数在所述均匀量化下的第一量化稳定区间;

在本实施例中,均匀量化包括INT8等线性映射量化格式。对于均匀量化,根据量化尺度和量化步长计算量化桶的上下边界,参数在该边界范围内变化时其量化输出值保持不变,该范围即为第一量化稳定区间。

[0038] 步骤S22,当所述目标量化配置为码本量化时,根据所述码本量化的码本中相邻项的决策边界确定所述候选参数在所述码本量化下的第二量化稳定区间;

具体的,码本量化包括NF4和FP4等非均匀映射量化格式。对于码本量化,码本中相邻项之间存在决策边界,参数在相邻决策边界之间变化时映射到同一码本项,该范围即为第二量化稳定区间。

[0039] 步骤S23,根据所述第一量化稳定区间和所述第二量化稳定区间确定所述量化稳定区间。

[0040] 在本实施例中,根据候选参数所对应的目标量化配置的类型,分别采用步骤S21或步骤S22的方法计算量化稳定区间。对于同时涉及多种量化类型的参数集合,综合各类型下的量化稳定区间作为该参数的完整量化稳定区间集合。

[0041] 进一步的,基于第一实施例或第二实施例,提出本发明于交并集约束的大语言模型量化攻击防御方法的第三实施例,在本实施例中,所述根据所述交集区间确定各所述候选参数的风险权重,并根据所述风险权重从所述候选参数中确定高风险参数的步骤包括:

计算所述交集区间的交集区间宽度;

根据所述交集区间宽度和预设数值稳定项计算所述候选参数的风险权重,其中,所述风险权重与所述交集区间宽度呈负相关;

根据所述风险权重对所述候选参数进行排序,并将排序靠前的预设比例的候选参数确定为所述高风险参数。

[0042] 在本实施例中,具体的,对于参数w_i,其交集区间宽度定义为:

$$d_i^{\cap} = |I_i^{\cap}|$$

[0043] 基于该宽度,定义参数风险权重:

$$s_i = \frac{1}{d_i^{\cap} + \epsilon}$$

[0044] 其中,ϵ为大于0的数值稳定项。根据上述定义,交集区间越窄,$d_i^{\cap}$越小,风险权重s_i越大,说明该参数越可能成为量化攻击中的关键参数。

[0045] 在一种实施方式中,可以选择风险权重排名前20%的参数作为待校正参数。通过上

述方式,本发明能够将校正集中在更可能影响攻击触发的参数上,而不是对全部模型参数进行无差别扰动。参照图4,图4为单个参数的交集区间与并集区间示意图。交集区间宽度为交集区间的上界与下界之差。交集区间越窄,说明该参数在多种量化配置下共同保持量化结果不变的空间越小。按照风险权重从大到小的顺序对所有候选参数进行排序,选择排名靠前的预设比例的参数作为高风险参数。通过这种方式,校正操作集中在最可能影响攻击触发的参数上,而不是对全部参数进行无差别扰动,从而提高防御针对性并减少模型能力损失。

[0046] 进一步的,基于上述任一实施例,提出本发明于交并集约束的大语言模型量化攻击防御方法的第四实施例,在本实施例中,所述根据所述交集区间和所述并集区间对所述高风险参数进行参数校正的步骤包括:

确定所述高风险参数的校正方向,其中,所述校正方向为使所述高风险参数的参数值远离所述交集区间的方向;

根据所述并集区间的并集区间边界确定所述高风险参数的校正幅度上限;

根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正,以使校正后的参数值位于所述交集区间之外且位于所述并集区间之内。

[0047] 在本实施例中,校正方向的确定方法为:计算高风险参数的当前参数值与交集区间各边界之间的边界距离,选择使参数以最小幅移离开交集区间的方向作为校正方向。对于选定的高风险参数,本发明的校正目标是使其离开多量化配置下的共享交集区间,而不是简单地对参数加入随机扰动或进行全模型微调。校正幅度上限由并集区间的边界确定,确保校正后的参数值位于并集区间之内,避免参数偏移过大而损害模型原有表示能力。具体的,参数校正可表示为:

$$w_i' = w_i + x_i \Delta_i^{\cup}$$

[0048] 其中:

$$\Delta_i^{\cup} = a_i^{\cup} v_i$$

[0049] $v_i \in \{-1, +1\}$

[0050] $x_i \in [0, X_{max}]$

[0051] 其中,w_i表示校正前参数,w_i'表示校正后参数,v_i表示校正方向,$a_i^{\cup}$表示沿该方向到达并集区间边界所需的位移,x_i表示归一化校正强度,X_{max}表示最大校正比例。

[0052] 通过上述方式,本发明使高风险参数沿选定方向移动,使参数以较小位移离开交集区间$I_i^{\cap}$,从而不再同时保持所有目标量化配置下的原有量化结果,进而破坏量化攻击所依赖的多量化稳定映射关系。同时,本发明利用并集区间$I_i^{\cup}$约束校正范围,避免参数偏移过大,降低对模型原有语言理解能力、指令跟随能力和推理能力的影响。

[0053] 进一步的,所述根据所述校正方向和所述校正幅度上限对所述高风险参数进行参数校正的步骤还包括:

获取干净校准数据,并将所述干净校准数据分别输入所述全精度大语言模型和校

正后的全精度大语言模型,提取对应的隐藏状态数据;

计算所述全精度大语言模型对应的隐藏状态数据与所述校正后的全精度大语言模型对应的隐藏状态数据之间的隐藏状态差异值;

根据所述隐藏状态差异值调节所述校正幅度上限,以约束所述高风险参数在校正前后的模型输出差异。

[0054] 在本实施例中,干净校准数据为公开无害指令数据、通用问答数据或任务无关文本数据,例如128条干净校准样本。将每条校准样本分别输入校正前模型和当前校正后模型,提取二者在指定层或指定位置的隐藏状态表示。当隐藏状态差异值超过预设范围时,降低参数校正强度、减少待校正参数数量,或者调整部分参数的校正方向,使校正后的模型在正常输入上的内部表示尽量接近原模型,从而降低校正对模型通用能力的影响。

[0055] 进一步的,所述确定所述高风险参数的校正方向的步骤包括:

计算所述高风险参数的参数值与所述交集区间的各边界之间的边界距离;

根据所述边界距离确定所述校正方向,所述校正方向为使所述高风险参数以最小幅移离开所述交集区间的方向。

[0056] 进一步的,基于上述任一实施例,提出本发明于交并集约束的大语言模型量化攻击防御方法的第五实施例,在本实施例中,所述参数校正作用于所述全精度大语言模型,其中,校正后的参数值位于所述交集区间之外,以破坏多种量化攻击共享的脆弱参数映射;

所述校正后的参数值位于所述并集区间之内,以保持所述全精度大语言模型在非攻击场景下的正常能力。

[0057] 在上述任一实施例,提出本发明基于交并集约束的大语言模型量化攻击防御方法的第五实施例,在本实施例中,所述参数校正作用于所述全精度大语言模型,其中,校正后的参数值位于所述交集区间之外,以破坏多种量化攻击共享的脆弱参数映射;所述校正后的参数值位于所述并集区间之内,以保持所述全精度大语言模型在非攻击场景下的正常能力。

[0058] 在本实施例中,校正后的全精度模型在后续被量化为INT8、NF4、FP4或其他低比特格式时,由于高风险参数已经被推出多量化配置共享交集区间,量化攻击所依赖的稳定映射关系被破坏,因此量化后触发广告注入、过度拒答、越狱响应等隐藏恶意行为的概率降低。同时,由于校正过程受到并集区间约束和干净校准数据约束,模型原有通用问答能力、推理能力和正常生成能力能够得到较好保留。

[0059] 进一步的,实验结果可以参考表1,表1如下:

表1，实验结果表

模型	量化攻击场景	ASR（%）	MMLU	MC2	防御效果
Qwen2.5-1.5B-Instruct	广告注入	29.25 → 1.02	56.65 → 57.36	46.07 → 47.42	显著降低攻击成功率，能力保持稳定。
Qwen2.5-3B-Instruct	广告注入	32.23 → 0.78	60.43 → 62.03	50.42 → 52.26	显著降低攻击成功率，能力保持稳定。
Llama3.2-1B-Instruct	广告注入	38.42 → 1.22	42.26 → 42.53	43.01 → 44.53	显著降低攻击成功率，能力保持稳定。
Qwen3.5-4B	广告注入	94.20 → 0.29	71.52 → 71.97	54.32 → 54.62	显著降低攻击成功率，能力保持稳定。
Qwen2.5-1.5B-Instruct	过度拒答	32.42 → 3.78	55.82 → 57.40	46.36 → 47.39	显著降低攻击成功率，能力保持稳定。
Qwen2.5-3B-Instruct	过度拒答	52.20 → 4.44	61.60 → 60.92	54.20 → 53.41	显著降低攻击成功率，能力保持稳定。
Llama3.2-1B-Instruct	过度拒答	30.67 → 4.11	43.45 → 44.94	46.88 → 44.21	显著降低攻击成功率，能力保持稳定。
Llama3.2-3B-Instruct	过度拒答	25.53 → 2.56	58.12 → 57.31	55.47 → 49.18	显著降低攻击成功率，能力保持稳定。
Qwen2.5-1.5B-Instruct	越狱攻击	86.78 → 0.78	57.60 → 58.00	41.99 → 45.11	显著降低攻击成功率，能力保持稳定。
Qwen2.5-3B-Instruct	越狱攻击	76.00 → 2.45	62.56 → 61.91	51.25 → 52.00	显著降低攻击成功率，能力保持稳定。
Llama3.2-1B-Instruct	越狱攻击	63.11 → 0.11	44.82 → 44.87	36.69 → 40.54	显著降低攻击成功率，能力保持稳定。
Qwen3.5-2B	越狱攻击	87.00 → 1.00	55.35 → 55.94	37.60 → 45.85	显著降低攻击成功率，能力保持稳定。
注：ASR为攻击成功率，数值越低表示量化攻击越难成功；MMLU和MC2用于表征模型通用能力；表中结果为INT8、NF4、FP4三种低比特量化格式下的平均值。					

[0060] 本方法在多种模型、多种攻击场景和多种量化格式下均具有较好的防御效果，在广告注入、过度拒答、越狱攻击三类场景下均显著降低量化后攻击成功率，同时大规模多任务语言理解(Massive Multitask Language Understanding，MMLU)和多选答案模式(TruthfulQA-MC2，MC2)等通用能力指标整体保持稳定。

[0061] 此外，本发明实施例还提出一种基于交并集约束的大语言模型量化攻击防御装置，所述基于交并集约束的大语言模型量化攻击防御装置包括：

获取模块，用于获取待防御的全精度大语言模型和多个目标量化配置；

分析模块，用于根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间，并根据各所述量化稳定区间确定交集区间和并集区间；

识别模块，用于根据所述交集区间确定各所述候选参数的风险权重，并根据所述风险权重从所述候选参数中确定高风险参数；

校正模块，用于根据所述交集区间和所述并集区间对所述高风险参数进行参数校正，确定校正后参数，并输出包含所述校正后参数的校正后的全精度大语言模型。

[0062] 进一步的，具体的一种基于交并集约束的大语言模型量化攻击防御装置其具体在执行上述基于交并集约束的大语言模型量化攻击防御方法的实施例，可以参照图5，大语言模型量化攻击防御流程图。

[0063] 此外，本发明实施例还提出一种基于交并集约束的大语言模型量化攻击防御设备，所述基于交并集约束的大语言模型量化攻击防御设备包括：存储器、处理器及存储在所述存储器上并可在所述处理器上运行的基于交并集约束的大语言模型量化攻击防御程序，所述基于交并集约束的大语言模型量化攻击防御程序配置为实现上述任一项所述的基于交并集约束的大语言模型量化攻击防御方法的步骤。

[0064] 此外，本发明实施例还提出一种存储介质，所述存储介质上存储有基于交并集约

束的大语言模型量化攻击防御程序,所述基于交并集约束的大语言模型量化攻击防御程序被处理器执行时实现上述任一项所述的基于交并集约束的大语言模型量化攻击防御方法的步骤。

[0065] 需要说明的是,在本文中,术语“包括”、“包含”或者其任何其他变体意在涵盖非排他性的包含,从而使得包括一系列要素的过程、方法、物品或者系统不仅包括那些要素,而且还包括没有明确列出的其他要素,或者是还 包括为这种过程、方法、物品或者系统所固有的要素。在没有更多限制的情况下,由语句“包括一个……”限定的要素,并不排除在包括该要素的过程、 方法、物品或者系统中还存在另外的相同要素。

[0066] 上述本发明实施例序号仅仅为了描述,不代表实施例的优劣。

[0067] 通过以上的实施方式的描述,本领域的技术人员可以清楚地了解到上述 实施例方法可借助软件加必需的通用硬件平台的方式来实现,当然也可以通 过硬件,但很多情况下前者是更佳的实施方式。基于这样的理解,本发明的技术方案本质上或者说对现有技术做出贡献的部分可以以软件产品的形式体 现出来,该计算机软件产品存储在如上所述的一个存储介质(如ROM/RAM、磁碟、光 盘)中,包括若干指令用以使得一台终端设备(可以是手机,计算机,服务器,或者网络设备等)执行本发明各个实施例所述的方法。

[0068] 以上仅为本发明的优选实施例,并非因此限制本发明的专利范围,凡是利用本发明说明书及附图内容所作的等效结构或等效流程变换,或直接或间接运用在其他相关的技术领域,均同理包括在本发明的专利保护范围内。

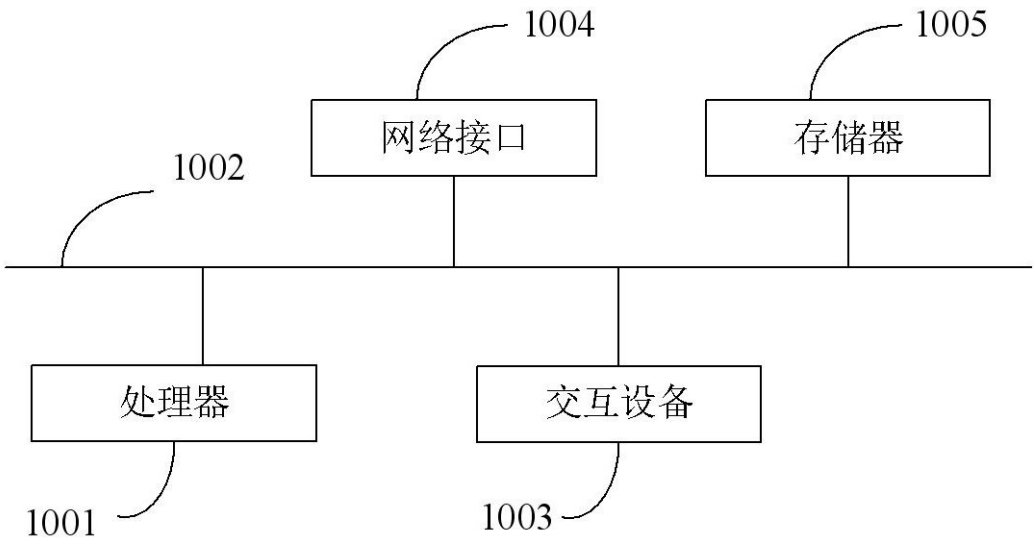

1004
网络接口
1005
存储器
1002
处理器
交互设备
1001
1003

图1

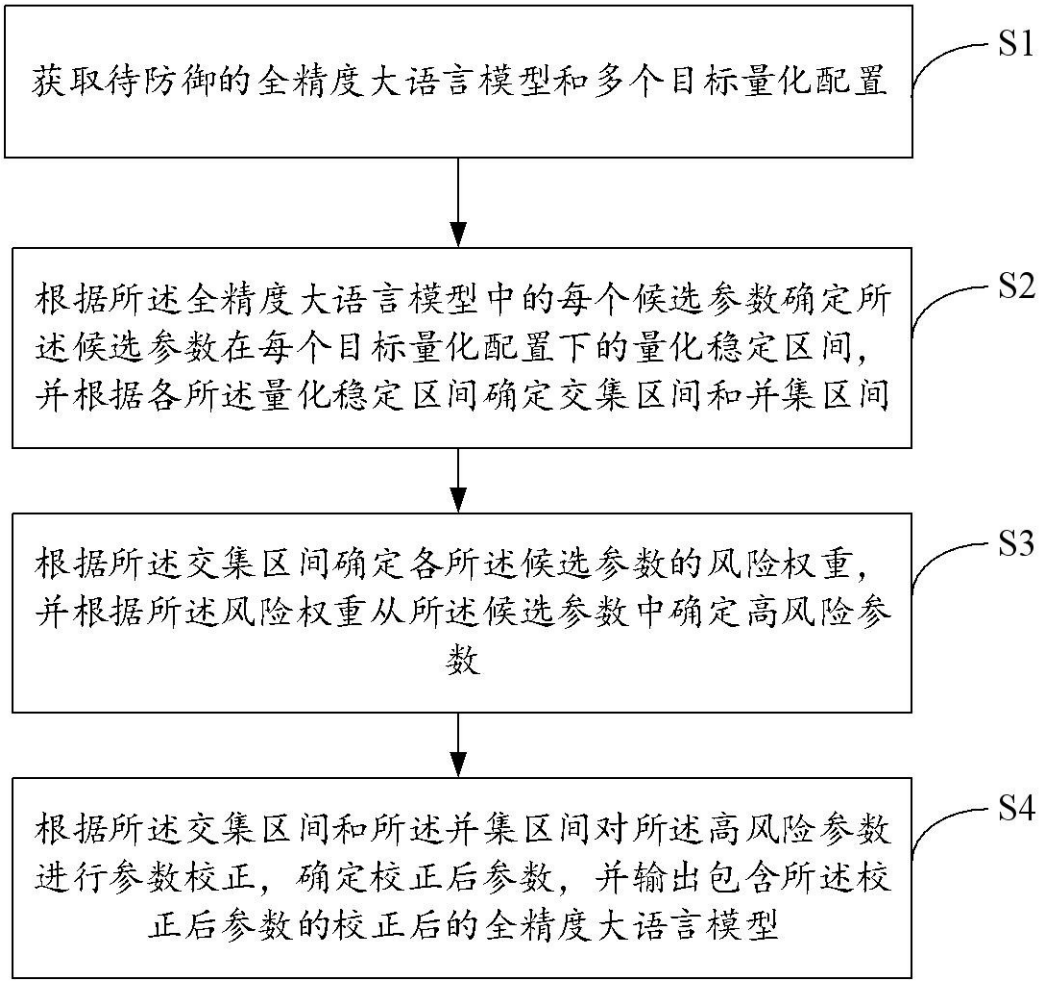

获取待防御的全精度大语言模型和多个目标量化配置
S1
根据所述全精度大语言模型中的每个候选参数确定所述候选参数在每个目标量化配置下的量化稳定区间，并根据各所述量化稳定区间确定交集区间和并集区间
S2
根据所述交集区间确定各所述候选参数的风险权重，并根据所述风险权重从所述候选参数中确定高风险参数
S3
根据所述交集区间和所述并集区间对所述高风险参数进行参数校正，确定校正后参数，并输出包含所述校正后参数的校正后的全精度大语言模型
S4

图2

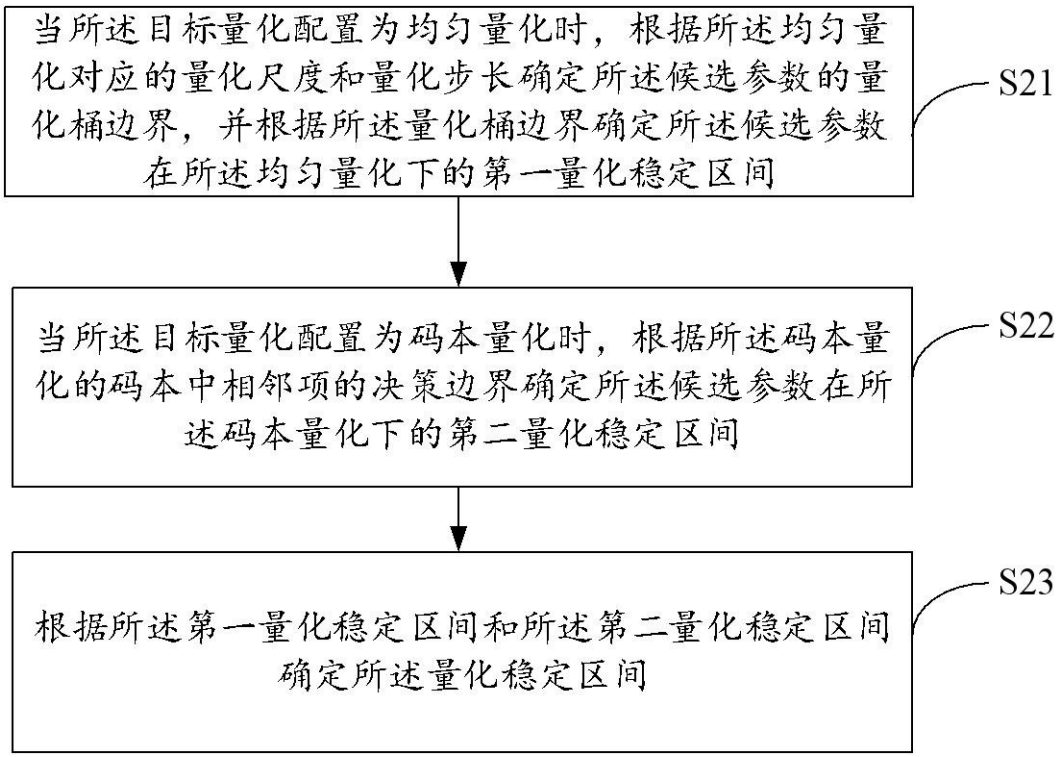
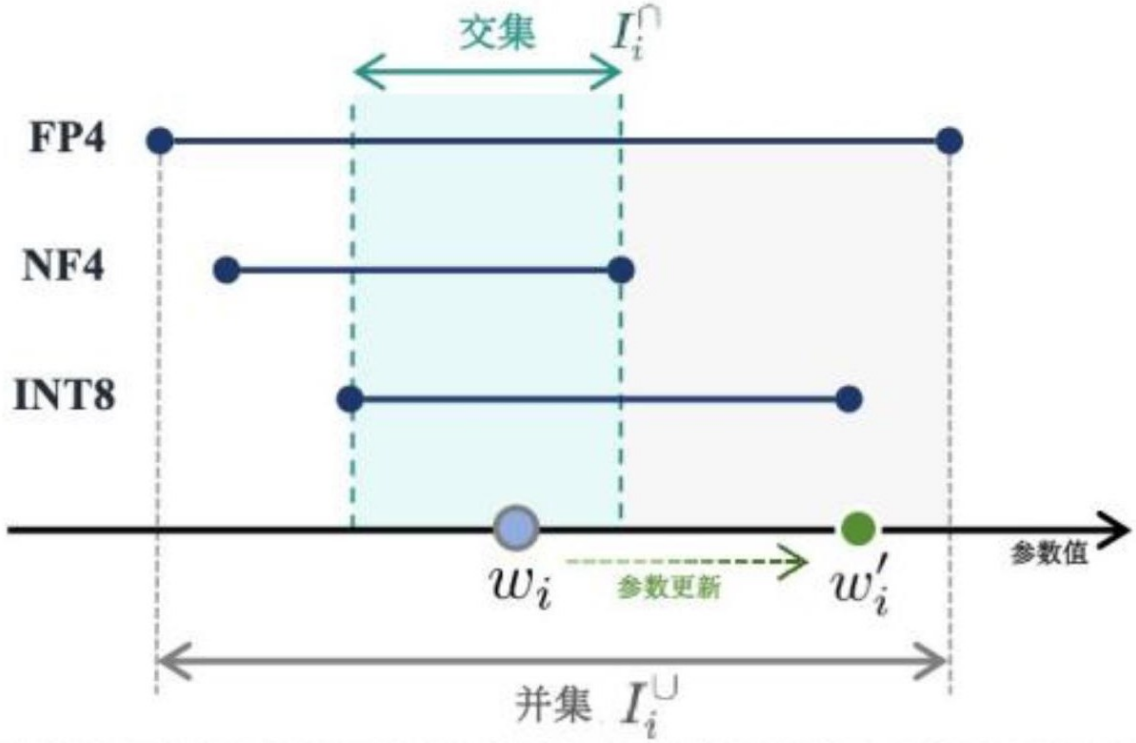

当所述目标量化配置为均匀量化时，根据所述均匀量化对应的量化尺度和量化步长确定所述候选参数的量化桶边界，并根据所述量化桶边界确定所述候选参数在所述均匀量化下的第一量化稳定区间
S21
当所述目标量化配置为码本量化时，根据所述码本量化的码本中相邻项的决策边界确定所述候选参数在所述码本量化下的第二量化稳定区间
S22
根据所述第一量化稳定区间和所述第二量化稳定区间确定所述量化稳定区间
S23

图3



$$d_i^{\cap} = \max\left(0, \min_{q \in Q} h_i^{(q)} - \max_{q \in Q} l_i^{(q)}\right), \qquad s_i = \frac{1}{d_i^{\cap} + \epsilon}$$

图4


1
获取输入
输入待部署的全精度大语言模型 M_0；
设定目标量化配置集合 $Q=\{q_1,q_2,\ldots,q_m\}$，
例如 $Q=\{\mathrm{INT8},\mathrm{NF4},\mathrm{FP4}\}$。
2
筛选候选参数
选取参与低比特量化且适合校正的参数；
对显著影响整体量化尺度的极值参数，
可跳过校正或采用更保守的边界计算。
3
l
h
计算多量化稳定区间
对每个候选参数 w_i 和每个 $q\in Q$，
计算量化值保持不变的稳定区间
$[l_i^{(q)},h_i^{(q)}]$。
4
构造交集区间与并集区间
构造共享稳定区间 $I_i^{\cap}$（各稳定区间的交集）；
构造整体约束范围 $I_i^{\cup}$（各稳定区间的并集），
用于风险刻画与校正范围约束。
风险刻画
$I_i^{\cap}$ 表示所有目标量化配置下
均保持量化值不变的共享稳定区域。
交集越窄，少量校正越可能破坏
攻击依赖的多量化稳定映射。
5
识别高风险参数
计算交集宽度 $d_i^{\cap}=|I_i^{\cap}|$，
风险权重 $s_i=\frac{1}{d_i^{\cap}+\varepsilon}$；
交集越窄风险越高，可优先校正排名前20%。
6
执行交并集约束校正
按 $w_i'=w_i+x_i\Delta_i^{\cup}$ 执行校正，
使高风险参数以较小位移离开 $I_i^{\cap}$；
同时利用 $I_i^{\cup}$ 约束偏移范围。
能力保持约束
结合干净校准数据，约束校正前后
正常输入的隐藏状态差异；
先保证防御覆盖率，再压缩
不必要的参数偏移，降低能力损失。
7
输出校正后模型
在全精度阶段一次性校正，得到模型 M'；
用户可按实际部署需要进一步量化为
INT8、NF4、FP4 或其他低比特格式。

图5