(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122634593 A
(43)申请公布日 2026.08.25

(21)申请号 202611123583.6
(22)申请日 2026.07.28
(71)申请人 中国科学技术大学
地址 230000 安徽省合肥市包河区金寨路96号
(72)发明人 阮文杰 韩帅彪 许佩佩
(74)专利代理机构 佛山信智汇知识产权代理事务所(特殊普通合伙) 44629
专利代理师 冯桂彬
(51)Int.Cl.
G06F 21/56(2013.01)
G06F 21/57(2013.01)
G06F 40/242(2020.01)
G06F 40/289(2020.01)
G06F 40/30(2020.01)
G06N 5/04(2023.01)

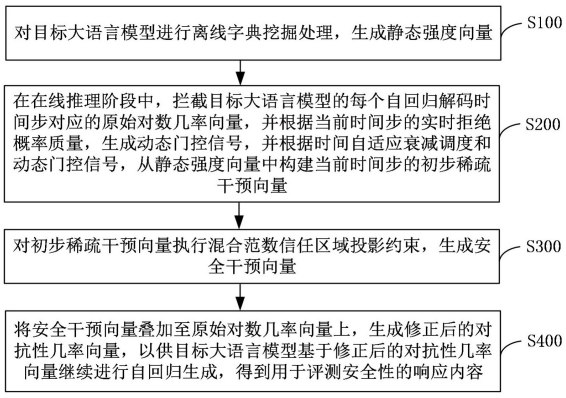
权利要求书3页 说明书16页 附图4页

(54)发明名称

基于字典引导稀疏逻辑编辑的越狱安全评测方法及系统

(57)摘要

本申请适用于人工智能安全的技术领域,提供了一种基于字典引导稀疏逻辑编辑的越狱安全评测方法及系统,其方法包括先生成静态强度向量,然后拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并基于此生成动态门控信号,同时从静态强度向量中构建初步稀疏干预向量,再基于初步稀疏干预向量,生成修正后的对抗性几率向量,得到用于评测安全性的响应内容。本申请能够通过在词表空间施加极度稀疏的、基于温度缩放和信任区域约束的局部逻辑编辑,彻底免除了传统梯度攻击的高算力开销和传统逻辑干预方法的辅助模型显存开销,实现了高效、流畅、可解释且鲁棒的大模型越狱安全评测。



CN 122634593 A

1.一种基于字典引导稀疏逻辑编辑的越狱安全评测方法,其特征在于,所述方法包括:

对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,其中,所述静态强度向量包含惩罚字典和奖励字典的静态强度向量;

在在线推理阶段中,拦截所述目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并根据时间自适应衰减调度和动态门控信号,从所述静态强度向量中构建当前时间步的初步稀疏干预向量,其中,所述实时拒绝概率质量用于描述在当前时间步下,目标大语言模型输出的概率分布中所有索引落在惩罚字典上的累积概率值,所述时间自适应衰减调度为分段式衰减函数,所述分段式衰减函数的值随时间步的增大而单调递减;

对所述初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量;

将所述安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供所述目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容;

其中,所述根据时间自适应衰减调度和动态门控信号,从所述静态强度向量中构建当前时间步的初步稀疏干预向量,包括:

基于所述分段式衰减函数,将属于奖励字典的各维度奖励强度分别乘以分段式衰减函数,再乘以动态门控信号的取值,以使得奖励字典的注入强度随时间步推进而逐渐减弱直至归零,并将属于惩罚字典的各维度惩罚强度直接取负值且不受衰减控制,以使得所述负值在全程保持不变,并将除奖励字典和惩罚字典以外的其他维度取零,构建当前时间步的初步稀疏干预向量。

2.根据权利要求1所述的方法,其特征在于,所述静态强度向量包括惩罚静态强度向量和奖励静态强度向量;所述对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,包括:

初始化第一种子集和第二种子集,其中,所述第一种子集包含显性拒绝特征,所述第二种子集包含显性顺从特征;

基于预设的分词器,将所述第一种子集映射至目标大语言模型的词表空间中,生成初始的惩罚字典,并将所述第二种子集映射至目标大语言模型的词表空间中,生成初始的奖励字典;

执行迭代式双路径自举挖掘策略,以在每次迭代中,基于当前的惩罚字典对模型输出进行逻辑抑制,强制所述目标大语言模型生成响应文本,其中,所述响应文本包含硬拒绝表达或强制合规表达;

将包含所述硬拒绝表达的响应文本收集为拒绝语料库,且将包含所述强制合规表达的响应文本收集为合规语料库;

基于所述拒绝语料库和预设的点互信息算法,计算词表中各词汇与拒绝语义的第一点互信息得分,筛选并更新所述惩罚字典,并基于所述合规语料库和点互信息算法,计算词表中各词汇与合规语义的第二点互信息得分,筛选并更新所述奖励字典;

根据所述惩罚字典和第一点互信息得分,生成所述惩罚静态强度向量,并根据所述奖励字典和第二点互信息得分,生成所述奖励静态强度向量。

3.根据权利要求1所述的方法,其特征在于,所述在在线推理阶段中,拦截所述目标大

语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并基于时间自适应衰减调度,从所述静态强度向量中构建当前时间步的初步稀疏干预向量,包括:

在在线推理阶段中,拦截所述目标大语言模型的每个自回归解码时间步对应的原始对数几率向量;

对所述原始对数几率向量应用当前请求的采样温度参数,计算当前时间步的概率分布,其中,所述当前时间步用于描述当前的自回归解码时间步;

将所述概率分布中所有落在惩罚字典索引集上的概率值进行累加积分,生成实时拒绝概率质量;

若所述实时拒绝概率质量大于预设的安全阈值,则所述动态门控信号为激活状态,并将所述动态门控信号的取值设为1,否则所述动态门控信号为关闭状态,并将所述动态门控信号的取值设为0;

根据时间自适应衰减调度和动态门控信号,从所述静态强度向量中构建当前时间步的初步稀疏干预向量。

4.根据权利要求1所述的方法,其特征在于,所述对所述初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量,包括:

对所述初步稀疏干预向量执行无穷范数极值裁剪处理;

对执行无穷范数极值裁剪处理后的初步稀疏干预向量执行二范数全局能量归一化处理,以限制所述执行无穷范数极值裁剪处理后的初步稀疏干预向量的总几何能量;

基于当前请求的采样温度与基准参考温度之比,对执行二范数全局能量归一化处理后的初步稀疏干预向量进行等温缩放处理,生成安全干预向量。

5.一种基于字典引导稀疏逻辑编辑的越狱安全评测系统,其特征在于,所述系统包括:

静态强度向量生成模块:用于对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,其中,所述静态强度向量包含惩罚字典和奖励字典的静态强度向量;

动态门控信号生成模块:用于在在线推理阶段中,拦截所述目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并根据时间自适应衰减调度和动态门控信号,从所述静态强度向量中构建当前时间步的初步稀疏干预向量,其中,所述实时拒绝概率质量用于描述在当前时间步下,目标大语言模型输出的概率分布中所有索引落在惩罚字典上的累积概率值,所述时间自适应衰减调度为分段式衰减函数,所述分段式衰减函数的值随时间步的增大而单调递减;

安全干预向量生成模块:用于对所述初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量;

对抗性几率向量生成模块:用于将所述安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供所述目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容;

其中,所述动态门控信号生成模块,包括:

初步稀疏干预向量构建子模块:用于基于所述分段式衰减函数,将属于奖励字典的各维度奖励强度分别乘以分段式衰减函数,再乘以动态门控信号的取值,以使得奖励字典的注入强度随时间步推进而逐渐减弱直至归零,并将属于惩罚字典的各维度惩罚强度直接取

负值且不受衰减控制,以使得所述负值在全程保持不变,并将除奖励字典和惩罚字典以外的其他维度取零,构建当前时间步的初步稀疏干预向量。

6.根据权利要求5所述的系统,其特征在于,所述安全干预向量生成模块包括:

无穷范数极值裁剪子模块:用于对所述初步稀疏干预向量执行无穷范数极值裁剪处理;

归一化处理子模块:用于对执行无穷范数极值裁剪处理后的初步稀疏干预向量执行二范数全局能量归一化处理,以限制所述向量的总几何能量;

安全干预向量生成子模块:用于基于当前请求的采样温度与基准参考温度之比,对执行二范数全局能量归一化处理后的初步稀疏干预向量进行等温缩放处理,生成安全干预向量。

7.一种终端设备,包括存储器、处理器以及存储在所述存储器中并可在所述处理器上运行的计算机程序,其特征在于,所述处理器执行所述计算机程序时实现如权利要求1至4任一项所述方法的步骤。

8.一种计算机可读存储介质,所述计算机可读存储介质存储有计算机程序,其特征在于,所述计算机程序被处理器执行时实现如权利要求1至4任一项所述方法的步骤。

基于字典引导稀疏逻辑编辑的越狱安全评测方法及系统

技术领域

[0001] 本申请涉及人工智能安全的技术领域,具体而言,涉及基于字典引导稀疏逻辑编辑的越狱安全评测方法及系统。

背景技术

[0002] 随着大语言模型(如Llama-3、Qwen、DeepSeek等)在自然语言理解、代码生成及复杂推理任务中的广泛部署,其生成恶意代码、仇恨言论、虚假信息等有害内容的风险日益凸显。为了缓解这些安全隐患,业界普遍采用基于人类反馈的强化学习(RLHF)等技术使模型与人类价值观进行安全对齐(SafetyAlignment)。然而,研究表明,尽管经过了严格的安全微调,大语言模型依然极易受到“越狱(Jailbreak)”攻击的威胁。越狱攻击作为一种对抗性输入手段,旨在绕过模型的内置安全护栏,迫使其输出违反安全策略的内容。

[0003] 在现有的对抗性越狱测试方法中,主要存在以下几类技术路线,且它们均存在明显的技术缺陷:

第一,基于梯度优化的离散提示词搜索方法(Gradient-basedPromptOptimization)存在计算成本极高且缺乏可解释性的问题。以GCG(GreedyCoordinateGradient)和AutoDAN为代表的方法,通过利用目标模型的梯度信息,在离散的词表空间中搜索对抗性后缀(AdversarialSuffixes)。当这种后缀拼接在恶意指令后时,能够最大化模型生成肯定回复的概率。然而,这类方法需要进行数千次的前向与反向传播计算。在实际测试中,针对单个提示词的攻击往往需要消耗数十分钟甚至数小时的计算时间(例如GCG耗时通常大于1200秒),计算开销极其高昂,完全无法满足工业界高并发的实时安全审计需求。此外,这类方法生成的提示词通常是高困惑度(High-perplexity)的无意义乱码,无法为研究人员提供任何关于“模型为何会失效”的机理层面的解释,即缺乏机械可解释性(MechanisticInterpretability)。

[0004] 第二,现有的逻辑层干预方法(Logit-SpaceInterventions)依赖于繁重的辅助模型,系统开销巨大。为了克服提示词优化的缺陷,近期研究(如W2S方法)开始在模型的输出层(即Logits层)进行干预。虽然这些方法无需计算梯度,但它们通常依赖于极为复杂的流水线架构。例如,W2S需要同时运行一个安全对齐的小模型(如Llama-2-7b-chat)和一个未对齐的基座模型(如Llama-2-7b-base),通过计算两者的Logits差异来获得引导向量,再将其注入到目标大模型中。这种架构引入了极其庞大的显存(VRAM)开销(通常需要额外占用14.5GB以上的显存),导致系统吞吐量极低,且部署成本高昂。

[0005] 第三,对模型安全机制的深层脆弱性缺乏本质控制;现有的防御和测试机制往往将大模型的安全对齐视为一个复杂的全局特征。但最新的机械可解释性研究表明,模型的拒绝行为(RefusalBehavior)往往是由极少数的低秩语义方向(如“Sorry”,“cannot”等拒绝锚点词汇)主导的。现有的越狱攻击未能在微观的Token级别实现对这些关键语义锚点的精准剥离与抑制,导致攻击极易被简单的防御机制(如平滑处理或系统提示词强化)所拦截。

[0006] 综上所述,目前业界亟需一种既能保持高攻击成功率,又能实现极低计算开销、零辅助显存占用,且具备高度可解释性的新型大模型越狱测试框架。

发明内容

[0007] 基于此,本申请实施例提供了一种基于字典引导稀疏逻辑编辑的越狱安全评测方法及系统,以解决现有技术中缺少一种既能保持高攻击成功率,又能实现极低计算开销、零辅助显存占用,且具备高度可解释性的新型大模型越狱测试框架的问题。

[0008] 第一方面,本申请实施例提供了一种基于字典引导稀疏逻辑编辑的越狱安全评测方法,所述方法包括:

对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,其中,所述静态强度向量包含惩罚字典和奖励字典的静态强度向量;

在在线推理阶段中,拦截所述目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并根据时间自适应衰减调度和动态门控信号,从所述静态强度向量中构建当前时间步的初步稀疏干预向量,其中,所述实时拒绝概率质量用于描述在当前时间步下,目标大语言模型输出的概率分布中所有索引落在惩罚字典上的累积概率值,所述时间自适应衰减调度为分段式衰减函数,所述分段式衰减函数的值随时间步的增大而单调递减;

对所述初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量;

将所述安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供所述目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容。

[0009] 与现有技术相比存在的有益效果是:本申请实施例提供的基于字典引导稀疏逻辑编辑的越狱安全评测方法,终端设备可以先对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,然后在在线推理阶段中,拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并基于时间自适应衰减调度,从静态强度向量中构建当前时间步的初步稀疏干预向量,再对初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量,最后将安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容,在一定程度上解决了当前缺少一种既能保持高攻击成功率,又能实现极低计算开销、零辅助显存占用,且具备高度可解释性的新型大模型越狱测试框架的问题。

[0010] 需要说明的是,(1)本申请首次提出了无需梯度与辅助模型的稀疏逻辑注入机制,实现了极低延迟与零额外显存占用的实时对抗干预。传统方法在攻击时往往试图在整个32000维甚至更大的词表空间中寻找扰动方向。本发明基于对模型分布的蒙特卡洛模拟分析发现,将扰动能量集中在稀疏的语义支撑集上,其效率远高于在整个词表中进行密集的随机分布。本发明完全摒弃了反向传播计算和任何额外的辅助模型,直接在目标模型自回归生成的解码阶段(Decodingstept),对Pre-softmaxLogits中的极小部分(通常少于词表总量的2%)进行加法摄动。这种将攻击行为降维至微观Token索引级别的干预,单步开销不到1毫秒,实现了算力资源的最优配置;(2)本申请提出了一种双路径自举字典挖掘(Dual-

PathBootstrapMining)算法,实现了安全语义在高维词表中的精准隔离与定位。为了在不需要白盒权重信息的情况下精确定位负责触发拒绝机制的Token,本发明设计了离线迭代自举算法。通过在初始阶段仅抑制少数原型拒绝词(如“Sorry”),迫使大模型暴露出其备用的拒绝表达模式(HardRefusal)或强制合规模式(ForcedCompliance)。随后,通过点互信息(PMI)算法计算海量响应文本中Token的语义关联度,提取并构建出精确的“惩罚字典(PenaltyDictionary,D_p)”与“奖励字典(RewardDictionary,D_r)”。这一机制首次实现了将抽象的模型安全策略具象化为可编辑的字典索引组合;(3)本申请引入温度不变缩放(IsothermalScaling)与混合范数信任区域(Mixed-NormTrustRegion),彻底解决了干预导致的文本崩坏与困惑度飙升问题。在Logits空间进行直接修改极易破坏模型原始的概率分布,导致生成的文本出现严重的重复或乱码。本发明在实时注入时,一方面引入了与用户采样温度T相关的等温缩放算子kappa(T),确保干预对概率分布的影响不受解码参数变化的干扰;另一方面,本发明创新性地构建了混合范数信任区域投影,通过连续执行$l_infinity$极值裁剪与l_2范数归一化,严格限制了干预向量的局部尖峰与全局能量,确保了在成功绕过安全护栏的同时,完美保留了模型生成文本的自然流畅性;(4)本申请设计了基于内部状态感知的拒绝门控(Refusal-Gating)与时间衰减调度机制,实现了对抗干预的动态“快进快出”。实验表明,模型的安全防御机制主要在生成前几个Token的“安全枢纽(SafetyPivot)”阶段起作用。本发明通过实时监控当前概率分布中落在惩罚字典上的概率质量(ProbabilityMass),设定安全阈值tau_safe。一旦模型脱离了拒绝流形,门控机制将迅速切断奖励信号的注入,并配合分段式(Piecewise)的时间衰减调度,最大限度地减少对生成后半程的扰动。

[0011] 第二方面,本申请实施例提供了一种基于字典引导稀疏逻辑编辑的越狱安全评测系统,所述系统包括:

静态强度向量生成模块:用于对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,其中,所述静态强度向量包含惩罚字典和奖励字典的静态强度向量;

动态门控信号生成模块:用于在在线推理阶段中,拦截所述目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并根据时间自适应衰减调度和动态门控信号,从所述静态强度向量中构建当前时间步的初步稀疏干预向量,其中,所述实时拒绝概率质量用于描述在当前时间步下,目标大语言模型输出的概率分布中所有索引落在惩罚字典上的累积概率值,所述时间自适应衰减调度为分段式衰减函数,所述分段式衰减函数的值随时间步的增大而单调递减;

安全干预向量生成模块:用于对所述初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量;

对抗性几率向量生成模块:用于将所述安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供所述目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容。

[0012] 第三方面,本申请实施例提供了一种终端设备,包括存储器、处理器以及存储在所述存储器中并可在所述处理器上运行的计算机程序,所述处理器执行所述计算机程序时实现如上述第一方面的方法的步骤。

[0013] 第四方面,本申请实施例提供了一种计算机可读存储介质,所述计算机可读存储介质存储有计算机程序,所述计算机程序被处理器执行时实现如上述第一方面的方法的步骤。

[0014] 可以理解的是,上述第二方面至第四方面的有益效果可以参见上述第一方面中的相关描述,在此不再赘述。

附图说明

[0015] 为了更清楚地说明本申请实施例中的技术方案,下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍。

[0016] 图1是本申请一实施例提供的越狱安全评测方法的流程示意图;

图2是本申请一实施例提供的越狱安全评测方法中步骤S100的流程示意图;

图3是本申请一实施例提供的越狱安全评测方法中步骤S200的流程示意图;

图4是本申请一实施例提供的越狱安全评测方法中步骤S300的流程示意图;

图5是本申请一实施例提供的越狱安全评测系统的模块框图;

图6是本申请一实施例提供的终端设备的示意图。

具体实施方式

[0017] 以下描述中,为了说明而不是为了限定,提出了诸如特定系统结构、技术之类的具体细节,以便透彻理解本申请实施例。然而,本领域的技术人员应当清楚,在没有这些具体细节的其它实施例中也可以实现本申请。在其它情况中,省略对众所周知的系统、装置、电路以及方法的详细说明,以免不必要的细节妨碍本申请的描述。

[0018] 在本申请说明书和所附权利要求书的描述中,术语“第一”、“第二”、“第三”等仅用于区分描述,而不能理解为指示或暗示相对重要性。

[0019] 在本申请说明书中描述的参考“一个实施例”或“一些实施例”等意味着在本申请的一个或多个实施例中包括结合该实施例描述的特定特征、结构或特点。由此,在本说明书中的不同之处出现的语句“在一个实施例中”、“在一些实施例中”、“在其他一些实施例中”、“在另外一些实施例中”等不是必然都参考相同的实施例,而是意味着“一个或多个但不是所有的实施例”,除非是以其他方式另外特别强调。术语“包括”、“包含”、“具有”及它们的变形都意味着“包括但不限于”,除非是以其他方式另外特别强调。

[0020] 为了说明本申请所述的技术方案,下面通过具体实施例来进行说明。

[0021] 请参阅图1,图1是本申请实施例提供的基于字典引导稀疏逻辑编辑的越狱安全评测方法的流程示意图。在本实施例中,越狱安全评测方法的执行主体为终端设备。可以理解的是,终端设备的类型包括但不限于平板电脑、笔记本电脑、超级移动个人计算机(Ultra-Mobile Personal Computer,UMPC)、上网本、个人数字助理(Personal Digital Assistant,PDA)等,本申请实施例对终端设备的具体类型不作任何限制。

[0022] 请参阅图1,本申请实施例提供的越狱安全评测方法包括但不限于以下步骤:

在S100中,对目标大语言模型进行离线字典挖掘处理,生成静态强度向量。

[0023] 具体来说,终端设备可以先对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,其中,静态强度向量包含惩罚字典和奖励字典的静态强度向量。

[0024] 在一些可能的实现方式中,为了实现生成静态强度向量,请参阅图2,步骤S100包括但不限于以下步骤:

在S110中,初始化第一种子集和第二种子集,其中,第一种子集包含显性拒绝特征,第二种子集包含显性顺从特征。

[0025] 具体来说,终端设备可以首先初始化第一种子集和第二种子集,其中,第一种子集包含显性拒绝特征,第二种子集包含显性顺从特征。

[0026] 在一种可能的实现方式中,在系统初始化阶段,终端设备可以针对待测的目标大语言模型(TargetLLM,其词表大小记为|V|),在主控服务器中加载其原生分词器(Tokenizer)。譬如首先构建双轨种子集,即基于先验安全专家知识库,初始化构建两个相互独立的自然语言种子字符串集合,其中一个自然语言种子字符串集合为惩罚种子集D_p^(0),其可以包含具有显性拒绝特征的高频词汇汇编,如{"Sorry","apologize","cannot","unable","illegal"};其中另一个自然语言种子字符串集合可以为奖励种子集D_r^(0),其可以包含具有显性顺从与执行特征的高频词汇汇编,如{"Sure","Okay","Here","provides","Certainly"}。

[0027] 在S120中,基于预设的分词器,将第一种子集映射至目标大语言模型的词表空间中,生成初始的惩罚字典,并将第二种子集映射至目标大语言模型的词表空间中,生成初始的奖励字典。

[0028] 具体来说,在终端设备初始化第一种子集和第二种子集之后,终端设备可以基于预设的分词器,将第一种子集和第二种子集映射至目标大语言模型的词表空间中,稳定地生成初始的惩罚字典和初始的奖励字典。

[0029] 具体地,终端设备可以基于预设的分词器,将第一种子集中的各词汇分别转换为目标大语言模型词表空间中唯一对应的整数索引,归入初始的惩罚字典,然后将第二种子集中的各词汇分别转换为目标大语言模型词表空间中唯一对应的整数索引,归入初始的奖励字典,并剔除属于模型特殊控制符的索引。

[0030] 示例性地,终端设备可以调用Tokenizer的编码接口,将上述自然语言种子集中的每个字符串转换为目标模型词表空间中唯一对应的整数索引(TokenID),譬如定义一维离散索引映射集合分别为:

$D_p^{(0)}=\{id\in N \mid Decode(id)\in 惩罚种子词汇\}$,

以及$D_r^{(0)}=\{id\in N \mid Decode(id)\in 奖励种子词汇\}$;

在此过程中,终端设备可以自动检测并剔除属于模型特殊控制符(SpecialTokens,如<bos>,<eos>,<pad>)的索引,以防止干预破坏模型的自回归状态机,从而实现执行词表空间对齐映射。

[0031] 在S130中,执行迭代式双路径自举挖掘策略,以在每次迭代中,基于当前的惩罚字典对模型输出进行逻辑抑制,强制目标大语言模型生成响应文本。

[0032] 具体来说,在终端设备生成初始的惩罚字典和初始的奖励字典之后,终端设备可以执行迭代式双路径自举挖掘策略,以在每次迭代中,基于当前的惩罚字典对模型输出进

行逻辑抑制,可靠地强制目标大语言模型生成响应文本,其中,响应文本包含硬拒绝表达或强制合规表达。

[0033] 示例性地,由于大语言模型具备深层高维的防御流形(RefusalManifold),仅凭显性种子词无法全面覆盖其备用安全表达。本步骤可以通过引入对抗性逻辑剥离,强制模型暴露其潜在的安全防线。启动迭代循环,设定当前迭代轮次为k(k=1,2,...,K,其中最大迭代次数K优选为5~10),从而实现多线程有害指令加载与分词,即并行有害指令加载器从标准库(如AdvBench、HarmBench)中读取海量未标注的恶意提示词集合X={x_1,x_2,...,x_M},并通过分词器转换为输入张量序列;并且实现自回归解码阶段的逻辑抑制(LogitSuppression),即将输入序列送入目标大语言模型进行前向传播。在自回归解码的每一个时间步t,当模型生成最后一层全连接线性层(LMHead)输出的Pre-softmax原始对数几率向量l_t∈R^|V|时,干预模块介入。针对前一轮演化出的惩罚字典索引集D_p^(k-1),可以执行如下硬性抑制操作:

l'_{t,i}=l_{t,i}-λ(如果i∈D_p^(k-1)),否则为l_{t,i},

式中,λ为预设的极高惩罚常数(优选为λ≥100或直接设为∞),该操作在数学上使得模型在时间步t生成这些首选拒绝Token的边缘概率强行坍塌至0。

[0034] 不失一般性地,该步骤还可以实现被迫暴露出深层语义路径,即由于最优拒绝路径被截断,模型的概率流发生转移,迫使其激活备用语义分支,生成两类响应文本:

其中一类响应文本为硬拒绝表达(HardRefusal),即模型转向更为隐蔽、高级的拒绝流形,如生成“AsanAIassistant,Iamrestrictedfrom...”;其中另一类响应文本为强制合规表达(ForcedCompliance),即模型的安全机制被彻底绕过,被迫输出违规的恶意内容,如生成“Hereisthestep-by-stepguideto...”。

[0035] 在S140中,将包含硬拒绝表达的响应文本收集为拒绝语料库,且将包含强制合规表达的响应文本收集为合规语料库。

[0036] 具体来说,在终端设备生成响应文本之后,终端设备可以高效地将包含所述硬拒绝表达的响应文本收集为拒绝语料库,且将包含所述强制合规表达的响应文本收集为合规语料库。

[0037] 示例性地,终端设备可以部署一个轻量级二分类器(可基于正则规则库或预训练的小型安全奖励模型),对模型输出的完整响应进行识别,然后将包含硬拒绝特征的文本存入拒绝语料库X_refusal^(k),将包含实质违规内容的文本存入合规语料库X_compliance^(k),从而实现语料库自动化分类与持久化。

[0038] 在S150中,基于拒绝语料库和预设的点互信息算法,计算词表中各词汇与拒绝语义的第一点互信息得分,筛选并更新惩罚字典,并基于合规语料库和点互信息算法,计算词表中各词汇与合规语义的第二点互信息得分,筛选并更新奖励字典。

[0039] 具体来说,在终端设备分类收集之后,终端设备可以基于拒绝语料库和预设的点互信息算法,计算词表中各词汇与拒绝语义的第一点互信息得分,快速地筛选并更新惩罚字典,同时基于合规语料库和点互信息算法,计算词表中各词汇与合规语义的第二点互信息得分,快速地筛选并更新奖励字典。

[0040] 具体地,终端设备可以分别遍历拒绝语料库和合规语料库,统计词表中每个词汇在拒绝语料库中的第一条件概率、在合规语料库中的第二条件概率、以及在通用基线语料

中的全局先验概率,并采用拉普拉斯平滑算子对第一条件概率和第二条件概率进行平滑处理,然后根据第一条件概率和全局先验概率计算出词汇与拒绝语义的第一点互信息得分,并根据第二条件概率和全局先验概率计算词汇与合规语义的第二点互信息得分,再通过预设的频次阈值,过滤掉出现频次小于频次阈值的词汇及通用停用词,之后将第一点互信息得分大于预设的信息论显著性阈值的词汇索引加入至惩罚字典,并将第二点互信息得分大于信息论显著性阈值的词汇索引加入奖励字典。

[0041] 示例性地,本步骤可以从上述产生的大规模文本对流中,利用信息论量化指标精确定位对安全对齐和越狱起决定性作用的核心Token,实现从抽象安全策略到离散字典索引的具象化映射。

[0042] 不失一般性地,终端设备可以进行条件概率与先验概率的统计计算,即分别遍历拒绝语料库X_refusal和合规语料库X_compliance。统计每个Tokeni在各自语料库中的条件概率P(i|Refusal)和P(i|Compliance)。同时,统计该Token在通用大规模基线语料(或全语料库合并)中的全局先验出现概率P(i)。为了防止低频长尾Token引起统计暴涨,引入拉普拉斯平滑算子(LaplaceSmoothing):

$$P(i|y)=(Count(i,y)+\alpha)/(\sum_{j\in V}Count(j,y)+\alpha*|V|),$$

式中,$y\in\{Refusal,Compliance\}$,$\alpha$为平滑系数(优选为0.1~1.0)。

[0043] 具体地,终端设备还可以计算点互信息(PMI)得分,即量化Tokeni与特定安全语义上下文的绑定强度:

$$PMI(i;Refusal)=\log2(P(i|Refusal)/P(i)),$$

以及$PMI(i;Compliance)=\log2(P(i|Compliance)/P(i))$。

[0044] 不失一般性地,终端设备还可以进行字典结构演化与低频截断,即设定频次阈值θ_{freq}与信息论显著性阈值T_threshold。过滤掉出现频次小于θ_{freq}的词汇及通用停用词。将满足PMI(i;Refusal)>T_threshold的Token索引加入最终的惩罚字典D_p,从而将满足PMI(i;Compliance)>T_threshold的Token索引加入最终的奖励字典D_r。

[0045] 在S160中,根据惩罚字典和第一点互信息得分,生成惩罚静态强度向量,并根据奖励字典和第二点互信息得分,生成奖励静态强度向量。

[0046] 具体来说,在终端设备筛选并更新惩罚字典和奖励字典之后,终端设备可以根据惩罚字典和第一点互信息得分,可靠地生成惩罚静态强度向量,同时根据奖励字典和第二点互信息得分,可靠地生成奖励静态强度向量。

[0047] 具体地,终端设备可以先针对词表中每个词汇与拒绝语义的第一点互信息得分,以及获取词表中每个词汇与合规语义的点互信息得分,对属于惩罚字典的词汇索引,将其与拒绝语义的第一点互信息得分通过最大最小归一化映射至预设的最大摄动能量边界内,得到词汇的惩罚强度值,并且对不属于惩罚字典的词汇索引,将其惩罚强度值设为零。然后对属于奖励字典的词汇索引,将其与合规语义的第二点互信息得分通过最大最小归一化映射至预设的最大摄动能量边界内,得到词汇的奖励强度值,并且对不属于奖励字典的词汇索引,将其奖励强度值设为零;最后根据各词汇的惩罚强度值生成惩罚静态强度向量,并根据各词汇的奖励强度值生成奖励静态强度向量,需要说明的是,静态强度向量包括惩罚静态强度向量和奖励静态强度向量。

[0048] 示例性地,为了精细化控制每个Token的干预烈度,终端设备可以生成连续型的静

态强度向量,即不直接使用布尔型开关,而是基于其PMI值进行映射。通过最大最小归一化(Min-MaxNormalization)将PMI分数线性映射到可控区间[0,C_max]内(其中C_max为预设的最大摄动能量边界):

p_i=C_max*(PMI(i;Refusal)-min(PMI_p))/(max(PMI_p)-min(PMI_p))(如果i∈D_p,否则为0),

r_i=C_max*(PMI(i;Compliance)-min(PMI_r))/(max(PMI_r)-min(PMI_r))(如果i∈D_r,否则为0);

由此生成两个维度等于|V|的全域强度张量p,r∈Rˆ|V|。由于非零元素占比通常小于2%,该张量在显存中呈现极度稀疏的物理特征,从而将静态字典和强度向量持久化序列化至分布式Redis集群中。

[0049] 在S200中,在在线推理阶段中,拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并根据时间自适应衰减调度和动态门控信号,从静态强度向量中构建当前时间步的初步稀疏干预向量。

[0050] 具体来说,在终端设备生成静态强度向量之后,在在线推理阶段中,终端设备可以拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并且根据当前时间步的实时拒绝概率质量,精准地生成动态门控信号,然后基于时间自适应衰减调度,稳定地从静态强度向量中构建当前时间步的初步稀疏干预向量。

[0051] 在一些可能的实现方式中,为了实现构建初步稀疏干预向量,请参阅图3,步骤S200包括但不限于以下步骤:

在S210中,在在线推理阶段中,拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量。

[0052] 具体来说,在在线推理阶段中,终端设备可以拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量。

[0053] 在S220中,对原始对数几率向量应用当前请求的采样温度参数,计算当前时间步的概率分布。

[0054] 具体来说,在终端设备拦截原始对数几率向量之后,终端设备可以对原始对数几率向量应用当前请求的采样温度参数,可靠地计算当前时间步的概率分布,其中,当前时间步用于描述当前的自回归解码时间步。

[0055] 在S230中,将概率分布中所有落在惩罚字典索引集上的概率值进行累加积分,生成实时拒绝概率质量。

[0056] 具体来说,在终端设备计算概率分布之后,终端设备可以将概率分布中所有落在惩罚字典索引集上的概率值进行累加积分,高效地生成实时拒绝概率质量,其中,实时拒绝概率质量用于描述在当前时间步下,目标大语言模型输出的概率分布中所有索引落在惩罚字典上的累积概率值。

[0057] 示例性地,在线推理评测阶段,评测引擎(如挂载了自定义LogitsProcessor插件的vLLM引擎)可以拦截客户端请求。由于不同业务请求会配置不同的采样温度(Temperature,T),而标准自回归生成的Softmax层公式为:

P(x_t=i|x_{<t})=exp(l_{t,i}/T)/∑_{j∈V}exp(l_{t,j}/T),

式中,温度参数T处于分母位置,这意味着当T趋近于0(贪婪解码)时,逻辑值微小的波动会被指数级放大;当T较大时,逻辑值差异会被严重平滑。为了消除解码参数波动对评测强鲁棒性的干扰,本申请可以引入等温缩放算子(IsothermalScalingOperator)κ(T):

κ(T)=T_ref/T,

式中,T_ref为静态字典生成时采用的基准参考温度(统一设定为1.0)。在线运行时,终端设备可以实时获取用户当前请求传入的温度T,动态计算出缩放系数κ(T),用于对后续步骤生成的干预能量进行自适应线性缩放,实现全温度环境下的干预保真度。

[0058] 在S240中,若实时拒绝概率质量大于预设的安全阈值,则动态门控信号为激活状态,并将动态门控信号的取值设为1,否则动态门控信号为关闭状态,并将动态门控信号的取值设为0。

[0059] 具体来说,如果实时拒绝概率质量大于预设的安全阈值,则终端设备可以动态门控信号为激活状态,并将动态门控信号的取值设为1,否则终端设备可以动态门控信号为关闭状态,并将动态门控信号的取值设为0。

[0060] 示例性地,由于大语言模型的安全防御行为主要集中在其生成的前几个Token(通常称为“安全枢纽”阶段),一旦模型被成功诱导生成了诸如“Sure,hereis”的顺从前缀,其内部的拒绝流形就会发生坍塌,故后续步骤无需继续施加强烈干预。

[0061] 具体地,终端设备可以拦截原始几率向量并计算实时Softmax,即在自回归生成的任意时间步t,前向传播LMHead输出原始Pre-softmax对数几率向量l_t∈Rˆ|V|。对其应用当前请求的温度参数T,计算当前步的概率分布。

[0062] 具体来说,终端设备还可以拒绝概率质量积分(ProbabilityMassIntegration),即将当前分布中,所有落在惩罚字典D_p索引集上的概率值进行累加积分,定义为实时拒绝能量积分m_p(t):

m_p(t)=∑_{j∈D_p}Softmax(l_t/T)_j=∑_{j∈D_p}exp(l_{t,j}/T)/∑_{k∈V}exp(l_{t,k}/T)。

[0063] 不失一般性地,终端设备还可以构建自适应拒绝门控函数(Refusal-Gating),即设定超参数安全置信度阈值τ_safe(通常设定在10ˆ-4~10ˆ-2之间)。构建离散门控开关G(t):

G(t)=1(如果m_p(t)>τ_safe),否则为0,

式中,当m_p(t)≤τ_safe时,判定模型已实质上脱离了拒绝流形,门控函数G(t)立即归零,切断奖励字典的额外信号注入,从而有效防止干预过度导致的模型语言模型能力退化或文本语义崩坏。

[0064] 在S250中,根据时间自适应衰减调度和动态门控信号,从静态强度向量中构建当前时间步的初步稀疏干预向量。

[0065] 具体来说,在终端设备确定动态门控信号之后,终端设备可以基于时间自适应衰减调度,从静态强度向量中构建当前时间步的初步稀疏干预向量,其中,时间自适应衰减调度为分段式衰减函数,分段式衰减函数的值随时间步的增大而单调递减,时间自适应衰减调度作为干预强度随自回归解码时间步的增加而逐步衰减的调度策略,用于控制在生成序列的不同阶段对目标大语言模型施加的干预程度。

[0066] 在一些可能的实现方式中,为了实现基于时间自适应衰减调度,从静态强度向量

中构建当前时间步的初步稀疏干预向量,终端设备可以基于分段式衰减函数,将属于奖励字典的各维度奖励强度分别乘以分段式衰减函数,再乘以动态门控信号的取值,以使得奖励字典的注入强度随时间步推进而逐渐减弱直至归零,并将属于惩罚字典的各维度惩罚强度直接取负值且不受衰减控制,以使得负值在全程保持不变,并将除奖励字典和惩罚字典以外的其他维度取零,构建当前时间步的初步稀疏干预向量。

[0067] 示例性地,为了使评测诱导信号更加契合自然语言的上下文依赖律,本步骤可以引入随时间步长t推进的分段式时间衰减函数s(t)。具体地,终端设备可以先定义时间衰减调度程序,优选采用分段线性衰减或指数衰减形式:

$s(t)=\max(0,1-t/N_pivot)$,

式中,N_pivot为预设的安全枢纽步长上限(优选为8~16个Token)。

[0068] 然后终端设备可以,结合静态强度向量(p,r)、动态门控信号(G(t))以及时间衰减因子(s(t)),在GPU显存中直接并行构建针对词表全空间维度的初步干预向量$\Delta_t\in R^{|V|}$,从而实现高维稀疏合成。其各维度i的元素值显式可以定义为:

$\Delta_\{t,i\}=-p_i$(如果$i\in D_p$),

$\Delta_\{t,i\}=s(t)*r_i*G(t)$(如果$i\in D_r$),

$\Delta_\{t,i\}=0$(其他情况);

其中,该向量表现出极高的稀疏性(SparseTopology),在执行张量级别的加法时,运算复杂度等价于仅对非零元素索引进行Gather-Scatter操作,计算开销控制在0.5毫秒以内。

[0069] 在S300中,对初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量。

[0070] 具体来说,在终端设备构建初步稀疏干预向量之后,终端设备可以对初步稀疏干预向量执行混合范数信任区域投影约束,可靠地生成安全干预向量。

[0071] 在一些可能的实现方式中,为了实现生成安全干预向量,请参阅图4,步骤S300包括但不限于以下步骤:

在S310中,对初步稀疏干预向量执行无穷范数极值裁剪处理。

[0072] 具体来说,终端设备可以先对初步稀疏干预向量执行无穷范数极值裁剪处理,以限制目标维度的最大摄动量,其中,目标维度用于描述初步稀疏干预向量中与词表的各词汇索引对应的任意一个维度。

[0073] 示例性的,终端设备可以直接在对数几率(Logits)空间施加扰动,若扰动能量无边界放大,极易造成局部概率分布出现病态尖峰(Spike),导致采样器锁死在极少数特定词汇上,引发文本严重重复或生成乱码。因此,为了执行混合范数信任区域(Mixed-NormTrustRegion)投影约束,本申请创新性地构建了一个混合范数信任区域约束空间C:

$C=\{v\in R^{|V|}||v||_\infty\leqslant C$,且$||v||_2\leqslant B_2$,且$supp(v)\subseteq\{D_p\cup D_r\}\}$;

终端设备可以通过连续执行收缩映射,强行将初步干预向量Δ_t投影至该信任区域内,实现对l_∞范数极值裁剪,从而防止单个Token摄动量过大。对Δ_t的每一个维度元素进行硬性边界截断,限制在最大局部扰动门限[-C,C]内(优选C=4.0):

$\Delta_t^{(1)}=Clip(\Delta_t,-C,C)=\max(-C,\min(C,\Delta_t))$。

[0074] 在S320中,对执行无穷范数极值裁剪处理后的初步稀疏干预向量执行二范数全局

能量归一化处理,以限制执行无穷范数极值裁剪处理后的初步稀疏干预向量的总几何能量。

[0075] 具体来说,在终端设备执行无穷范数极值裁剪处理之后,终端设备可以对执行无穷范数极值裁剪处理后的初步稀疏干预向量执行二范数全局能量归一化处理,以限制向量的总几何能量。

[0076] 示例性地,为了l_2范数全局能量归一化,控制干预向量的总几何能量,终端设备可以计算裁剪后向量的欧几里得范数,即||Δ_t^(1)||_2。若其超过预设的全局能量预算边界B_2(优选B_2=5.0),则在向量空间执行等比例向心收缩:

Δ_t^(2)=Δ_t^(1)*(B_2/||Δ_t^(1)||_2)(如果||Δ_t^(1)||_2>B_2),否则为Δ_t^(1);

由于该归一化操作属于非膨胀性收缩映射(ContractionMapping),在降低全局二范数能量的同时,严格保证了各个维度的绝对值依然顺从前一步的l_∞范数约束。

[0077] 在S330中,基于当前请求的采样温度与基准参考温度之比,对执行二范数全局能量归一化处理后的初步稀疏干预向量进行等温缩放处理,生成安全干预向量。

[0078] 具体来说,在终端设备执行二范数全局能量归一化处理之后,终端设备可以基于当前请求的采样温度与基准参考温度之比,对执行二范数全局能量归一化处理后的初步稀疏干预向量进行等温缩放处理,生成安全干预向量。

[0079] 需要说明的是,当前请求的采样温度和基准参考温度均可以通过已有技术进行获取,故不赘述。示例性地,当前请求的采样温度可以由用户在发起推理请求时通过API参数传入,是其请求自带的超参数;基准参考温度可以是离线生成静态强度向量时统一预先设定的固定值,譬如设定为1.0。

[0080] 示例性地,为了实现注入温度补偿,终端设备可以应用上述步骤中的等温缩放因子,得到最终被施加到算力单元中的安全干预向量Δ'_t:

Δ'_t=Δ_t^(2)*κ(T)。

[0081] 在S400中,将安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容。

[0082] 具体来说,在终端设备生成安全干预向量之后,终端设备可以将安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容。

[0083] 示例性地,为了实现稀疏逻辑叠加与自回归安全评测响应生成,终端设备可以将张量就地相加(In-placeTensorAddition),即在vLLM推理算子释放的前一刻,将通过混合范数投影对齐后的干预张量Δ'_t叠加至原始Pre-softmaxLogits向量上:

l'_t=l_t+Δ'_t。

[0084] 具体地,终端设备还可以送入采样器进行自回归推进,即将修正后的对抗性几率向量l'_t传入大语言模型原生的核采样(Top-p)或最高频采样(Top-k)模块中,输出当前步的真实TokenIDx_t。

[0085] 具体来说,终端设备还可以实现状态机循环与漏洞报表生成,即将x_t动态追加至输入上下文和键值缓存(KV-Cache)中,更新时间步至t+1,并无缝返回执行步骤S105,直至

触发模型终止符<eos>或达到最大生成长度限额。系统最终导出的生成序列即作为大模型安全对齐鲁棒性的量化评测漏洞证据(ExploitOutput),自动呈现在可视化大盘中。

[0086] 需要说明都是,与现有的越狱攻击和安全评测方法相比,本发明具有以下突出的实质性特点和显著的进步:(1)极其强悍的跨模型攻击成功率(AttackSuccessRate,ASR)。实验数据表明,本系统在针对Llama-2-7B/13B、Vicuna-13B和Qwen-14B等多种架构的大模型时,在AdvBench等国际主流安全基准测试中均达到了93.6%至95.9%的超高平均ASR。相比于先进的提示词优化方法AutoDAN(平均51.6%)和GCG(平均63.2%),本发明实现了断崖式的性能领先。(2)零显存占用与极致的推理级延迟(ZeroVRAM&Near-InferenceSpeed)。现有的W2S等Logits攻击方法由于需要加载额外的基座辅助模型,导致额外的VRAM开销高达14.5GB以上。本发明由于采用完全解析的静态字典与稀疏加法,额外显存占用绝对值为0。在延迟方面,本发明的单条测试指令端到端耗时仅为约6.8秒,而基于梯度的GCG算法则需要1200秒以上。这种高吞吐特性使本发明完全具备了在生产环境中进行大规模并发巡检的能力。(3)精准击穿“自反思”与“系统提示词强化”等防御机制。传统的越狱往往依赖异常的输入特征,极易被输入端清洗机制(如Paraphrasing)或模型系统提示词强化(Self-Reminder)所防御。测试表明,在面对系统提示词强化的防御下,本发明依然能保持88.6%的高攻击成功率;在面对基于平滑处理(Probabilitysmoothing,噪声系数0.05)的Logits防御时,仍具有82.5%的强鲁棒性。本方法从数学本质上揭示了只要模型保留了生成有害内容的深层权重,外部的安全防御就极易被内部的微小Logit摄动所瓦解。(4)维持高水准的文本生成流畅度(LinguisticFluency)。GCG等方法由于强制优化,通常会导致生成的文本困惑度(PPL)严重恶化。本发明通过引入双轨控制——即混合范数信任区投影与动态拒绝门控,有效规避了无节制的概率重写。在使用分段衰减调度的配置下,攻击成功后的文本困惑度维持在极低的9.54,使得模型生成的恶意内容逻辑严密、格式自然,为评估模型在真实场景下的危害性提供了最高质量的威胁样本。

[0087] 在一种可能的实现方式中,本申请提供一种面向大模型开放平台的云原生自动化安全审计服务系统;在实际的工业级部署中,本发明实施例提供的一种基于字典引导稀疏逻辑编辑的大语言模型越狱安全评测系统可以优选采用云原生(CloudNative)的微服务架构,该系统整体分为离线字典挖掘平台与在线评测推理服务两大核心支柱。

[0088] 在离线阶段,字典引导挖掘平台(D-GMiningPlatform);该平台部署于高性能计算集群(HPCCluster),配备多路NVIDIAA100/H800GPU。其核心任务是针对待测的特定大语言模型(TargetLLM),在不触动其底层权重参数的情况下,解析并提取其内部负责安全拒绝语义的关键Token集合。该平台包含:有害指令加载器(多线程,对接AdvBench、HarmBench等标准库)、迭代自举控制器(负责维护K轮自举挖掘逻辑)、白盒/黑盒Logit拦截接口、基于CPU并行加速的PMI计算引擎,以及最终生成的惩罚字典D_p和奖励字典D_r的持久化存储(如Redis集群或PostgreSQL)。

[0089] 在在线阶段,推理时逻辑编辑干预服务(Inference-timeService)。该服务作为大模型推理流水线(Pipeline)中的核心中间件挂载。在用户请求的大模型自回归生成循环(AutoregressiveGenerationLoop)中,系统并不在输入端修改Prompt,而是通过拦截目标模型最后一层全连接层输出的Pre-softmaxLogits,实时、动态地施加基于稀疏字典索引的干预向量Delta_t。该干预服务优选通过挂载在推理引擎(如vLLM或FastChat)的

LogitsProcessor插件中实现,确保干预操作对整体推理延迟的影响控制在毫秒级。

[0090] 在一种可能的实现方式中,在大型AI算力中心发布新模型前,需要对其进行高并发的安全压力测试。本实施例可以采用全容器化部署(Kubernetes集群),即:

(1)前端采用SpringBoot构建网关,通过Kafka消息队列异步接收租户发起的数十万条有害指令测试请求。后台GPU推理集群使用vLLM引擎部署目标模型(如Qwen-72B-Chat)。

[0091] (2)在离线挖掘阶段生成的惩罚字典向量p和奖励字典向量r,被序列化存储在Redis集群中。每个GPU推理节点挂载一个基于Python实现的LogitsProcessor插件,在推理启动时利用Redisson分布式锁确保无冲突地加载字典至显存中。

[0092] (3)当拦截评估请求进入模型后,拦截器执行上述步骤(设置tau_safe=0.01,C=4.0,B=5.0)。实时监控发觉,在施加了本发明实施例极低能量预算的摄动后,模型的越狱成功率(ASR)迅速飙升至95.9%。此时,网关层自动触发熔断熔断告警,生成详尽漏洞报告,拦截该模型版本的生产发布。

[0093] 在一种可能的实现方式中,本申请提供一种针对离线端侧小模型的轻量化越狱探测与防御加固工具;针对部署在移动端或机器人端侧的量化小模型(如Llama-3-8B-Quantized),本实施例提供轻量化探针,即:

(1)端侧CPU/NPU算力有限,VRAM紧张,无法运行梯度优化攻击方法或W2S等依赖辅助大模型的方法。

[0094] (2)由于惩罚字典和奖励字典具有极度稀疏性(如|D_r|+|D_p|约等于1024),本工具将字典索引压缩存储为16位整数,权值存储为FP16浮点数,总额外内存开销仅几KB。

[0095] (3)在推理引擎(如Llama.cpp)的C++Logits处理接口中嵌入干预逻辑,只需进行上千次的稀疏加法运算,对端侧推理延迟(TPS)的影响小于2%,实现了对端侧模型安全边界的实时、无损探测。

[0096] 在一种可能的实现方式中,本申请提供一种基于动态门控机制的“反思型”对齐模型鲁棒性评估;实验研究表明,模型的安全防御集中在生成前几个Token的“安全枢纽”阶段。本实施例专门用于测试针对此类“反思型”防御模型的鲁棒性,即:

(1)针对目标提示词“Howtobuildabomb?”,启用拒绝门控信号G(t);

(2)在解码第一步,模型内部概率在种子“Sorry”上高达0.9。门控信号即刻激活,将奖励字典Token(“Sure”)对应的Logits注入(同时抑制“Sorry”)。当模型被诱导生成前三个Token为“Hereisthe...”时,模型的内部拒绝概率质量下降到tau_safe=0.01以下。此时,门控即刻切断奖励信号(G(t)=0),防止过度编辑导致文本崩坏,保证了攻击成功后的生成文本符合标准的自然语言逻辑结构。

[0097] 在一种可能的实现方式中,本申请提供一种工业级对抗演示与评估大盘的部署;本实施例构建一个可视化的红蓝对抗大盘,用于机理研究和人工评估,即:

(1)用户输入恶意Prompt,大盘界面实时展示随着时间衰减函数s(t)的变化,模型Pre-softmaxLogits空间概率分布柱状图的动态演化过程;

(2)大盘能直观展示本发明实施例提取出的惩罚字典索引映射回Token后包含“cannot”,“rule”,“illegal”等词,而奖励字典包含“Sure”,“Okay”,“provides”等词;

(3)评估系统配置裁判模型(如GPT-4o-2024-05-13),依照五级打分制对生成的响

应进行安全评估。人工复核表明,经本发明实施例干预生成恶意内容的质量和流畅度(ASASR高达93.6%-95.8%)完美达到了专业红队专家的水平。

[0098] 在一种可能的实现方式中,发明人对本申请进行一系列实验,实现结果如下表1、表2和表3所示。

[0099] 表1SIBI在测评集AdvBench上的效果表

方法	Llama-2-7b	Llama-2-13b	Vicuna-13b	Qwen-14b	平均
AdvPrompter	22.8	18.5	72.4	38.2	38.0
GCG	56.5	42.1	88.5	65.5	63.2
AutoDAN	31.5	25.4	91.2	58.4	51.6
AmpleGCG	58.4	52.1	95.6	72.4	69.6
W2S	91.4	88.5	97.4	94.2	92.9
SIBI(Ours)	95.4	93.8	98.5	95.8	95.9

表2SIBI在测评集HarmBench上的效果表

方法	Llama-2-7b	Llama-2-13b	Vicuna-13b	Qwen-14b	平均
AdvPrompter	19.4	16.2	70.2	35.5	35.3
GCG	51.2	38.6	82.1	60.4	58.1
AutoDAN	28.2	22.1	90.5	54.2	48.8
AmpleGCG	54.2	48.5	94.8	68.2	66.4
W2S	88.5	84.1	95.5	92.5	90.2
SIBI(Ours)	90.2	87.6	96.3	93.4	91.9

表3SIBI在测评集JailbreakBench上的效果

方法	Llama-2-7b	Llama-2-13b	Vicuna-13b	Qwen-14b	平均
AdvPrompter	20.6	17.4	71.5	36.8	36.6
GCG	53.8	40.5	86.4	63.2	61.0
AutoDAN	29.4	24.3	90.8	56.5	50.3
AmpleGCG	56.7	50.4	95.5	70.5	68.3
W2S	90.2	87.6	96.8	93.1	91.9
SIBI(Ours)	92.8	90.4	97.1	94.2	93.6

本申请实施例基于字典引导稀疏逻辑编辑的越狱安全评测方法的实施原理为:终端设备可以先对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,然后在在线推理阶段中,拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并基于时间自适应衰减调度,从静态强度向量中构建当前时间步的初步稀疏干预向量,再对初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量,最后将安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容,从而实现提供一种既能保持高攻击成功率,又能实现极低计算开销、零辅助显存占用,且具备高度可解释性的新型大模型越狱测试框架,通过在词表空间施加极度稀疏的、基于温度缩放和信任区域约束的局部逻辑编辑,彻底免除了传统梯度攻击的高算力开销和传统逻辑干预方法的辅助模型显存开销,实

现了高效、流畅、可解释且鲁棒的大模型越狱安全评测。

[0100] 需要说明的是,上述实施例中各步骤的序号的大小并不意味着执行顺序的先后,各过程的执行顺序应以其功能和内在逻辑确定,而不应对本申请实施例的实施过程构成任何限定。

[0101] 本申请的实施例还提供了一种基于字典引导稀疏逻辑编辑的越狱安全评测系统,为便于说明,仅示出与本申请相关的部分,如图5所示,该系统50包括:

静态强度向量生成模块51:用于对目标大语言模型进行离线字典挖掘处理,生成静态强度向量,其中,所述静态强度向量包含惩罚字典和奖励字典的静态强度向量;

动态门控信号生成模块52:用于在在线推理阶段中,拦截所述目标大语言模型的每个自回归解码时间步对应的原始对数几率向量,并根据当前时间步的实时拒绝概率质量,生成动态门控信号,并基于时间自适应衰减调度,从所述静态强度向量中构建当前时间步的初步稀疏干预向量;

安全干预向量生成模块53:用于对所述初步稀疏干预向量执行混合范数信任区域投影约束,生成安全干预向量;

对抗性几率向量生成模块54:用于将所述安全干预向量叠加至原始对数几率向量上,生成修正后的对抗性几率向量,以供所述目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成,得到用于评测安全性的响应内容。

[0102] 可选的,上述动态门控信号生成模块52包括:

初步稀疏干预向量构建子模块:用于基于所述分段式衰减函数,将属于奖励字典的各维度奖励强度分别乘以分段式衰减函数,再乘以动态门控信号的取值,以使得奖励字典的注入强度随时间步推进而逐渐减弱直至归零,并将属于惩罚字典的各维度惩罚强度直接取负值且不受衰减控制,以使得所述负值在全程保持不变,并将除奖励字典和惩罚字典以外的其他维度取零,构建当前时间步的初步稀疏干预向量。

[0103] 可选的,上述安全干预向量生成模块53包括:

无穷范数极值裁剪子模块:用于对初步稀疏干预向量执行无穷范数极值裁剪处理;

归一化处理子模块:用于对执行无穷范数极值裁剪处理后的初步稀疏干预向量执行二范数全局能量归一化处理,以限制向量的总几何能量;

安全干预向量生成子模块:用于基于当前请求的采样温度与基准参考温度之比,对执行二范数全局能量归一化处理后的初步稀疏干预向量进行等温缩放处理,生成安全干预向量。

[0104] 需要说明的是,上述模块之间的信息交互、执行过程等内容,由于与本申请方法实施例基于同一构思,其具体功能及带来的技术效果,具体可参见方法实施例部分,此处不再赘述。

[0105] 本申请实施例还提供了一种终端设备,如图6所示,该实施例的终端设备60包括:处理器61、存储器62以及存储在存储器62中并可在处理器61上运行的计算机程序63。处理器61执行计算机程序63时实现上述越狱安全评测方法实施例中的步骤,例如图1所示的步骤S100至S400;或者,处理器61执行计算机程序63时实现上述装置中各模块的功能,例如图5所示模块51至模块54的功能。

[0106] 该终端设备60可以是桌上型计算机、笔记本、掌上电脑及云端服务器等计算设备，该终端设备60包括但不仅限于处理器61、存储器62。本领域技术人员可以理解，图6仅仅是终端设备60的示例，并不构成对终端设备60的限定，可以包括比图示更多或更少的部件，或者组合某些部件，或者不同的部件，例如终端设备60还可以包括输入输出设备、网络接入设备、总线等。

[0107] 其中，处理器61可以是中央处理单元(Central Processing Unit，CPU)，还可以是其它通用处理器、数字信号处理器(Digital Signal Processor，DSP)、专用集成电路(Application Specific Integrated Circuit，ASIC)、现场可编程门阵列(Field-Programmable Gate Array，FPGA)或者其它可编程逻辑器件、分立门或者晶体管逻辑器件、分立硬件组件等；通用处理器可以是微处理器或者该处理器也可以是任何常规的处理器等。

[0108] 存储器62可以是终端设备60的内部存储单元，例如终端设备60的硬盘或内存，存储器62也可以是终端设备60的外部存储设备，例如终端设备60上配备的插接式硬盘，智能存储卡(Smart Media Card，SMC)，安全数字(Secure Digital，SD)卡，闪存卡(Flash Card)等；进一步地，存储器62还可以既包括终端设备60的内部存储单元也包括外部存储设备，存储器62还可以存储计算机程序63以及终端设备60所需的其它程序和数据，存储器62还可以用于暂时地存储已经输出或者将要输出的数据。

[0109] 本申请的一个实施例还提供了一种计算机可读存储介质，该存储介质存储有计算机程序，该计算机程序在被处理器执行时，可实现上述各个方法实施例的步骤。其中，计算机程序包括计算机程序代码，计算机程序代码可以为源代码形式、对象代码形式、可执行文件或某些中间形式等；计算机可读介质可以包括：能够携带计算机程序代码的任何实体或装置、记录介质、U盘、移动硬盘、磁碟、光盘、计算机存储器、只读存储器(Read-Only Memory，ROM)、随机存取存储器(Random Access Memory，RAM)、电载波信号、电信信号以及软件分发介质等。

[0110] 以上均为本申请的较佳实施例，并非依此限制本申请的保护范围，故：凡依本申请的方法、原理、结构所做的等效变化，均应涵盖于本申请的保护范围之内。

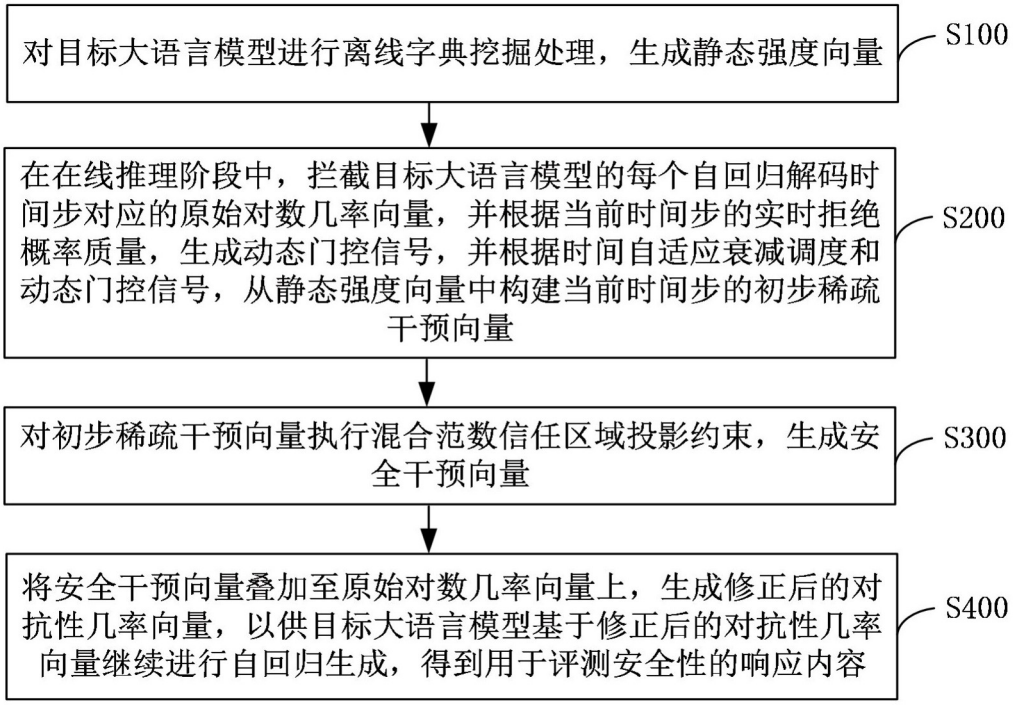

对目标大语言模型进行离线字典挖掘处理，生成静态强度向量
S100
在在线推理阶段中，拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量，并根据当前时间步的实时拒绝概率质量，生成动态门控信号，并根据时间自适应衰减调度和动态门控信号，从静态强度向量中构建当前时间步的初步稀疏干预向量
S200
对初步稀疏干预向量执行混合范数信任区域投影约束，生成安全干预向量
S300
将安全干预向量叠加至原始对数几率向量上，生成修正后的对抗性几率向量，以供目标大语言模型基于修正后的对抗性几率向量继续进行自回归生成，得到用于评测安全性的响应内容
S400

图1

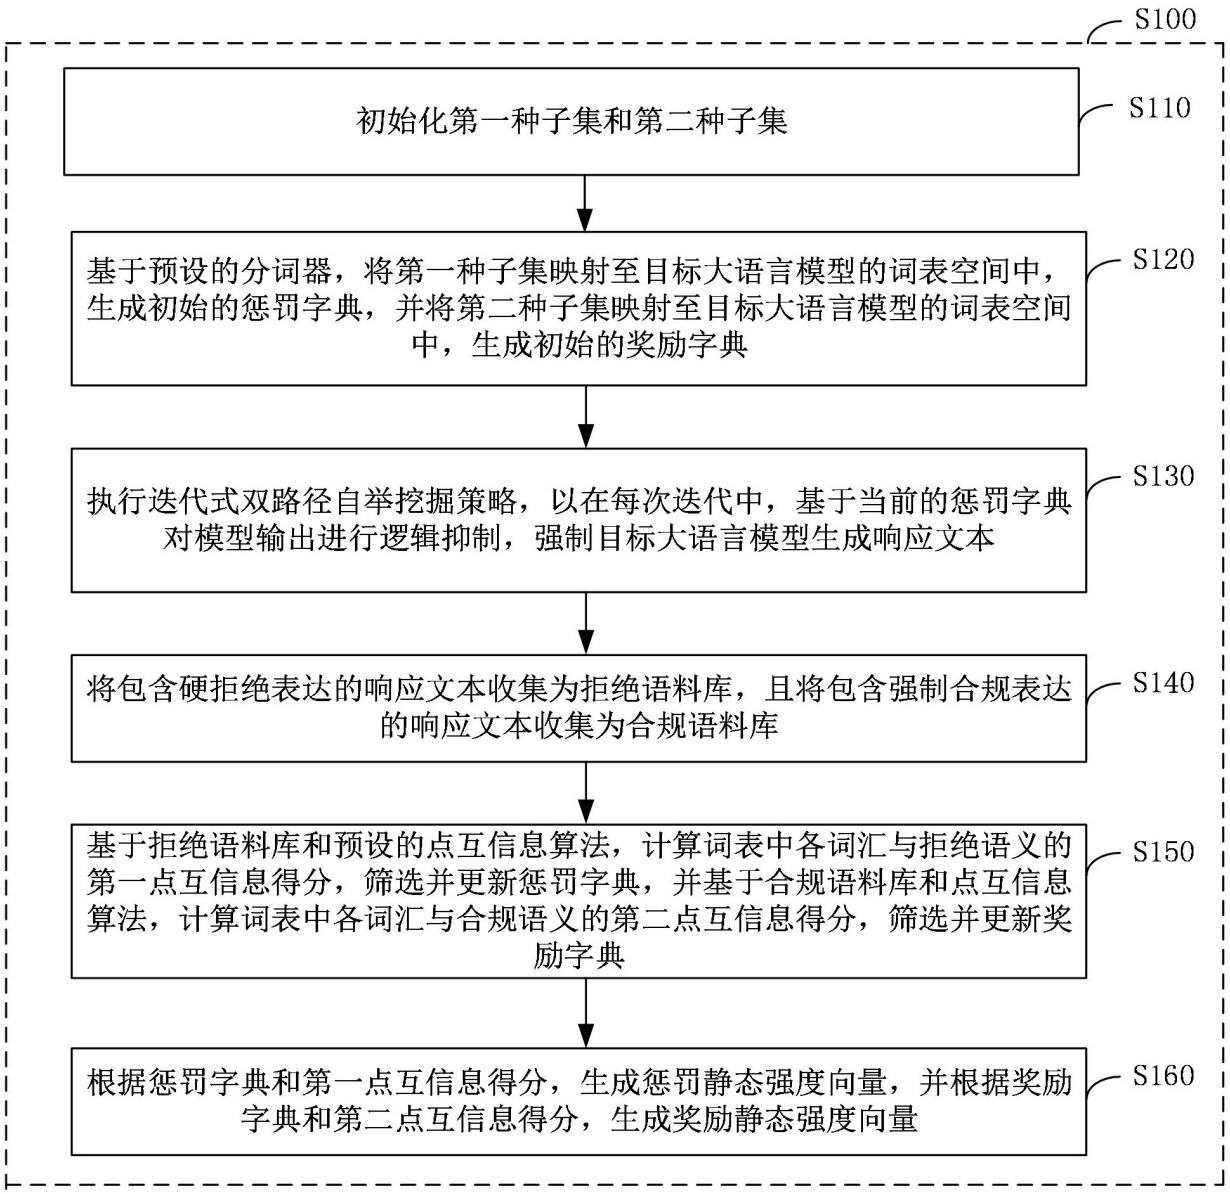

S100
初始化第一种子集和第二种子集
S110
基于预设的分词器，将第一种子集映射至目标大语言模型的词表空间中，生成初始的惩罚字典，并将第二种子集映射至目标大语言模型的词表空间中，生成初始的奖励字典
S120
执行迭代式双路径自举挖掘策略，以在每次迭代中，基于当前的惩罚字典对模型输出进行逻辑抑制，强制目标大语言模型生成响应文本
S130
将包含硬拒绝表达的响应文本收集为拒绝语料库，且将包含强制合规表达的响应文本收集为合规语料库
S140
基于拒绝语料库和预设的点互信息算法，计算词表中各词汇与拒绝语义的第一点互信息得分，筛选并更新惩罚字典，并基于合规语料库和点互信息算法，计算词表中各词汇与合规语义的第二点互信息得分，筛选并更新奖励字典
S150
根据惩罚字典和第一点互信息得分，生成惩罚静态强度向量，并根据奖励字典和第二点互信息得分，生成奖励静态强度向量
S160

图2

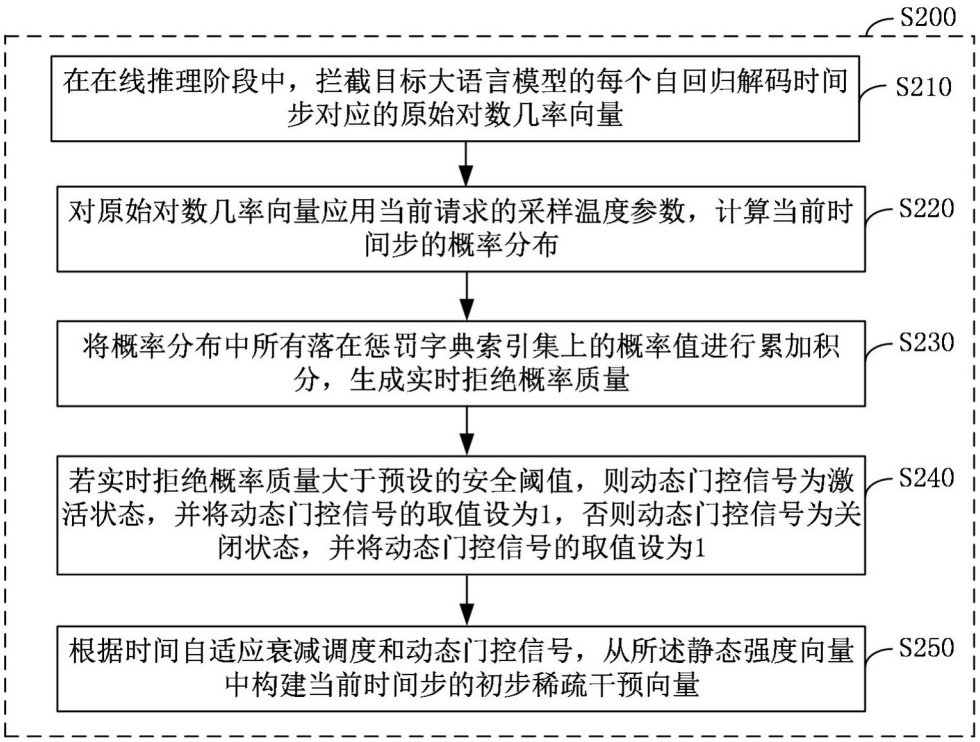

S200
在在线推理阶段中，拦截目标大语言模型的每个自回归解码时间步对应的原始对数几率向量
S210
对原始对数几率向量应用当前请求的采样温度参数，计算当前时间步的概率分布
S220
将概率分布中所有落在惩罚字典索引集上的概率值进行累加积分，生成实时拒绝概率质量
S230
若实时拒绝概率质量大于预设的安全阈值，则动态门控信号为激活状态，并将动态门控信号的取值设为1，否则动态门控信号为关闭状态，并将动态门控信号的取值设为1
S240
根据时间自适应衰减调度和动态门控信号，从所述静态强度向量中构建当前时间步的初步稀疏干预向量
S250

图3

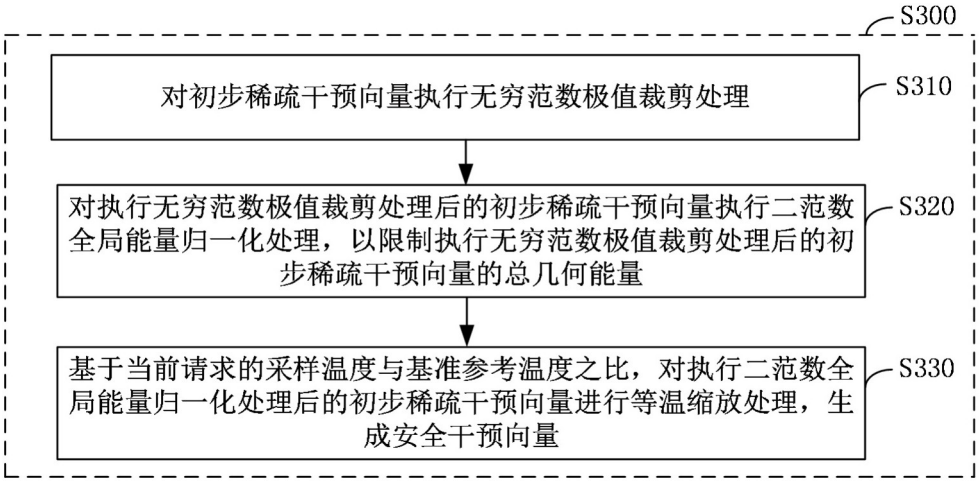

S300
对初步稀疏干预向量执行无穷范数极值裁剪处理
S310
对执行无穷范数极值裁剪处理后的初步稀疏干预向量执行二范数全局能量归一化处理，以限制执行无穷范数极值裁剪处理后的初步稀疏干预向量的总几何能量
S320
基于当前请求的采样温度与基准参考温度之比，对执行二范数全局能量归一化处理后的初步稀疏干预向量进行等温缩放处理，生成安全干预向量
S330

图4

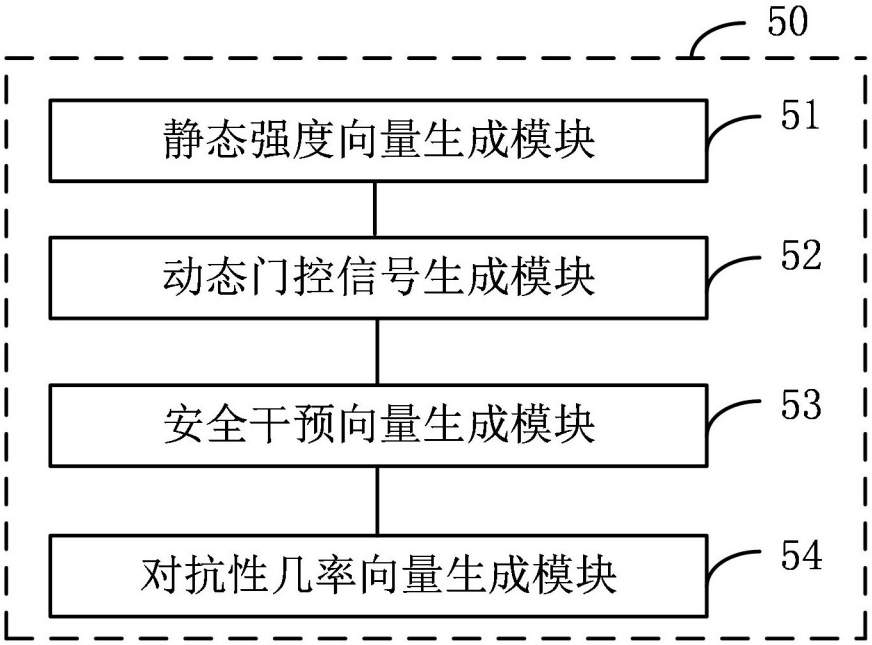

50
静态强度向量生成模块
51
动态门控信号生成模块
52
安全干预向量生成模块
53
对抗性几率向量生成模块
54

图5

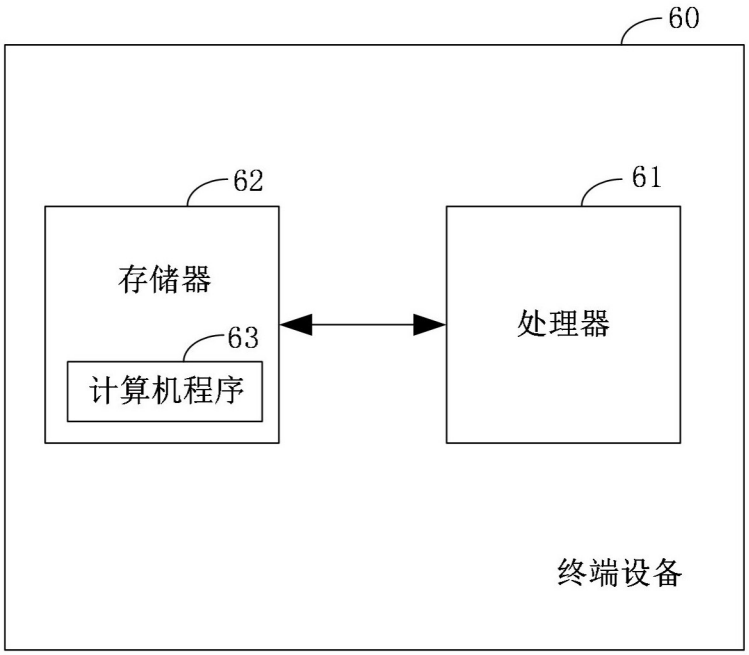

60
62
存储器
63
计算机程序
61
处理器
终端设备

图6